

Universität Freiburg (CH)

Departement Kommunikationswissenschaft und
Medienforschung DCM

Bachelorarbeit

Betreuer: Prof. Dr. Andreas Fahr

Optimierung von
Meinungsführerschaft auf Twitter

Eingereicht von: Janice Butler

Gässlimattweg 8

3067 Boll

Email: janice.butler@unifr.ch

Studierenden-Nummer: 15-212-202

Datum: 14. Februar 2018

Inhaltsverzeichnis

1. Einleitung	1
1.1. Vorgehen	2
1.2. Grundansatz.....	2
2. Theoretischer Hintergrund	4
2.1. Opinion Leadership	5
2.2. Sentiment	7
2.3. Soziale Netzwerke.....	7
2.3.1. Soziale Netzwerk Topologien	11
2.4. Netzwerkanalyse	12
2.4.1. Netzwerkmetriken	14
2.4.2. Centralities.....	15
2.5. Artificial Neuronale Netze (ANNs).....	17
2.5.1. Wort Repräsentationen als Vektoren.....	20
2.5.2. N-Grams	21
2.5.3. Trainieren von Neuronalen Netzen.....	21
2.6. Forschungsfrage	22
3. Konzeption und Methode.....	23
3.1. Design	23
3.2. Datenzugriff.....	25
3.2.1. Exploratives Suchen	25
3.2.2. API Einsatz	25
3.2.3. MATLAB	26
3.2.4. NodeXL.....	26
3.2.5. Textkorpora.....	27
3.3. Limitationen der Twitter API.....	28
3.4. Netzwerkanalyse.....	28
3.5. Datenselektion	29
3.6. Datenbereinigung	29
3.7. Datenaufbereitung/Text-Vektorisierung	31
3.8. Mustererkennung und Optimierung mittels Neuronalen Netzen	31
3.8.1. Konfiguration und Optimierung der Neuronalen Netze	32
3.9. Darstellung und Evaluation von Lernergebnissen	34

3.9.1.	Die Confusion Matrix	34
3.9.2.	Receiver Operating Characteristic.....	35
3.9.3.	Performanz Validierung und Training State	36
4.	Ergebnisse	37
4.1.	Selektion der Datensätze zu Untersuchung	37
4.2.	Erstellung von Word Embeddings für #unfoundation	39
4.3.	Klassenbestimmung der Daten.....	40
4.4.	Supervised Learning Ergebnisse.....	40
4.4.1.	Betweenness Centrality.....	41
4.4.2.	Positives Sentiment	42
4.4.1.	Negatives Sentiment.....	43
4.5.	Anwendung des Neuronalen Netzes	43
4.6.	Interpretation der Ergebnisse	45
5.	Konklusion	46
6.	Ausblick und Limitation der angewandten Methode	48
Bibliografie.....		50
Anhang A		56
Twitter Advanced Search		56
Anhang B		57
Apigee API Console		57
Anhang C		59
MATLAB Entwicklungsumgebung		59
Anhang D		60
Gruppierungen		60
Führende Betweenness Zentralitäten		62
Führende URLs, Hashtags und Wörter im Netzwerk		62
Anhang E.....		66
Anhang F.....		110

Abbildungsverzeichnis

Abbildung 1 Media Netzwerk Archetypen (Quelle: Smith, et al., 2009)	12
Abbildung 2: Betweenness Centralities eines einfachen Netzes	16
Abbildung 3 Vergleiche der vier Typen von Zentralität.....	17
Abbildung 4: Lern- und Prediktphasen eines neuronalen Netzes.....	32
Abbildung 5: Beispiel eines Confusion Matrix	35
Abbildung 6: Zwei Beispiele der Receiver Operating Characteristic.....	36
Abbildung 7:Beispiel der Best Validation Performance vs. Training State	37
Abbildung 8: Netzwerk Analyse des Hashtags #unfoundation	39
Abbildung 9: ROC Trainingsergebnis für BC2 (Hidden Layer 10, Bigram 2-3)	42
Abbildung 10: Beispielhaftes Ergebnis zu dem Test Tweet:.....	44
Abbildung 11: Twitter Advanced Search Maske.....	56
Abbildung 12: Apigee API Console, Selektion der Methode.....	57
Abbildung 13: Twitter Advanced Search (Suchbegriff).....	58
Abbildung 14: Apigee API Console (Ergebnisse eins Suchbegriffes)	58
Abbildung 15: Die MATLAB Entwicklungsumgebung.....	59

Tabellenverzeichnis

Tabelle 1: MLF Lernergebnisse für Betweenness Centrality	41
Tabelle 2: MLF Lernergebnisse für Positives Sentiment	42
Tabelle 3: MLF Lernergebnisse für Negatives Sentiment.....	43

Glossar

Ausdruck Bedeutung

<i>ANN</i>	Artificial Neural Network
<i>API</i>	Application Programming Interface
<i>BC</i>	Betweenness Centrality
<i>FPR</i>	False Positive Rate
<i>json</i>	JavaScript Object Notation
<i>MLF</i>	Multi-Layer Feed Forward Netzwerk
<i>REST</i>	Representational State Transfer
<i>ROC</i>	Receiver Operating Characteristic
<i>SM</i>	Social Media
<i>SN</i>	Social Networks / Soziale Netzwerke
<i>TPR</i>	True Positive Rate

1. Einleitung

Opinion Leader stellen eine aus vielerlei Hinsicht interessante Gruppe dar, da sie einen erheblichen Einfluss auf Bezugsgruppen ausüben können. Sie sind charakterisiert durch ein intensives Involvement und Wissen in ihrem Themengebiet. Sie pflegen Kontakte zu vielen Personen und nehmen einen hohen Status in dem Teilbereich der Gesellschaft ein, der sich auf ihr Thema konzentriert. Aus Gründen der Konnektivität verfügen sie üblicherweise über eine grössere Plattform als Nicht-Opinion Leader (Xu, Sang, Blasiola, & Park, 2014, S. 1280). Sie beeinflussen auf vielfältige Art und Weise, indem sie zum Beispiel als Rollenvorbilder handeln, Verhaltensveränderungen herbeiführen, Informationen weiterverbreiten und Rat erteilen (Reinecke Flynn, Goldsmith, & Eastman, 1996, S. 138; Valente & Pumpong, 2007, S. 881; Xu, Sang, Blasiola, & Park, 2014, S. 1280). Diese Funktionen verdichten sich in einer Definition, «Opinion leaders are people who influence the opinions, attitudes, beliefs, motivations, and behaviors of others» (Valente & Pumpong, 2007, S. 881).

Zahlreiche Opinion Leader werden darüber hinaus von Unternehmen angeworben, um spezifische Produkte und Dienste mittels den Sozialen Medien an vorbestimmte Zielgruppen zu vermarkten. Somit besteht von den Opinion Leadern selbst, wie auch von einem möglichen Auftraggeber, grosses Interesse darin, ihre Social Media Beiträge so zu gestalten, dass eine Intensivierung der Meinungsführerschaft hervorgeht. Diese Arbeit untersucht empirisch, Optimierungsmethoden für Meinungsführer auf der Micro Blogging-Plattform Twitter indem die Posts von Meinungsführern analysiert werden und die erkannten Muster simuliert werden.

1.1.Vorgehen

Unter Verwendung von statistischen und topologischen Daten aus sozialen Netzwerken (SN) wird ein für Opinion Leader repräsentatives Thema und für das Projekt geeignete Themendomäne ausgewählt. Aus diesen Daten lassen sich Meinungsführer identifizieren. Durch die Massendatensammlung und algorithmische Klassifizierung von den thematisierten Micro-Blogging-Beiträgen – von Meinungsführern und Nicht-Meinungsführern gleichermassen – erfolgt eine Identifikation von semantischen und topologischen Mustern. Die initiale Datenklassifizierung wird unterstützt durch Werkzeuge der Netzwerkanalyse, deren Ergebnisse mit Hilfe von Techniken der künstlichen Intelligenz (Deep Learning) Vorhersagen über die Effektivität der künftigen Beiträge von Meinungsführern und anderen beteiligten Nutzern in sozialen Netzwerken ermöglichen. Das endgültige Ziel ist es, Techniken zu ermitteln und zu bewerten, welche zu einer Optimierung von SN-Beiträge, gerichtet auf (gesteigerte) Social Media, Meinungsführerschaft führen könnten.

1.2.Grundansatz

Konkret werden Daten des Micro Blogging Sozial Netzwerks Twitter¹ verwendet, die Beziehungsinhalte wie Follower, Likes und Retweets sowie semantische Daten aus den Tweet-Texten und verwendeten Hash-Tags beinhalten und sich für diese Forschungszwecke eignen. Twitter eignet sich besonders für solche Analysen, da sich dort frei zugängliche Informationen verbreiten, wo sich Datennetze dank Zwischenreferenzen von Botschaften (Likes, Retweets), von Personen (Users und Followers) und durch Verwendung von Metadaten in den Botschaften (Hashtags, URLs) bilden. Durch diese Charakteristik kann das Netzwerk des «Folgens und gefolgt werden»

¹ Twitter: Ein Micro Blogging Soziales Netzwerk <https://twitter.com>

nachvollzogen werden (Bakshy, Hofman, Mason, & Watts, 2011, S. 2; Xu, Sang, Blasiola, & Park, 2014, S. 1281). Twitter-Nutzer posten Nachrichten sogenannte Tweets auf der Plattform, die bis zu 140 Charakter lang sind². Tweets können durch die Aktion des ‘Retweeten’ weitergeleitet werden. Das Prinzip des ‘Retweeten’ steht im Einklang mit der fundamentalen Vorstellung von Opinion Leadern, Einfluss zu verbreiten, sei dieser positiv, wie zum Beispiel durch liken eines Tweets oder negativ (Xu, Sang, Blasiola, & Park, 2014, S. 1281).

Erfolgsmuster lassen sich erkennen, indem mehrere mögliche Variationen eines Tweets in die erstellten neuronalen Netzwerke eingegeben werden und Klassifizierungswerte für positives und negatives Sentiment sowie für Betweenness Centrality für die jeweilige Version eines Tweets prognostiziert werden. Ein solches Verfahren kann für Politiker, Diplomaten, Markenbotschafter und viele weitere Personen des öffentlichen Lebens von Vorteil sein – entweder, um eine möglichst positive Wirkung auf Twitter zu erzielen, oder auch um in der Informationsweitergabe unbeabsichtigte, negative Eindrücke zu vermeiden. Erfolg äußert sich in möglichst vielen Likes und Retweets mit gleichzeitig möglichst wenigen negativen Auswirkungen, wie einer Verminderung der Vernetzung über einen Zeitraum (siehe 2.3.1) (Kwak, Lee, Park, & Moon , 2010; Cha, Haddadi, Benevenuto, & Gummadi, 2010; Bakshy, Hofman, Mason, & Watts, 2011). Dadurch werden Strategien zur Optimierung der Effektivität der Tweets von Opinion Leader ableitbar.

In dieser Arbeit wird die topologische Datenanalyse mittels Netzwerkanalyse im Vorfeld umgesetzt. Cluster im Netzwerk werden ermittelt und nach Relevanz beurteilt. Die gewonnenen Datenklassifizierungen werden dreigeteilt und weiterverwendet. Der überwiegende Teil an Klassifizierungsdaten wird als Trainings-Daten in ein künstliches,

² In September 2017 kündigte Twitter an, Botschaften mit 280 Zeichen zu erproben.

neuronales Netzwerk (Artificial Neural Network oder ANN) eingespeist um dieses zu trainieren (Kim, 2014, S. 1746; Sosa & Sadigh, 2016). Die klassifizierten Daten, welche nicht schon für das Trainieren eingesetzt wurden, werden einerseits für die Optimierung und andererseits für die Verifikation des ANNs verwendet. Schliesslich wird das neuronale Netz als Klassifizierungs- und Bewertungsinstrument für neue Tweets verwendet, ohne dass weitere Netzwerkanalysen benötigt werden. Es ist auch vorgesehen, dass zur Kontrolle der Erfolg von echten, neuen Tweets (von den in Frage kommenden Meinungsführern) vorhergesagt werden soll. Ein wichtiger Teil dieser Arbeit ist es, schliesslich ein optimiertes NN-System bereitzustellen, womit potentielle Twitter Daten analysiert werden können.

Meinungsführer, als die Verteiler und Beeinflusser von Informationen, sind die zu erstrebenden Ideale auf Sozialen Netzwerken wie Twitter. Wie Winter und Neubaum beschreiben, kann seine eigene Meinung über öffentliche Angelegenheiten öffentlich mittels SNS an eine Reihe von Freunden zu teilen, als Versuch Informationen zu teilen und andere von der eigenen Meinung zu überzeugen, interpretiert werden (Winter & Neubaum, 2016). Meinungsführer sind aus diesem Grund ideale Untersuchungsobjekte, um den Erfolg auf Twitter zu messen. Durch die Resultate des neuronalen Netzwerkes und dessen subsequente Anwendung können Tweets kreiert werden, die nach Qualitäten der Meinungsführerschaft optimiert werden.

2. Theoretischer Hintergrund

In den folgenden Abschnitten werden zentrale Konzepte und Modelle erklärt, sowohl in den Bereichen des Opinion Leaderships, der Sozialen Netzwerke, der Netzwerkanalyse, wie auch in dem Themengebiet der neuronalen Netze.

2.1.Opinion Leadership

Die Annahme, dass Individuen andere Menschen beeinflussen können, wurde als erstes von Lazarsfeld, Berelson und Gaudet im Jahr 1944 in ihrer Studie «People's Choice» formuliert. Dort wird die Hypothese aufgestellt, dass der persönliche Einfluss auf das Wahlverhalten, der von Personen aus dem näheren Umfeld wie aus der Familie ausgeht, stärker ist, als jener, den die Massenmedien ausüben. Opinion Leader gelten als Vorbilder und können aus diesem Grund einen hohen Einfluss auf andere Individuen innerhalb ihrer sozialen Netzwerke ausüben (Lazarsfeld, Berelson, & Gaudet, 1944). Lazarsfeld und sein Team stellten bei ihrer Analyse der US-Amerikanischen Präsidentschaftswahlverhalten von 1940 fest, dass sich Opinion Leader – in Gegensatz zu ihren Mitwählern – stärker in die politische Diskussion einbrachten. Traditionelle Medien waren zudem effektiver bei Opinion Leaders als Quelle der Information im Vergleich zu persönlichen Beziehungen im Formulieren ihrer Meinungen (Lazarsfeld, Berelson, & Gaudet, 1944, S. 14). Stehr et al. erklären daher, dass das Phänomen der Opinion Leader als fehlendes Glied zur Erklärung von Information und Persuasion gesehen werden kann, und nicht der traditionellen Medienberichterstattung zuzuschreiben ist. Aus diesem Grund kommen die Autoren zum Schluss: “it is assumed that interpersonal communication with opinion leaders is an alternative channel of influence that may interact with mass media communication” (Stehr, Rössler, Leissner, & Schönhardt, 2015, S. 983).

Der Einfluss von Person-zu-Person erreichte diejenigen Wähler eher, die anfälliger für Meinungsänderungen waren. Somit ist die interpersönliche Überzeugungskraft die Brücke, über welche die traditionellen Medien ihren Einfluss erweitern können. Persönliche Beziehungen haben ebenfalls psychologische Effekte, wie zum Beispiel den Druck der ausgeübt wird und schlussendlich zu einer politischen Homogenität sozialer

Gruppen führt (Lazarsfeld, Berelson, & Gaudet, 1944, S. 14). Die psychologischen Effekte werden in dieser Arbeit allerdings nicht weiter beachtet.

Gemäss Katz gibt es drei Funktionen, welche den Opinion Leader ausmachen und ihn von der Gruppe unterscheiden. Der Einfluss ist bezogen auf (a) die Personifikation von Werten («who one is»), (b) die Kompetenz oder Expertise («what one knows») und (c) die soziale Position («who one knows»), welche eine Person, die in der Gruppe bekannt ist, von der Aussenwelt unterscheidet (Katz, 1957, S. 73). Katz berichtet von der Studie Rovere, einer Studie basierend auf «People's Choice», welche von lokalen Beeinflussern berichtet dessen Führung auf ihre zentrale Position in einem Netzwerk von persönlichen Beziehungen zurückzuführen ist. Die Erkenntnis, dass die Position relativ im Netzwerk von Bedeutung ist, wird weiterhin für die Arbeit bei der Analyse von Sozialen Netzwerk Topologien relevant sein (siehe Abschnitt 2.3.1).

Die fundamentalen Grundsätze der Theorien rund um Opinion Leadership gehen davon aus, dass einzelne Personen einen höheren Einfluss ausüben, als die traditionellen Massenmedien wie Zeitung, Radio und Fernsehen. In Zeiten der Sozialen Netzwerke, in der einflussreiche und beeinflussbare Individuen in neuen Formen der Medien «unterwegs» sind, hat sich diese Machtdynamik verändert (Xu, Sang, Blasiola, & Park, 2014, S. 1280).

Sofern ein Opinion Leader in Social Media präsent ist, eröffnen sich Wege, die Bekanntheit und den Einfluss zu multiplizieren. Es ist jedoch klar, dass die Twitterer schon eine gewisse Anzahl an Follower aus dem «realen» Leben mitbringen und den Einfluss den diese Twitterer innehaben, nicht (nur) aufgrund ihrer Tweets geschieht, sondern (eher) aufgrund von äusseren Einflüssen erfolgt (Cha, Haddadi, Benevenuto, & Gummadi, 2010).

2.2.Sentiment

Eine der Effekte des globalen Nutzens von Social Media ist die weitläufige Verbreitung und Verfügbarkeit von Daten. Die Konsequenz daraus ist «social media mining». Die Sentiment-Analyse ist eine Form der Analyse von Daten auf SNS und ist das rechnerische Verfahren um Stimmungen, Meinungen und Subjektivität von Texten auf Social Media Plattformen über ein Thema zu bestimmen und so zu einem Mass der generellen Stimmung zu kommen (Kennedy, 2012, p. 435; Pang & Lee, 2008). Die Sentiment-Analyse wird häufig auch mit Opinion Mining gleichgesetzt. Opinion Leader selber sind die einflussreichsten Knoten in einem Netzwerk und erfassen, wie das Team um Song herausgefunden hat, die am meisten repräsentativen Meinungen eines Netzwerkes (Song, Chi, Hino, & Tseng , 2007, p. 974). Ein Ereignis, das wichtig genug ist, um eine Reaktion auf Twitter auszulösen, ist so gut wie immer mit einer emotionalen Reaktion verbunden. Thelwall berichtet ebenfalls, dass Tweets mit negativ geladenen Nachrichten auf Twitter vorherrschend sind (Thelwall, Buckley, & Paltoglou, 2011). Ma und sein Team haben für ihre Arbeit in der Vorhersage der Popularität von Hash-Tags auf Twitter aus Thelwalls Erkenntnissen geschlossen, dass die Sentiment-Analyse von Hash-Tags ein möglicher Indikator dessen Verbreitung ist (Ma, Sun, & Cong, 2013).

2.3.Soziale Netzwerke

Twitter ist eine Micro-Blogging Plattform, bei dem sich Nutzer über jedes Thema mittels Tweet austauschen können, solange das maximale Limit von 140/280 Charaktere je Botschaft nicht überschritten wird. Nutzer können einander folgen und Nachrichten des anderen per Push-Verfahren mitgeteilt bekommen. Bei Twitter gibt es, im Vergleich zu anderen sozialen Netzwerken wie Facebook oder LinkedIn, keine Abhängigkeitsbedingung in der Beziehung zwischen «Followee» und «Follower». Ein

Nutzer kann einem anderen folgen, ohne von diesem gefolgt werden zu müssen. Durch die Aktion des Retweetens kann die Nachricht eines Nutzers ausserhalb des Urhebers eigenen Netzwerkes weiterverbreitet werden (Kwak, Lee, Park, & Moon , 2010, S. 1; Ma, Sun, & Cong, 2013, S. 1399; Xu, Sang, Blasiola, & Park, 2014, S. 1281; Zubiaga, Spina, Martínez, & Fresno, 2015; Tumasjan, Sprenger, Sandner, & Welpe , 2010). Hash-Tags sind Mittel, um einen Kontext für ein spezifisches, neues Thema oder Event zu geben (Ma, Sun, & Cong, 2013, S. 1399).

Verschiedene Studien zeigten, dass Twitter ein Kommunikationsmittel ist, das von sowohl Aktivisten als auch von der allgemeinen Gesellschaft, die nicht politisch unterwegs ist, genutzt wird, um Nachrichten und Meinungen zu verbreiten (daher «viral gehen zu lassen»), Menschen zu mobilisieren und ihre Aufmerksamkeit auf relevante Themen zu lenken (Jungherr, 2014, S. 242). Nachrichten auf Twitter gehen über die neutrale, nicht emotional besetzte Informationsweitergabe hinaus und stellen eine grosse Spannbreite an öffentlichen Meinungen her, wobei sie nicht nur Fakten aufzeigen, sondern auch Meinungen, Kommentare, Witze und Spekulationen wiedergeben. Kwak und sein Team fanden, dass die Twitter Nutzer viele Links zu traditionellen Medien in ihren Tweets einbeziehen. Sie schlussfolgern daraus, dass zumindest ein Teil der politischen Diskussionen auf Twitter aus der Reaktion auf traditionelle Nachrichtenberichterstattung entsteht (Kwak, Lee, Park, & Moon , 2010). Tweets haben ebenfalls die Eigenschaft, lokale Informationen zu verbreiten. Als Resultat dieser Eigenschaften verändert Twitter fundamental die Grundstrukturen der Gesellschaft, da die Berichterstattung von Events auf subjektiven Erfahrungen, Meinungen und Emotionen basiert (Jungherr, 2014, S. 242; O’Leary, 2015, S. 227). Tumasjan et al. deuten an, dass politische Aktivitäten auf Twitter die generelle politische Landschaft

besser reflektieren als dies traditionelle Medien tun (Tumasjan, Sprenger, Sandner, & Welpe , 2010).

Netzwerkstrukturanalysen³ zeigen, dass alle Gruppierungen auf Social Media deutlich ausgeprägte Strukturen von Einfluss und Verbindung besitzen. Opinion Leader halten dabei strategische Positionen in diesen Netzwerken inne. Smith et al. unterscheiden zwischen «hubs» und «bridges». «Hubs» sind wichtige Personen, die sich im Zentrum einer Gruppierung befinden, aus denen Nachrichten verbreitet werden. Ihre Follower retweeten (d.h. senden per Tweet weiter), was diese als Originalbotschaft getweetet haben. Die andere Art von Opinion Leaders sind «bridges», die zwischen zwei Gruppierungen stehen. Sie spielen insofern eine wichtige Vermittlerrolle, weil sie Informationen zwischen unterschiedlichen und getrennten Gruppierungen (z.B. unterschiedlichen Sprachgemeinden) verbreiten. Oft spielen sie eine katalytische Rolle, wenn eine Nachricht «viral geht» (Smith, Rainie, Shneiderman, & Himelboim, 2014, S. 7).

Durch eine Analyse der Merkmale von Tweets, können je nachdem, welche Semantik, Hash-Tags und Referenzen verwendet wurden Aussagen über die Effekte von Tweets auf Follower und andere Vorhersagen abgeleitet werden. Die Effekte des Erfolgs drücken sich durch die Anzahl Followers, Retweets und Likes aus, woraus Netzwerkmetriken errechnet werden können. Diese Metriken und die angewendeten Techniken ihrer Ermittlung, sind beschrieben in Abschnitt 2.3.1. Die Ableitungen von Aussagen, Vorhersagen und Meinungsströmungen aus Massendaten von Twitter, werden unter dem Begriff «Twitter Mining» zusammengefasst (O’Leary, 2015, S. 230).

³ Siehe Absatz 2.4 für eine Behandlung der Techniken der Netzwerkanalyse

Ein bedeutender Aspekt von Twitter Mining ist die Erkennung von Informationen bezogen auf Inhalte von Tweets, zum Beispiel durch eine Sentiment-Analyse, mit der eine negative, positive oder neutrale Emotionalität in den Tweets dargestellt werden kann. Eine Sentiment-Analyse erfolgt typischerweise durch eine wörterbuchgeleitete Analyse (Zählung) von allgemein anerkannten Gruppen von «key words», wobei angenommen wird, dass bestimmte Wörtermengen eine spezifische Konnotation mit sich ziehen. Durch die Limitierung von Charakteren bei Tweets, werden jedoch häufig Abkürzungen, Emoticons aber auch ausgedehnte Wörter (beispielsweise ‘cooool’ anstelle von ‘cool’) verwendet (O’Leary, 2015, S. 234). Auf Grund der einschränkenden Ausdrucksweise bei der rein wörterbuchgeleiteten Analyse, wird bei der Sentiment-Analyse ein anderer Ansatz in diesem Projekt gewählt, nämlich der Einsatz von Machine-Learning und neuronalen Netzwerken (s. Absatz 3.8, wie dies z.B. auch von Sosa und Sadigh erfolgreich angewendet wurde (Sosa & Sadigh, 2016, S. 11). Die These dabei ist, dass die Ausdrucksweise, die sozialen Netzwerken eigen ist, dadurch besser berücksichtigt werden kann. Die Sprache ist ein Kriterium, das einen Einfluss auf die Bewertung der Netzwerkmitglieder hat, ob jemand bereits ein Meinungsführer ist oder nicht. Trepte und Scherer fanden in ihren Studien, dass Opinion Leader keineswegs mehr wissend sein müssen. Sie können sich auch mehr auf ihre kommunikativen Fähigkeiten stützen. Einen kommunikativ interessanten Inhalt zu bieten, führt zu einer höheren Wahrscheinlichkeit, dass Inhalte von der Domäne eines Meinungsführers einfacher erreicht werden können, und dass Twitter-Nutzer es relevant finden, ihre Meinung zu dem Thema zu posten (Trepte & Scherer, 2010, S. 120). Durch das Referenzieren von Tweets entstehen Netzwerke, welche in den nächsten Abschnitten in einer detaillierteren Tiefe behandelt werden.

2.3.1. Soziale Netzwerk Topologien

Die Netzwerkbildung in Twitter nimmt verschiedene Formen an. Für die Arbeit wird ein Netzwerkmuster anhand einer Themendomäne ausgewählt, in welche die zu untersuchenden Meinungsführer deutlich erkennbar sind. Eine empirische Analyse von mehreren tausend Twitter „Crowds“ hat die Identifikation von sechs sozialen Netzwerkarchetypen ermittelt (Smith, Rainie, Shneiderman, & Himelboim, 2014, S. 2).

Die sechs Archetypen sind:

- a) **Polarized Crowd:** Es bilden sich mindestens zwei dichte Gruppen, die wenig Interaktion miteinander haben. Dieses Muster wird häufig bei politischen Inhalten vorgefunden.
- b) **Tight Crowd:** Ein Gegensatz zum Polarized Crowd, wo sich zwar multiple Gruppen bilden, diese aber dennoch stark mit anderen Gruppen kommunizieren. Mitglieder sind wegen den engen Bindungen untereinander bekannt.
- c) **Brand Clusters:** Hier werden viele Inseln gebildet, die kaum Interkonnektivität besitzen. Man kennt sich scheinbar nicht und interessiert sich praktisch zufällig für das gleiche Thema. Brand Clusters formieren sich um Themen, die einen weiten Bekanntheitsgrad besitzen.
- d) **Community Clusters:** Eine Sammlung von mehreren mittelgrossen Untergruppen bildet sich, deren Mitglieder innerhalb der Untergruppe gut miteinander vernetzt sind. Ein Hauptthema ist in mehrere Subthemenbereiche geteilt, die sich jeweils wenig mit den anderen Subthemeninteressierten austauschen.
- e) **Broadcast Network:** Eine starke Rad-und-Naben Struktur wird gebildet. Typisch ist dies bei Medienfirmen oder prominenten Medienvertretern (positioniert im Zentrum), dessen Botschaften von den Umgebenen weiter verteilt werden.

f) **Support Network:** Grosse Firmen betreiben eine enge Kundenbindung auf Twitter, um Unterstützung anzubieten und Kundeninteresse zu pflegen. Ähnlich wie die Broadcast Network tauschen die „Anhänger“ sich wenig miteinander aus – kommunizieren aber aktiv mit der zentralen Figur.

Die graphischen Darstellungen der Konversationstypen sind in Abbildung 1 ersichtlich.

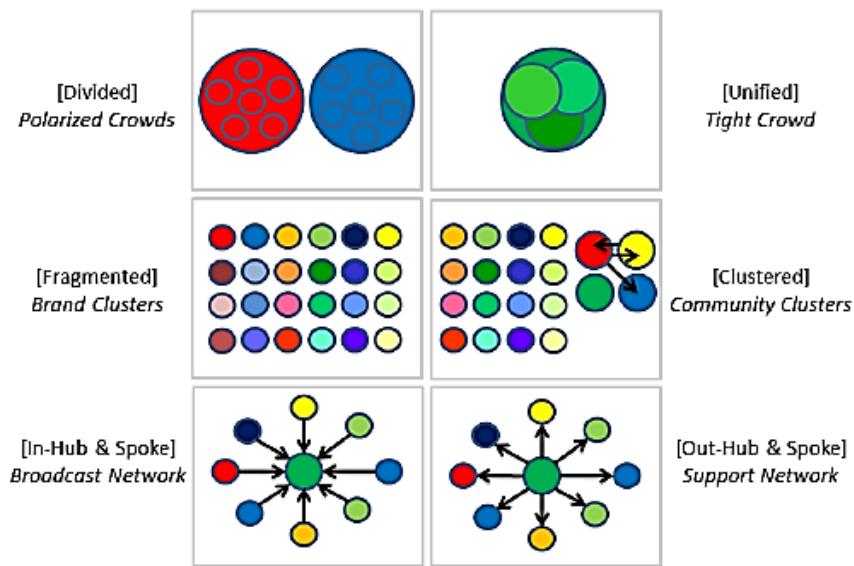


Abbildung 1 Media Netzwerk Archetypen (Quelle: Smith, et al., 2009)

2.4. Netzwerkanalyse

Netzwerke sind aus Knoten aufgebaut, die über Kanten miteinander verbunden sind. Die Knoten, in der realen, soziologischen Welt, können Individuen, Organisationen, Nationen oder weitere logische bzw. technische Instanzen repräsentieren. Die Kanten bilden die Relationen (z.B. Freundschaft, Kontrolle, Informationsaustausch, Zitierungen, usw.) zwischen den Knoten ab. Verbindungen können gerichtet (von - nach) oder ungerichtet (bidirektional) sein. Knoten verbunden durch unterschiedliche Relationstypen bilden einen «Multigraph». Graphen, die zwei oder mehr Knotentypen

abbilden werden als «bipartite» respektive, «n-mode Graphen» bezeichnet (Krempel, 2016, S. 3-4). Durch Visualisierung von Netzwerken, können Topologien, Muster und Strukturen entdeckt werden, die zum Beispiel in einem Sozialen Netzwerk zur Erkennung gängiger Archetypen führen können (siehe 2.3.1).

Als Ziel der sozialen Netzwerkanalyse sieht Häussling die Verbindung von der Mikroebene der einzelnen Rezipienten, der Mesoebene (wo sich Rezipienten zu sozialen Gruppen zusammenschliessen) und der Makroebene, worin die sozialen Gruppenstrukturen der Gesellschaft eingebettet sind (Häussling, 2008, S. 76). Die Netzwerkanalyse, die bei verschiedenen Arten von Netzwerken verwendet werden kann, wird hier angewendet, um Einblick in einen Teil des sozialen Netzwerkes Twitter zu gewinnen (Easley & Kleinberg, 2010, S. 8; Xu, Sang, Blasiola, & Park, 2014, S. 1282) und um daraus SN-Daten zu klassifizieren. Der strukturelle Aspekt der Meinungsführerschaft geht davon aus, dass Meinungsführer eine zentrale Rolle in der Struktur eines Netzwerkes inhalten, wobei sie mit vielen weiteren Mitgliedern des Netzwerkes verbunden sind. Der einfache Zentralitätsgrad⁴ der Meinungsführer in dem Netzwerk ist nicht unbedingt ausschlaggebend, da Meinungsführer einerseits in der Mitte eines Netzwerkes sein können, aber auch als wichtige Brücke zwischen zwei Teilnetzwerken fungieren können (siehe 2.3) (Smith, Rainie, Shneiderman, & Himelboim, 2014; Valente & Pumpuang, 2007).

Die soziale Netzwerkanalyse visualisiert Muster anhand der veröffentlichten Nachrichten (Micro-Blogs), womit in der Folge Beziehungen zwischen Menschen oder Gruppen von Menschen (Organisationen) analysiert werden können. Das Soziale Netzwerk von Twitter entspricht einem gerichteten n-Mode Graphen, wobei die «Nodes»

⁴ Zentralitätsgrad (oder «Degree Centrality») ist ein Mass der Anzahl der unmittelbaren Nachbarn eines Knotens im Graphen. Siehe 2.4.1 für weitere Metriken wichtig für Meinungsführerschaft.

(Knoten) Menschen, Organisationen und Hashtags, und «edges» (Kanten) die Interaktion oder Beziehung (Likes, Following) zwischen ihnen repräsentieren (Easley & Kleinberg, 2010, S. 24; Smith, et al., 2009, p. 2). Bei dieser Analyse wird davon ausgegangen, dass der Einfluss von Massenkommunikation ebenfalls einen Einfluss auf die Ausdehnung von sozialen Netzwerken hat (Bonfadelli, Friemel, & Wirth, 2010, S. 643).

2.4.1. Netzwerkmetriken

Die Diffusion von Information geschieht sowohl direkt als auch indirekt. In Zeiten der reinen Mund-zu-Mund Propaganda war dieser Prozess sehr schwierig zu beobachten und somit nicht adäquat messbar. Mit sozialen Netzwerken ist die direkte Informationsweitergabe mit den unmittelbaren Nachbarn im Netz leicht erkennbar. Es ist aber auch die weite Informationsdiffusion an topologisch entfernten Netzwerkeinheiten durch erweiterte Netzwerkanalysen zu erkennen und sogar numerisch exakt zu quantifizieren.

Numerisch ausgedrückt werden Netzwerkmetriken wie „Centralities“ verwendet, um nicht nur die Stärke von direkten Verbindungen der Knoten auszudrücken, sondern auch um die indirekten Verbindungen und damit den globalen Effekt auf das Netzwerk zu beurteilen: „This shifts the focus of the analysis from bilateral action to a system perspective“ (Krempel, 2016, S. 9) .

Im Falle von Twitter bilden die Twitter-User, Tweets oder Hash-Tags die Knoten, wobei die Kanten durch Followership, Retweeting, Hash-Tag-Einbettung und Likes, die Relationen zwischen den Knoten herstellen. Opinion Leader sind in diesem Kontext User, welche eine zentrale Position in einem Netzwerk sozialer Interaktion inne haben (Smith, Rainie, Shneiderman, & Himelboim, 2014). Wie auch schon Freeman im Jahre 1979 ermittelt hat, ist die Zentralität einer Organisation stark abhängig von zum einen den

Charakteristiken der Organisation und zum anderen von den Eigenschaften des Netzwerkes (Freeman, 1979, S. 216).

2.4.2.Centralities

Die Zentralität (Centrality) eines Knoten drückt die Wichtigkeit oder den Einfluss im Netzwerk des Knotens aus. Die Zentralität als Messwert kann Aussagen liefern, zum Beispiel, ob eine Strasse viel benutzt wird, wie wichtig ein Web-Page ist oder wie einflussreich eine Person in einem Netzwerk ist (siehe Konzept des Opinion Leader 2.1).

Vier Hauptarten von Zentralitäten werden hier verglichen. 1) Degree Centrality 2) Closeness Centrality 3) Eigenvector Centrality und 4) Betweenness Centrality. Degree Centrality (Zentralitätsgrad) ist einfach zu ermitteln, es werden lediglich die Anzahl der unmittelbaren Nachbarknoten gezählt. Diese Zahl kann wahlweise normalisiert werden, indem jede ermittelte Zentralität durch den maximalen Grad dividiert wird. Jeder Knoten erhält somit einen Zentralitätsgrad von maximal 1,0. Closeness Centrality misst die relative Dauer für die Diffusion von Information von einem Knoten zu allen im Netz verfügbaren Knoten. Closeness Centrality wird wie Degree Centrality auch meist normalisiert.

Eigenvector Centrality misst den Knoteneinfluss durch eine Vergabe von Punkten zu allen Knoten, wobei Verbindungen zu anderen Knoten aufgewertet werden, abhängig von deren Wichtigkeit (bemessen ebenfalls durch zugeteilte Punkte). Eigenvector Centrality wird z.B. als Basis für den Google PageRank⁵ Algorithmus verwendet.

⁵ Der Suchdienst Google liefert Ergebnisse sortiert nach dem sog. PageRank an den Anwender zurück.

Betweenness Centrality quantifiziert die Bedeutung eines Knotens an der Kommunikation zweier sonstigen Netzketten. Ein einfaches Beispiel verdeutlicht die Berechnungsmethode:

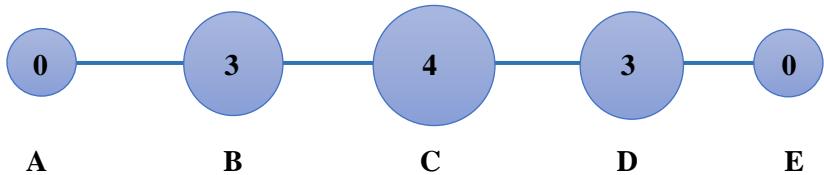


Abbildung 2: Betweenness Centralities eines einfachen Netzes

Knoten A liegt zwischen keinem weiteren Knoten und hat eine Betweenness Centrality von Null. Knoten B liegt zwischen 3 Knotenpaaren (AC, AD und AE). Knoten C liegt zwischen 4 Knotenpaaren (AD, AE, BD und BE). Betweenness Centrality kann, wie Freeman bereits 1979 definiert hat, als Index gesehen werden für das Potenzial eines Knotens die Kommunikation in einem Netzwerk zu kontrollieren (Freeman, 1979, S. 224). Aufgrund dieser Definition wird Betweenness Centrality als bedeutendster Massstab für Opinion Leadership in der sozialen Netzwerkanalyse betrachtet und in diesem Projekt extensiv als empirisches Mass der Meinungsführerschaft in Twitter-Netzwerken verwendet.

In Abbildung 3 wird zur Verdeutlichung der Unterschiede der jeweiligen Zentralitätsmetriken ein kleines Netzwerk 4-mal abgebildet. Die Zentralitätsgrösse für die Knoten ist jeweils proportional zur Knotengrösse. Somit erkennt man die zu erwartende Distribution des Einflusses von jedem Teilnehmer im Netzwerk aus topologischer Sicht. Bei der Betweenness Centrality haben die Akteure am Rand (hier: C, E, J) keinen Einfluss. Punkt H hat bei diesem Mass, aufgrund der Position im Netz, am meisten Einfluss, obwohl H nicht die meisten direkten Nachbarn im Graphen besitzt, besitzt der Punkt nicht den höchsten Degree Centrality. Je nach Auswahl des Zentralitätsgrades ist die Berechnung anders und es werden unterschiedliche

Konklusionen getroffen, welcher relative Konten im Netz der wichtigste ist. Für das Thema des Meinungsführers in dieser Arbeit ist die Betweenness Centrality am besten geeignet.

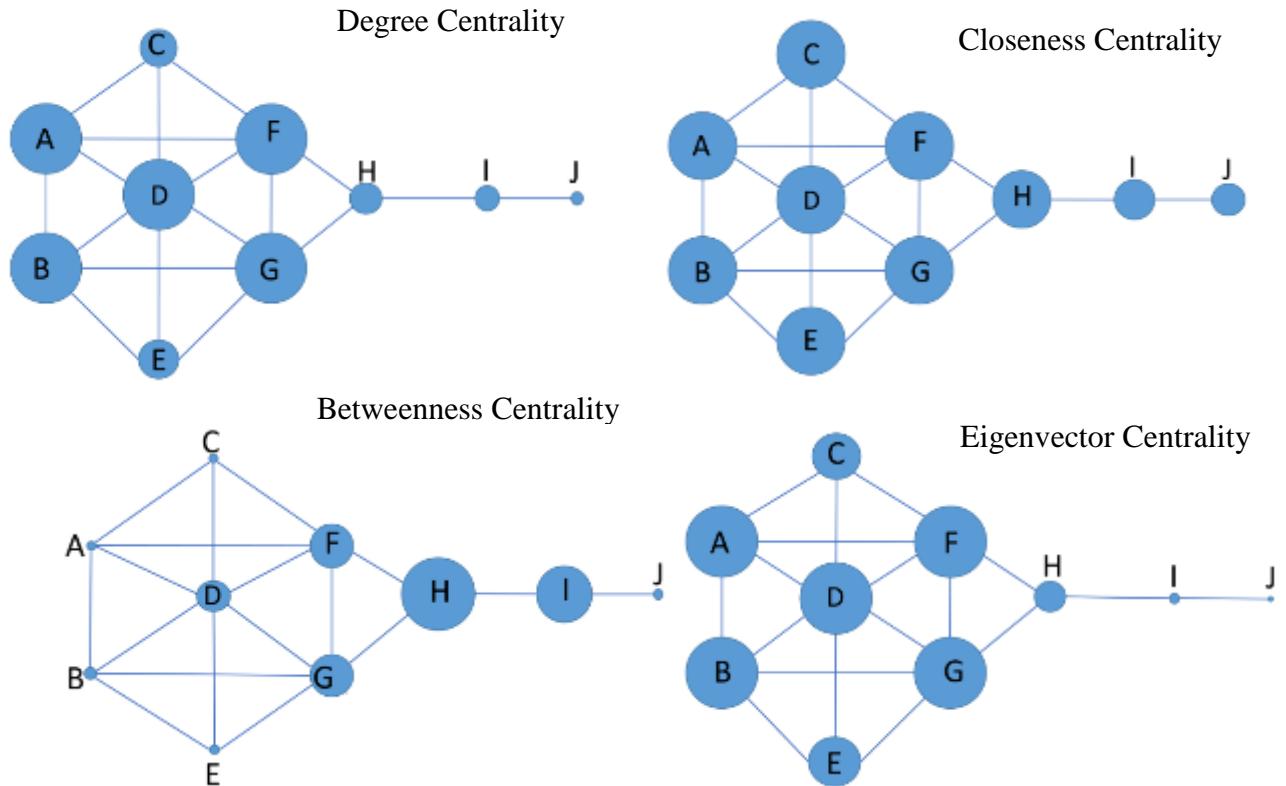


Abbildung 3 Vergleiche der vier Typen von Zentralität
Quelle: (Krempel, 2016)

2.5. Artificial Neuronale Netze (ANNs)

Die Funktionen der Klassifizierung, Anpassung und Vorhersage von Meinungsführer-Daten aus dem Sozialen Netzwerk Twitter sind für die Analyse der Rolle der Opinion Leader relevant. Künstliche neuronale Netze (ANNs) sind Softwaremodelle, welche auf der Wirkungsweise von biologischen Gehirnen basieren. Ein solches System soll Muster erlernen und erkennen können unter der Verwendung von in Relation zu einander stehenden Neuronen. ANNs sind geeignet um ein breites Spektrum an

Problemen zu lösen, die durch andere Mittel kaum (oder nur mit immenser konzeptioneller Arbeit) zu bewältigen wären. Sie bieten darüber hinaus weitreichende Möglichkeiten Probleme der Klassifizierung autonom zu absolvieren und bestehen zwar aus einfachen Neuronen, die allerdings in einem grossen Netzwerk angeordnet werden. Bei der Mustererkennung wird, so wie sie in dieser Arbeit verwendet wird, versucht, Eingangsdaten zu einer von vielen Sentiment- und Zentralitäts-Werteklassen zuzuteilen. Bei der Funktionsapproximation nähert das System eine zugrundeliegende Funktion an, die zu dem gegebenen Zielmuster passt. Weitere Aufgaben, die mit ANNs behandelt werden, sind Datenvorhersagen und Optimierungsprobleme.

Wie Zhu erwähnt, gibt es zurzeit zwei Formen der Vorhersage bei neuralen Netzwerken, «trend prediction», also die Vorhersage von Trends, (zum Beispiel beim Aktienkurs oder bei der Vorhersage von «viralen» Hash-Tags), über einen bestimmten Zeitraum, und «regression based on causality prediction», womit die Verwendung von multiplen Regressionen gemeint ist (Zhu, 2017, S. 4-5).

Ein wichtiger Teil dieser Arbeit besteht darin, das beste neuronale Netz zu ermitteln, um eine sinnvolle Zuordnung von potentiellen Tweets einem Sozialen Netzwerk im Voraus zu schätzen. Die prädiktiven und klassifizierenden Eigenschaften von künstlichen neuronalen Netzwerken (Artificial Neural Networks, ANNs) werden zu diesem Zweck eingesetzt.

Es existieren verschiedene Arten von neuronalen Netzwerken, wichtig darunter ist für diese Arbeit das Multi-Layer Feed-Forward Netzwerk (MLF). Ein MLF bezeichnet ein neuronales Netz, in dem die Input-Output Relationen durch Anpassen der Gewichte, welche die Neuronen verbinden, verändert werden können. Das MLF besteht aus verschiedenen Lagen. Die erste davon wird als Input-Lage bezeichnet, die letzte Lage ist die Output-Lage und alle dazwischenliegenden sind die «Hidden-Layers». In jeder Lage

befinden sich Neuronen, wobei jedes einzelne Neuron einer Lage mit allen anderen Neuronen der darüberliegenden Lage verbunden ist. Die Relationen zwischen den Neuronen werden mit Gewichten beeinflusst. Der Gewichtskoeffizient widerspiegelt den Grad der Bedeutung dieser Relationen in einem neuronalen Netzwerk. In dem Training des MLF werden als erstes die Gewichte randomisiert ausgewählt. In jeder Epoche, (daher die Iteration eines Gesamtdurchlaufs des Trainings-Datensatzes), werden die Gewichte zwischen den Neuronen angepasst, so dass die Fehler zwischen den Input- und Output-Werten minimiert werden. So werden durch mehrere Durchläufe die optimalsten Output-Werte erlangt (Svozil, Kvasnicka, & Pospichal, 1997; Biganzoli , Boracchi , Mariani, & Marubini, 1998).

Ein häufiges Problem beim MLF ist «overfitting». Dies geschieht, wenn das neuronale Netz geringe Fehler bei dem Trainings-Datensatz, jedoch grosse Fehler bei einem neuen Datensatz aufweist. Das neuronale Netzwerk hat den Trainings-Datensatz gelernt, hat jedoch nicht gelernt neue Daten zu generalisieren. Um «overfitting» zu vermeiden, wird der gesamte Datensatz in Tranchen aufgeteilt und zur Validation und zum Training genutzt. Das Training wird terminiert, wenn die Fehlerrate bei der Validation eine definierte Grenze übersteigt, oder aber eine Maximalanzahl Iterationen erreicht ist.

Die Ergebnisse von Kim (2014, S. 1750) zeigen positive Vorteile von MLFs in Aufgaben, die Klassifizierung auf der Satz-Ebene benötigen. Diese Aufgabenstellung ist zentral für die Analyse von Tweets, und wurde von Sosa und Sadigh in ihrer Forschung von der Sentiment-Analyse von Tweets entsprechend belegt (Sosa & Sadigh, 2016, S. 10).

2.5.1. Wort Repräsentationen als Vektoren

Da neuronale Netze zwingend numerische Eingangsdaten benötigen, müssen alle zu verwendenden Texte aus den Tweets in geeigneter Art und Weise aufbereitet werden. Obwohl mehrere Ansätze für diese Art von Datenaufbereitung existieren (Bag of Words, Dimension Reduction, Hash-Encoding etc.), empfiehlt die aktuelle Forschung überwiegend semantische Vektorraummodelle, um Wörter zu repräsentieren (Pennington, Socher, & Manning, 2014, S. 1532; Goikoetxea, Agirre, & Soroa, 2016, S. 2608). Ein statistisches Verfahren, bekannt als Word Embeddings, trainiert ein neuronales Netz aus einer Korpora von – im Idealfall, Millionen von – textuellen Artikeln, um jedes Wort aus der Textkorpora als einen Realnummern-Vektor mit vielen Dimension (erfolgreiche Versuche verwenden Dimensionen im Bereich von 50, 200 bis 300) zu repräsentieren.

Word Embeddings haben für diese Forschungszwecke eine Reihe von Vorteilen. Erstens existieren mehrere bereits antrainierte Word Embeddings, die aus einer immensen Menge an Daten (z.B. die komplette Wikipedia Texte oder Google News Artikel von mehreren Jahren) errechnet wurden und für Forschungszwecke frei zugänglich sind. Die Erstellung von eigenen Word Embeddings in dieser Grösse würde mehrere Wochen Rechenarbeit in Anspruch nehmen. Zweitens, ist es möglich, eigene Word Embeddings aus Texten, die keine gängigen Vokabeln besitzen (z.B. coool und andere Wörter in spezieller Schreibweise die eigen von SNS wie Twitter sind), selbst anzutrainieren und mit geeigneten Techniken in Kombination mit anderen (vorgefertigten) Word Embeddings gemeinsam zu verwenden (Goikoetxea, Agirre, & Soroa, 2016, S. 2613).

Schliesslich ist anzumerken, dass bei Wort-Vektorisierung, die Ursprungssprache der Wörter – sofern die Training-Daten in den verschiedenen Sprachen in ausreichenden Mengen vorhanden sind – nicht mehr ausschlaggebend ist, und dass die Verwendung von

multiplen Sprachen in Word Embeddings sogar vorteilhaft ist. Eine Eigenschaft, die von Faruqui und Dyer demonstriert wurde (Faruqui & Dyer, 2014).

2.5.2. N-Grams

Texte (beispielsweise von Tweets) können in mehrere Einheiten unterteilt werden. Eine solche Einheit wird als n-Gram bezeichnet und kann ein einzelnes Zeichen sein oder ein Wort, wobei ein Wort definiert wird, als eine Zeichenfolge separiert von anderen Zeichen durch eine Leerstelle. Ein Unigram (ein einzelnes Wort) ist das kleinste n-Gram. Bigrams bestehen aus zwei Unigrams, Trigrams aus drei Unigrams etc. Obwohl viel erreicht werden kann mit der Textanalyse auf Unigram-Basis, soll vermerkt werden, dass erst durch Multigrams Aspekte der Wortreihenfolge und damit der Kontext berücksichtigt werden kann (Vergeest, 2014, S. 23). Die Leistung eines Erkennungssystems kann – in Abhängigkeit von den involvierten Textarten und vor allem der Menge an Daten zum Trainieren des neuronalen Netzes – durch die Verwendung von Multigrams modifiziert werden. Vergeest ermittelte statistische Vorteile bei Charakter Trigrams und bei Wort Unigrams (Vergeest, 2014, S. 53).

2.5.3. Trainieren von neuronalen Netzen

Um ein neuronales Netz zu erhalten, welches die oben erwähnten Eigenschaften zur Klassifizierung erfüllt, wird das Netz mit einer grossen Menge von relevanten Daten gespeist, wobei für jeden Datensatz die erwartete Klassifizierung bekannt (daher ob der Tweet von einem Opinion Leader ist oder nicht) ist. Ein iterativer Lernprozess erfolgt, wenn bei sogenannten «Supervised Learning» die initialen Ausgabewerte mit der erwarteten Klassifizierung verglichen werden. Die Differenz wird errechnet und per «Back Propagation» zurückgeführt, um die Gewichtung der Neuronen zu modifizieren und so die richtigen Ausgabewerte zu erhalten. Die gleichen Daten dürfen und werden

i.d.R. mehrfach in mehreren «Epochen» zum Trainieren verwendet. Ein Teil der verfügbaren (klassifizierten) Daten werden zurückgehalten und nur verwendet, um die Qualität des resultierenden neuronalen Netzes zu messen (Svozil, Kvasnicka, & Pospichal, 1997, S. 48).

Sofern keine vorbestimmten Zielwerte für den Datenkorpus vorliegen, können neuronale Netze ebenfalls im «unsupervised» Lernverfahren trainiert werden. Das Verfahren eignet sich beispielsweise, um Clusteranalysen durchzuführen oder unbekannte Datenmuster zu erkennen (Herrero, Valencia, & Dopazo, 2001, S. 127) und wird auch verwendet, um die Word Embeddings (siehe 2.5.1) zu erstellen.

2.6. Forschungsfrage

Aus der vorangehenden Analyse des Forschungsstandes lässt sich für die Arbeit folgende Forschungsfrage formulieren:

Wie kann man die Informationen (Semantik, Topologie, enthaltenes Sentiment), die im Sozialen Netzwerk von Opinion Leadern beinhaltet sind, nutzen, um Meinungsführerschaft in neuen Twitter-Posts zu optimieren?

3. Konzeption und Methode

Um eine Analyse der Tweets von Opinion Leader durchzuführen, müssen geeignete Daten von Twitter gesammelt werden. Hierzu stehen von Twitter angebotene Tools zur Verfügung, wie dessen Application Programming Interface (API). Dieses Tool⁶ bietet Zugang zu öffentlichen Daten des Netzwerks durch 51 verschiedene Suchmethoden.

3.1. Design

Diese Arbeit entsteht unter der Annahme, dass Posts auf Twitter optimiert werden können, in dem die Tweets von Opinion Leader analysiert und bestimmte Muster in ihren Posts erkannt und nach Bedarf simuliert werden. Die vorliegende Arbeit fokussiert sich auf ein Themengebiet, ausgehend davon wurde eine Interessensdomäne für das Projekt festgelegt. Die Domäne wurde Anhand einer Netzwerkanalyse gewählt (s. Absatz 3.4) von kleineren Twitter Daten-Samples (ca. 3000 jeweils), um ein Themenbereich zu finden, entsprechend der Community Cluster Archetype (siehe Absatz 2.3.1).

Die Community Cluster wurde als Ziel-Archetype für die Forschung nach Opinion Leader gewählt, da bei diesem Muster eine moderate Anzahl von Gruppen (und dazugehörige Opinion Leader) vorzufinden sind. Es sollte weder eine zu polarisierte noch zu undeutlich erkennbare Führerschaft von Meinungsführern vorherrschen.

Nach Festlegung des Themengebiets, erfolgt eine Periode der Datengewinnung (im Detail erklärt in Absatz 3.2) gefolgt von 3 Phasen der Datenaufbereitung (siehe 3.4 und 3.7) für die Übergabe an das Supervised Training und die Optimierung der zu erstellenden

⁶ Twitter API Console Tool: <https://dev.twitter.com/rest/tools/console>

neuronalen Netze (siehe 3.8). Die Daten für das nachfolgende Trainieren erhalten ihre Klassifizierung von einer Netzwerkanalyse (vgl. NodeXL 3.2.4), woraus die Berechnung der Knotenzentralitäten und damit Erkennung der Grad der Meinungsführerschaft (siehe 2.4.2 für eine Behandlung von Zentralitäten) hervorgehen. Die Betweenness Centrality eignet sich insbesondere um Meinungsführer zu identifizieren, da diese Kennzahl die strategische Position des Meinungsführers innerhalb eines Netzwerkes und den kürzesten Weg zu anderen Mitgliedern des Netzwerkes beschreibt (Ediger, et al., 2010; Freeman, 1979).

Ebenfalls in Vorbereitung des Supervised Trainings, wird eine konventionelle Sentiment-Analyse durchgeführt, um den prozentualen Anteil der jeweils positiven- und negativen Sentiment-Wörter je Tweet zu errechnen. Diese Daten – zusammen mit den dazugehörigen Tweets – werden verwendet, um Sentiment-Analysen mittels neuronalen Netzen zu untersuchen.

Die dritte Phase der Datenaufbereitung umfasst die Erstellung von Word Embeddings (s. 2.5.1) aus den gesammelten Twitter Botschaften. Somit werden Millionen von Wörtern und Hashtags – unabhängig ihrer Sprachherkunft – in ihrer Essenz kodiert in einem numerischen Raum von der Dimension 300, damit diese, aber auch andere Tweets als geeignete Eingabe zu den neuronalen Netzen (sowohl in der Lernphase als auch in der Verwendung der fertigen Netze) verwendet werden können.

Diese Kodierung erfolgt in einem Unsupervised-Learning-Verfahren (s. 2.5.3). Es werden mehrere Embeddings erstellt mit unterschiedlichen Kombinationen von n-Grams (von Unigrammen und Bigramen bis hin zu Sexagramen), um zusätzlich den Effekt von

einer einfachen versus einer komplexere Satzdekomposition des Tweets auf die Ergebnisse zu prüfen. Der theoretische Hintergrund dazu ist in Absatz 2.5.2. erläutert.

3.2.Datenzugriff

Obwohl Twitter Daten öffentlich sind, und mittels der Suchmaske⁷ zu finden wären, stehen die Informationen so noch nicht in wissenschaftlich verwertbarer Form zur Verfügung. Um eine Datenbasis an Tweets von sowohl Opinion Leadern als auch Nicht-Opinion Leadern aufzubauen zu können, müssen die Zieldaten ausgewählt und softwaretechnisch von Twitter extrahiert und gesammelt werden. In den folgenden Abschnitten wurden vier Ansätze untersucht, um die Tweets, welche für das Trainieren des neuronalen Netzes notwendig sind, zu gewinnen.

3.2.1. Exploratives Suchen

Der „Twitter Advanced Search“ (s. Anhang A) wurde eingesetzt, als das einfachste Mittel, um explorativ an einen erwünschten Suchbegriff (und damit an die Datensätze in der ausgewählten Themendomäne für das Projekt) zu gelangen. Die Twitter REST-Schnittstelle bedeutet, dass die Query aus der URL-Zeile des Browsers entnommen, und an einer anderen Stelle (siehe 3.2.2) eingesetzt werden kann, um weiter verwendbare Twitter-Daten zu gewinnen.

3.2.2. API Einsatz

Der Apigee API Console (siehe Anhang B) wird eingesetzt, um alle der 51 Twitter-APIs anzusprechen. Ein Suchstring, gewonnen beispielsweise aus Versuchen mit dem

⁷ <https://twitter.com/search-advanced>

„Twitter Advanced Search“ (vgl. 3.2.1), wird in der Console abgesetzt und Daten im json⁸ Format im Browser-Fenster zurückgeliefert. Die json.Daten können dann in weitere Programme geparsst und weiterverwendet werden. Diese Methodik eignet sich eher für kleinere prototypische Experimente, ist jedoch hilfreich, um die Twitter Datenstrukturen und zurückgelieferte Daten in einem ersten Schritt kennenzulernen.

3.2.3.MATLAB

MATLAB⁹ ist eine Mehrzweck Entwicklungsumgebung (siehe Anhang C) für das Programmieren von wissenschaftlicher Software basierend auf Matrix und Array-Manipulationen. Eine Laufzeit-Umgebung, um kontrollierte Abläufe auch in Debugging-Modus¹⁰ durchzuführen, ist ebenfalls enthalten. In diesem Projekt wurden die Zusatzmodule von MATLAB für Deep Learning¹¹, sowie Data und Text Analytics¹² extensiv eingesetzt. Wesentliche Programmierarbeiten des Projektes wurden mit MATLAB durchgeführt.

3.2.4.NodeXL

Die Import-Funktion von NodeXL¹³ – einem Add-in für Excel – ermöglicht es, über den eigenen Twitter Account NodeXL als Anwendung zu registrieren, damit die Search-API angesprochen werden kann. Bis zu 18000 Tweets pro Tag können so bezogen werden. NodeXL hat ausserdem Visualisierungsoptionen (Huisman & van Duijn, 2016,

⁸ json: JavaScript Object Notation

⁹ MATLAB <https://ch.mathworks.com>

¹⁰ In Debugging-Modus wird das Programm kontrolliert, in Schritten ausgeführt. Die Werte aller Programmvariablen können währenddessen analysiert werden.

¹¹ Neuronales Netz Toolbox: <https://ch.mathworks.com/products/neural-network.html>

¹² Text Analytics Toolbox: <https://ch.mathworks.com/products/text-analytics.html>

¹³ NodeXL: <https://nodexl.codeplex.com/>

S. 27) nach verschiedenen Cluster- und Layout-Algorithmen. Womit Daten nach den erwünschten Archetypen (im Abschnitt 2.3.1 ersichtlich) identifiziert wurden.

Zwei Arten von Ergebnissen der NodeXL Netzwerkanalysen wurden für das Supervised Learning-Phase der neuronalen Netze verwendet, nämlich für die Zentralitäten der auserwählten Twitter-Daten sowie für die Sentiment-Analysen der gleichen Tweets durchzuführen.

3.2.5. Textkorpora

Zusätzlich zu den vier vorangegangenen Datengewinnungsstrategien existieren einige bereits von anderen Autoren analysierte und zugängliche Datenkorpora. Eine solche Datenbasis ist der „Twitter Sentiment Corpus“¹⁴ bestehend aus 1,578,627 nach Sentiment klassifizierten Tweets von Niek Sanders. Noch ergiebiger erwies sich die Datensammlungen, die auf <http://nodexlgraphgallery.org> zu finden sind. Hier werden seit mehr als drei Jahren über 60'000 Netzwerk Graphen und dazugehörige Twitter-Daten, Woche für Woche von der NodeXL Community zu den verschiedensten Themen archiviert. Außerdem werden diverse Metriken zu den Daten unter dieser URL publiziert, sowie Daten in NodeXL- und GraphML-Format der Allgemeinheit zur Verfügung gestellt. Die Verwendung von Twitter-Korpora beschleunigt die Datengewinnungsphase des Projektes erheblich, da aktuelle sowie historische Daten, genau passend zur Interessensdomäne, schnell bezogen werden konnten.

¹⁴ Twitter Sentiment Corpus: <http://www.sanalytics.com/lab/twitter-sentiment>

3.3. Limitationen der Twitter API

Ein wichtiger Punkt in der Datenbeschaffung ist, dass der Twitter API seit einigen Jahren nicht mehr verwendet werden kann, um beliebige Recherchen nach grossen Mengen von Tweets in einer Session durchzuführen. Bei jeder Suche ist die Treffermenge limitiert. Die Datenmenge von bezogenen Daten ist pro Tag limitiert auf 18000 Tweets und Tweets, die älter als einige Tage sind, (eine genaue Begrenzung ist nicht definiert, liegt aber in dem Bereich von ca. 6 bis 7 Tage), sind über den Search-API nicht abrufbar.

Diese Einschränkung gilt mit Ausnahme der Datenkorpora für alle der obigen Datenbezugsmethoden (3.2.1 bis 3.2.5) und bedeutet für das Projekt, dass, um längere Phasen der Datengewinnung zu vermeiden, erhebliche Datenmengen von <http://nodexlgraphgallery.org> bezogen wurden, sobald die Ziele der Datensammlung feststanden (siehe Abschnitt 3.5).

3.4. Netzwerkanalyse

Die gesammelten Daten von Twitter werden in das Tool NodeXL eingelesen. Daten konnten in ein analysierbares und visualisierbares Netzwerk umgewandelt werden, dass sich leicht filtern und sortieren lässt (Smith, et al., 2009). Die gesammelten Tweets wurden bei der Netzwerkanalyse um errechnete Zentralitäten (siehe 2.4.2) ergänzt, die in einer späteren Phase beim «Supervised Learning» der neuronalen Netzwerke (vgl. 2.5.3) in Kategorien eingeteilt und als Mass des Einflusses von Tweet-Erfasser verwendet werden. Ausserdem verfügt NodeXL über eine Sentiment-Analyse, dessen Ergebnisse ebenfalls in diesem Projekt als Training-Daten für die neuronalen Netze verwendet wurden.

3.5. Datenselektion

Bei der Datenselektion bieten Soziale Netzwerke die Möglichkeit, ein mehrstufiges Verfahren anzuwenden. Da eine ständige Verfügbarkeit von umfassenden, archivierten Daten (für Twitter, siehe 3.2.2) existiert, wurde, um eine für das Projekt nützliche Datenmenge zu beschaffen, iterativ vorgegangen.

Wie in 3.1 beschrieben, wurde die Interessensdomäne für das Projekt anhand einer Netzwerkanalyse von zeitbegrenzten Twitter Daten-Samples ermittelt, um geeignete Community Cluster (siehe Absatz 2.3.1) zu begutachten und für das Projekt festzulegen.

Im vorliegenden Fall war zu erwarten, dass diese Eingrenzung primär durch Suchen von Hashtag-Gruppen (von beispielsweise einem Thema oder einem Event) und/oder einer Selektion von Twitter-Handles (zum Beispiel von Personen oder Organisationen) ausgehen musste (Dang-Xuan, Stieglitz, Wladarsch, & Neuberger, 2013, S. 801). Die so definierten Suchkriterien wurden anschliessend in der Haupt-Datensammlungsphase eingesetzt.

3.6. Datenbereinigung

NodeXL und MATLAB bieten mehrere Funktionen zur Datenbereinigung an. Beispielsweise können Daten nach Thresholds (z.B. keine Twitter-Follower, Zentralitäten von Null oder selbstreferenzierende Retweets) aus gefiltert werden, womit die Menge an zu analysierenden Informationen erheblich eingeschränkt werden kann. Andere Forscher filtern oft ihre Daten und betrachten nur vermeintlich relevante/interessante Daten. Da das Projekt einen Fokus auf Opinion Leader legt, wäre es denkbar, auf alle Tweets, die keine Retweets haben, oder Twitter-User, die weniger als eine bestimmte Anzahl Follower haben, einschränken zu wollen. So wurde dies bereits in

einigen Studien praktiziert (Kwak, Lee, Park, & Moon , 2010; Suh, Hong, Pirolli, & Chi, 2010; Xu, Sang, Blasiola, & Park, 2014). Als Vorselektion möge es auch sinnvoll erscheinen, die Sprache der Tweets auf nur eine dominante Sprache (Englisch) einzuschränken. Die dazu notwendige Information ist in den meisten Fällen (wenn nicht immer zuverlässig¹⁵⁾ vorhanden.

Bei einem rein statistischen Vorgehen ist es jedoch wichtig zu versuchen, Daten, die ein Ergebnis fälschen könnten, von vorherein auszuschliessen. Die Problematik darin liegt, zuverlässig und ohne Bias zu entscheiden, welche Daten als ungültig oder als «Noise» gelten. Ein wesentlicher Vorteil dieses Projekts besteht darin, dass durch die Anwendung von neuralen Netzen in Kombination mit Massendaten, der Effekt von «Noise» in den Test- und Training-Daten sehr gut durch die multiplen Trainings Iterationen (in sogenannten Epochen: s. 2.5.3) egalisiert werden kann. Anzumerken ist auch, dass sowohl negative Daten (d.h. Tweets, die ohne meinungsbildenden Erfolg bleiben und als «von Nicht-Meinungsführern» klassifiziert werden) als auch positive Daten von Opinion Leader absolut notwendig sind, um ein neuronales Netz effektiv zu trainieren.

Aufgrund der vorangegangenen Gründe wurde weitestgehend auf Datenbereinigung verzichtet. Lediglich die Eliminierung von Duplikaten in einer Vorstufe wurde programmatisch automatisiert. Auf einer Einschränkung der Daten auf einer einzigen Sprache wurde – in Anlehnung an der Arbeit von Faruqui und Dyer (Faruqui & Dyer, 2014) – ebenfalls verzichtet auch, weil gerade Opinion Leader, die Tweets in mehreren Sprachen veröffentlichen und dadurch eine Brückenfunktion von

¹⁵ Die Sprache ist im Profil des Twitter-Users erfasst. Dies ist aber nicht zwangsläufig die Sprache aller dazugehörigen Tweets.

verschiedenen Gruppen auf Social Media einnehmen, so ungenügend in Betracht gezogen worden wären (vgl. 2.1 und 2.4).

3.7. Datenaufbereitung/Text-Vektorisierung

Nachdem die Rohdaten von Twitter erhalten wurden, musste ein spezialisiertes Data Embedding für diese Daten erstellt werden. Wie im Abschnitt 2.5.1 beschrieben, gibt es sehr umfassende, frei verfügbare Word Embeddings, die sich für die Kodierung von generischen textuellen Daten für das Trainieren von neuronalen Netzen eignen. Diese bereits vortrainierten Embeddings wurden ebenfalls im Projekt verwendet, aber es fiel nach den ersten Testläufen auf, dass allein mit dieser Methode, ca. 50% der Inhalte der Tweets nicht vektorisiert und somit ungenutzt blieben. So wurden eigene Embeddings von der gleichen Dimension (jedes Wort wird mit einem Vector der Dimension 300 repräsentiert) – wie die von anderen Forschern vorgefertigten Embeddings – aus den gewonnenen Twitter-Texten erstellt, damit die beiden Repräsentationen in Kombination miteinander verwendet werden konnten.

Das Vorgehen ist, durch alle der 227'759 eindeutigen Tweet-Texte (d.h. alle Tweets ohne doppelte Vorkommnisse) zu iterieren und bei jedem Tweet von maximal 140 Zeichen, den Tweet in sogenannte «Tokens» zu zerteilen. Die Trennung in Tokens wird mit spezialisierten MATLAB Funktionen vorgenommen, wobei man ein Token i.d.R. als ein Wort oder ein Emoticon betrachten kann oder in asiatischen Sprachen wie Japanisch und Chinesisch als ein Symbol.

3.8. Mustererkennung und Optimierung mittels neuronalen Netzen

Die Eigenschaften von Neuronalen Netzen werden genutzt, um komplexe Datenmuster, welche zwischen den Tweets und den errechneten Betweenness Centralities

entstehen können, in multiplen, sich wiederholenden Trainingsläufen (sog. Epochen) einzuprägen. Ähnlich wird mit den Sentiment-Werten vorgegangen, die als Ergebnis der Netzwerkanalyse mit NodeXL gewonnen werden. Die Ergebnisse aus der Netzwerkanalyse werden mit ihren zugehörigen, vektorisierten (siehe 3.7) Tweets in drei Tranchen aufgeteilt, und für die Anlernphase, die Verifikationsphase und die Testphase, des neuronalen Netzwerkes im Verhältnis 70:15:15 im Supervised-Learning Ansatz verwendet. Anschliessend steht ein einsatzfähiges neuronales Netz für die Prediktpause bereit.

Diese Phasen des Aufbaus und der Verwendung eines neuronalen Netzes wird grob in Abbildung 4 visualisiert.

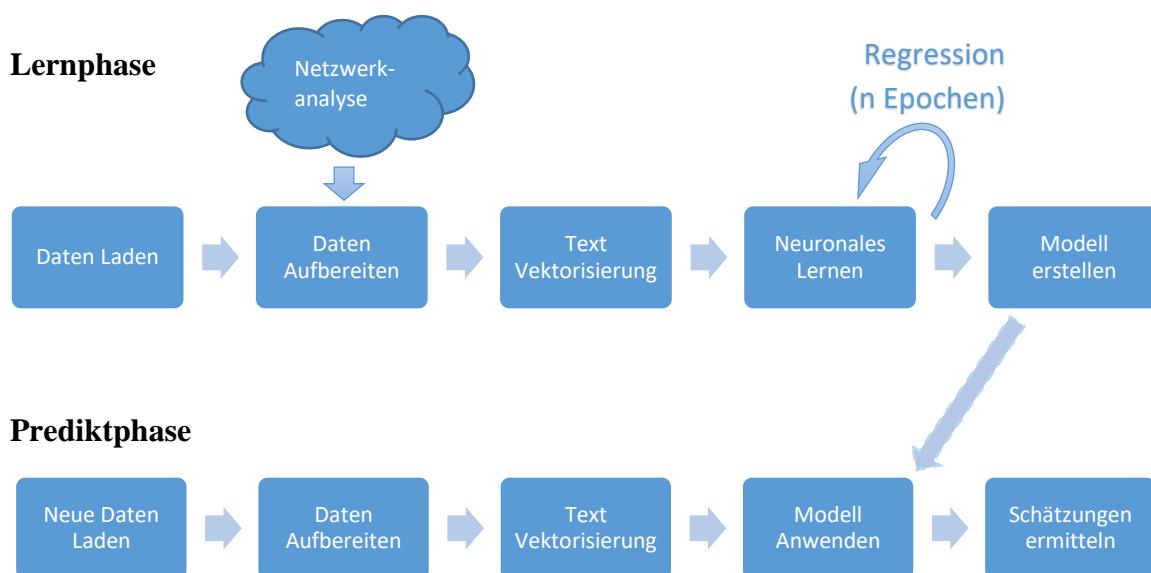


Abbildung 4: Lern- und Prediktphasen eines neuronalen Netzes
(Quelle: Eigene Abbildung)

3.8.1. Konfiguration und Optimierung der neuronalen Netze

Der im Abbildung 4 als „Regression“ abgebildete Schritt wird mehrfach wiederholt, um sich einer optimalen Parametrisierung des neuronalen Netzes anzunähern. Die Anlernphase wird selbstständig abgeschlossen, wenn die Verifikation beginnt und sich

keine weitere Besserung der Trainingsergebnisse zeigt. In diesem Projekt wurde stets die von MATLAB vorgeschlagenen 6 konsekutiven Verschlechterungen der Testergebnisse als Abschlusskriterium gewählt (vgl Validation Checks in Abbildung 7).

Die gesamte Lernphase wurde experimentell mehrfach wiederholt, um verschiedene Netzwerk-Architekturen (z.B. die Anzahl «hidden layers» oder Neuronen in einer Lage) zu prüfen. Dabei wurden jeweils unterschiedliche Anzahlen von Neuronen in den versteckten Lagen spezifiziert. Ebenfalls wurden verschiedene Satzdekompositionen bei der Text-Vektorisierung (in Unigrams bis Sexagrams) implementiert (gemäss Abschnitt 2.5.2) und experimentell in der Prediktpause eingesetzt.

Auf den Einsatz von weiteren, möglichen Algorithmen für Training und Performanz wurde zu Gunsten der von MATLAB voreingestellten «Scaled Conjugate Gradient» bzw. «Cross Entropy» Modelle verzichtet. Die Tranchenaufteilung wurde stets randomisiert vorgenommen.

Ein Multi-Layer Feed Forward Netzwerk (MLF) mit einer sigmoid versteckten Lage und softmax Ausgangsneuronen wurde für alle Mustererkennungsprobleme eingesetzt (siehe 2.5 für Theorie über MLF). Für die Word Embeddings wurde ein Word2Vec Embedding Algorithmus in Unsupervised Learnmodus und das CBOW¹⁶ Model benutzt. Beim Anlernen der Word Embeddings wurde jeweils ein Limit von 10 Epochen, (daher die Iterationen, die das neuronale Netzwerk durchläuft), festgelegt.

¹⁶ CBOW (Continuous Bag of Words): In diesem Vektorraum Modell, wird der Kontext eines Zielwortes durch mehrere Wörter repräsentiert. Zum Beispiel kann «klettern» sowohl durch das Wort «Baum» als auch «Katze» repräsentiert sein (Integrated Knowledge Solutions, 2015)

3.9.Darstellung und Evaluation von Lernergebnissen

Die Lernfortschritte und Ergebnisse während und nach dem Supervised-Learning werden mittels 4 Diagrammarten kontrolliert und bewertet. Um die Qualität des neuronalen Netzes zu bewerten, ist die Einschätzung, inwiefern die Klassifizierung mit neuen Twitter Daten – die nicht für das Anlernen verwendet wurden – von dem neuralen Netzwerk in den korrekten Klassen eingeteilt werden können. Dabei werden Informationen für jede einzelne Datenklasseunterteilung benötigt, die ursprünglich während den Trainings- und Validierungsläufen, sowie anschliessend im Testen eingesetzt werden, da durchaus unterschiedliche Datenmengen in den unterschiedlichen Klassen vorkommen werden. Zu diesem Zweck wird eine sogenannte Confusion Matrix verwendet.

3.9.1. Die Confusion Matrix

Die Klassifizierungsergebnisse werden in einer Confusion Matrix zusammengefasst und die prozentuale Genauigkeit, klassenweise und insgesamt errechnet. Bei der Klassifizierung sind 4 Ergebnisse je Vorhersage möglich:

- a) “true positive”: Korrekte Zugehörigkeit zu einer Klasse wird vorhergesagt
- b) “false positive”: Inkorrekte Zugehörigkeit zu einer Klasse wird vorhergesagt
- c) “true negative”: Korrekte Nicht-Zugehörigkeit zu einer Klasse wird vorhergesagt

d) “false negative”: Inkorrekte Nicht-Zugehörigkeit zu einer Klasse wird vorhergesagt

In dem Einfachen Beispiel in Abbildung 5 sind viele Information enthalten. Die Daten werden in 2 Klassen (1 und 2) unterteilt. Eine Mehrheit der Daten (56.2%) werden in Klasse 1 eingeteilt, wobei 93.7% korrekt als true positive vorhergesagt werden und 95.2% korrekt als true negative. Insgesamt wird für die Klassifizierung eine Fehlerquote von 5.7% ausgewiesen.

Test Confusion Matrix			
Output Class	Target Class		
	1	2	
1	59 56.2%	4 3.8%	93.7% 6.3%
2	2 1.9%	40 38.1%	95.2% 4.8%
	96.7% 3.3%	90.9% 9.1%	94.3% 5.7%

Abbildung 5: Beispiel eines Confusion Matrix

3.9.2. Receiver Operating Characteristic

Eine zusätzliche, differenzierte Analyse der Klassifizierungsgenauigkeit der Datenklassen wird mit dem Receiver Operating Characteristic (ROC) ermöglicht. Für jede Datenklasse wird die True Positive Rate (TPR, siehe 3.9.1) gegen die False Positive Rate (FPR) auf unterschiedlichen Niveaus gegenübergestellt. Eine sehr starke Übereinstimmung mit den Erwartungen zeigen die Punkte links oben, am weitesten weg von der Diagonalen. Wie dies im Idealfall aussehen kann, ist im rechten Diagramm der Abbildung 6 dargestellt. Die Differenzierung für die einzelnen Klassen ist beispielhaft in Abbildung 6 (links) dargestellt, wobei Class 6 die stärkste übereinstimmende Klassifizierung darstellt und Class 5 die schlechteste (welche Klassen für diese Arbeit bestimmt werden wird im Abschnitt 4.3 weiter erläutert). Punkte an der Diagonalen wären gleichbedeutend für Zufallswerte und würden auf ein neuronales Netz mit einer rein zufälligen Verteilung hindeuten.

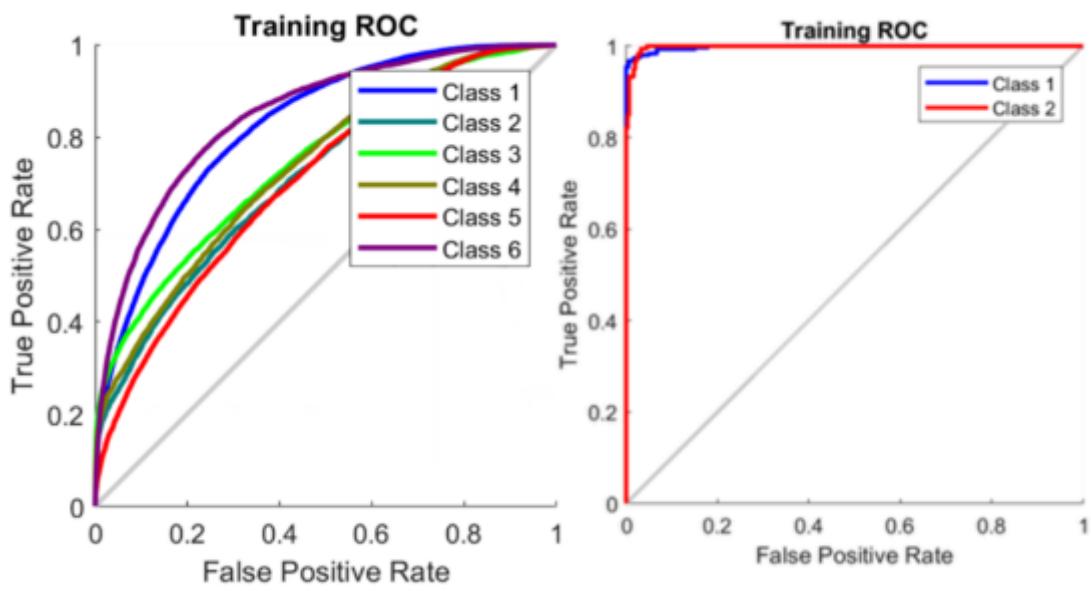


Abbildung 6: Zwei Beispiele der Receiver Operating Characteristic

3.9.3. Performanz Validierung und Training State

Ein Graph des fortlaufenden Erfolgs des Lernvorgangs für ein neuronales Netz wird verwendet, um zu kontrollieren, wann (in welcher Epoche) und mit welcher Genauigkeit das Training abgeschlossen wird. Der Verlauf eines Trainings über 17 Epochen wird in Abbildung 7 beispielhaft dargestellt. Der dazugehörige Training State (Rechts im Bild) zeigt deutlich, dass die beste Annäherung bei der 11. Epoche erreicht wird. Die Trainingsvorgänge werden nach 6^{17} hintereinander verschlechternden Epochen terminiert (vgl. 3.8.1).

¹⁷ Der Defaultwert von maximal 6 wurde unverändert von MATLAB übernommen

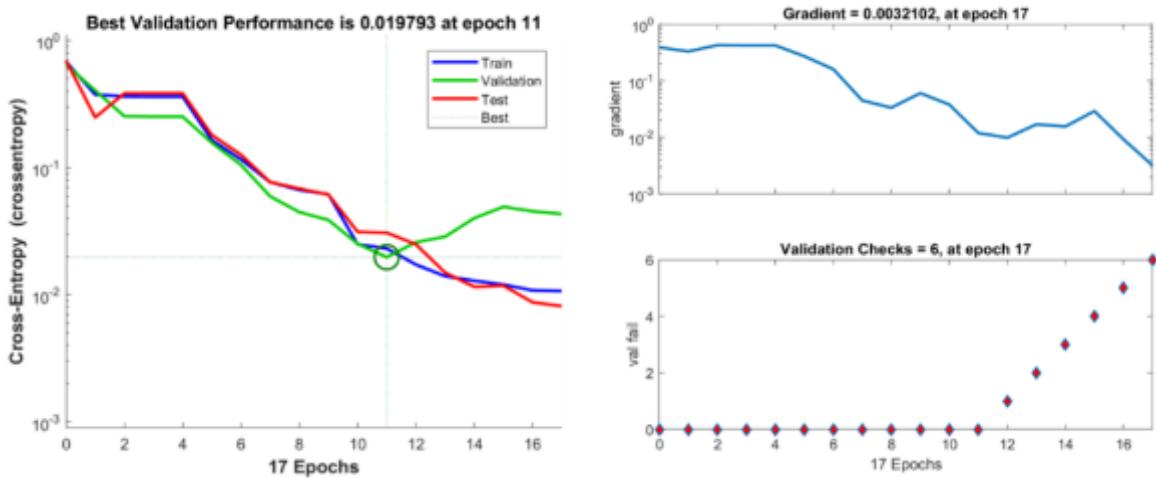


Abbildung 7: Beispiel der Best Validation Performance vs. Training State

4. Ergebnisse

Die Ergebnisse des Projektes werden in 5 Teilbereichen präsentiert. Zuerst wurde durch ad hoc Analysen von mehreren Twitter Netzwerken ein Themengebiet basierend auf genau einem Hashtag gewählt und Daten aus dem Zeitraum 25.12.2016 bis 15.11.2017 dazu gesammelt. Durch Netzwerkanalysen der Tweets, in Datentranchen von je einer Woche, wurden die Betweenness Centralities der Netzknöten ermittelt und die Durchführung einer Sentiment-Analyse, indem positiv- und negativbesetzte Wörter (im Vergleich zu standardisierten Sentiment-Wörterbüchern) in jedem Tweet identifiziert. Dies erlaubt den Ausdruck des Sentiments eines ganzen Tweets in zwei prozentuale Indikatoren (positiv/negativ) festzuhalten.

4.1. Selektion der Datensätze zu Untersuchung

Nach der explorativen Analyse von zahlreichen Twitter Netzwerken wurde aufgrund der guten Korrespondenz zur Sozialen Netzwerk Topologie des Community

Cluster (siehe 2.3.1) entschieden, den Hash-Tag #unfoundation als Basis für alle weitere Projektarbeit zu übernehmen. In Abbildung 8 (ein Beispiel mit Daten von einer Woche im November 2017) können die gut ausgeprägten Cluster erkannt werden, mit – gemäss der Netzwerkanalyse – dementsprechend mehreren Meinungsführern. In diesem Beispiel wurden, um die Abbildung deutlicher werden zu lassen, die kleineren Gruppen (G9 – G73) ausgeblendet. Ausführlichere Daten zu allen UN-Foundation Gruppen aus dieser Woche sowie die häufigsten Hashtags, URLs und verwendeten Wörter sind im Anhang D aufgeführt.

Die UN-Foundation ist eine unabhängige, gemeinnützige Organisation, welche mit ihrem Wirken die Ziele der United Nation zu unterstützen versucht. Der Grundgedanke der Stiftung ist, dass die Regierungen, welche mit der UN arbeiten nicht ausreichend sind, um dessen Ziele zu erreichen, weswegen Partnerschaften zwischen dem öffentlichen und privaten Sektor nötig sind. Die UN-Foundation unterstützt die UN indem sie Menschen, Ideen und Ressourcen verbindet (United Nations Foundation, 2013). Insbesondere durch die verschiedenen Wirkungsbereiche der UN (Klimawandel, Frieden, Frauenrechte und viele weitere Themen) entsteht ein Community Cluster gemäss Smith (siehe 2.3.1). Innerhalb einer Anzahl an Subthemen bzw. der Organisationen, welche sie unterstützen, herrschen enge Verbindungen. Die Subthemen selber sind nur zum Teil miteinander verbunden.

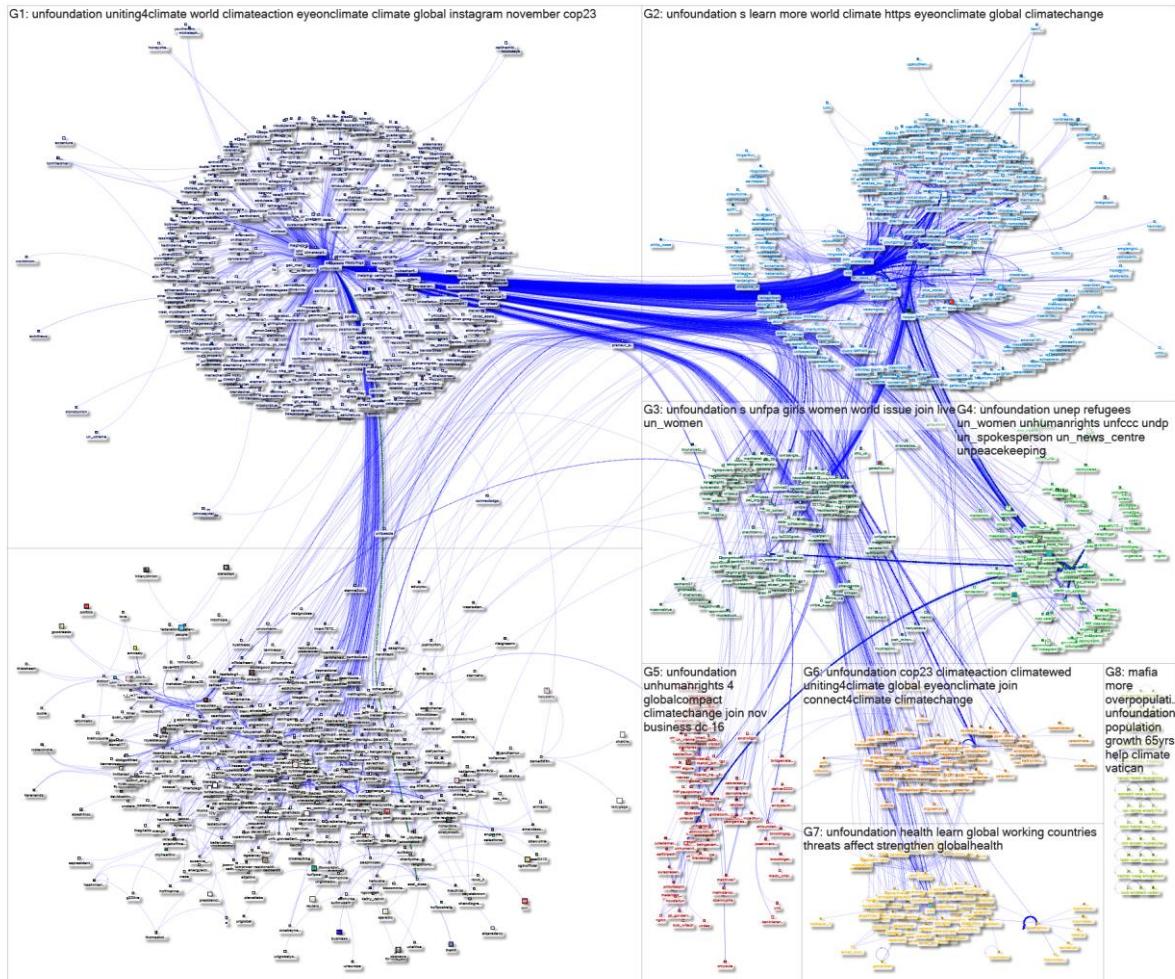


Abbildung 8: Netzwerk Analyse des Hashtags #unfoundation
09.11.2017 - 15.11.2017 (Gruppen 1 – 8)

Es wurden Twitter-Daten der Zeitraum 25.12.2016 durchgehend bis 15.11.2017 gesammelt und doppelte Vorkommnisse ausgefiltert (Datenbereinigung gemäss Absatz 3.6). Die Anzahl an eindeutigen Tweets, die in den folgenden Arbeitsschritten verwendet wurde, war 207'930.

4.2. Erstellung von Word Embeddings für #unfoundation

Anhand der 207'930 Tweets wurden 4 Word Embeddings erstellt mit n-Gram-Bereichen von Unigram bis Trigram zu Sexagram, um gemäss 2.5.2 die späteren Effekte

von unterschiedlichen n-Gram-Bereichen zu prüfen. Es wurde jeweils ein Vokabular von 32'926 Tokens enkodiert mit der Dimension 300, damit diese eigenen Encodings mit den Embeddings (von ebenfalls Dimension 300) der Universität von Stanford zusammengefügt werden konnten. Die Embeddings der Universität Stanford wiederum wurden mit dem GloVe¹⁸ Algorithmus trainiert mit einem Vokabular von 400'000 Wörtern von Wikipedia und Gigaword5¹⁹.

4.3. Klassenbestimmung der Daten

Anhand der beobachteten Verteilung der Centrality- und Sentiment-Werten, wurden Werteklassen bestimmt. Für Betweenness Centrality waren diese logarithmisch verteilt: 0-1, 1-10, 10-100, ..., bis 10'000 und darüber, für Sentiment, fast linear verteilt mit einer höchsten Sentiment-Wort-Perzentil von 25% und darüber. Diese grobe Aufteilung der erwarteten Werte sollte dafür sorgen, dass immer eine statistisch signifikante Anzahl von Tweets in jeder Klasse vorzufinden war. Die Aufteilung wurde verwendet, um jeden einzelnen Tweet, für die neuronalen Netz-Lernvorgänge, in genau eine Klasse einzuteilen.

4.4. Supervised Learning Ergebnisse

Für alle Anlernvorgänge der MLFs wurden die 207'930 eindeutigen Tweets in Trainierdaten, Verifikationsdaten und Testdaten in einem randomisierten Vorgang unterteilt. Die Tweets wurden jeweils mit einer Kombination der eigenen Word Embeddings (in 4 unterschiedlichen n-Gram Kombinationen) und diejenigen von der Universität von Stanford vektorisiert als Input für das MLF aufbereitet. Die errechneten

¹⁸ GloVe: Global vectors for Word Representation <https://nlp.stanford.edu/projects/glove/>

¹⁹ Gigaword (<https://catalog.ldc.upenn.edu/LDC2011T07>) ist ein Konsortium der Linguistik der Universität von Pennsylvania, das Texte aus Nachrichtendiensten über mehrere Jahre hinweg sammelt.

Betweenness Centralities der Netzwerkanalyse wurden in 6 Klassen unterteilt (vgl. 4.3), als Ergebnisse des Trainings (resp. der Validierung oder des Tests). Die Ergebnisse werden im Folgenden tabellarisch zusammengefasst. Die ausführlichen Ergebnisse sind in Anhang E aufgeführt.

4.4.1. Betweenness Centrality

Tabelle 1: MLF Lernergebnisse für Betweenness Centrality

Id.	# Neuronen im versteckten Layer	n-Gram Bereich	Lernepochen	Lernzeit	Gesamt Testerfolg²⁰
BC1	10	1 – 1	351	15m 41s	60.3%
BC2	10	2 – 3	378	11m 50s	60.3%
BC3	10	2 – 4	360	5m 45s	60.2%
BC4	10	3 – 6	403	12m 40s	59.5%
BC5²¹	10	3 – 6	350	11m 21s	59.5%
BC6	100	3 - 6	478	40m 11s	61.8%
BC7	500	3 - 6	583	4h 16m 47s	62.2%
BC8	1000	3 – 6	726	9h 20m 57s	62.6%

²⁰ Durchschnitt aller Klasseergebnisse

²¹ Absichtliche (Kontroll-)Wiederholung von BC4

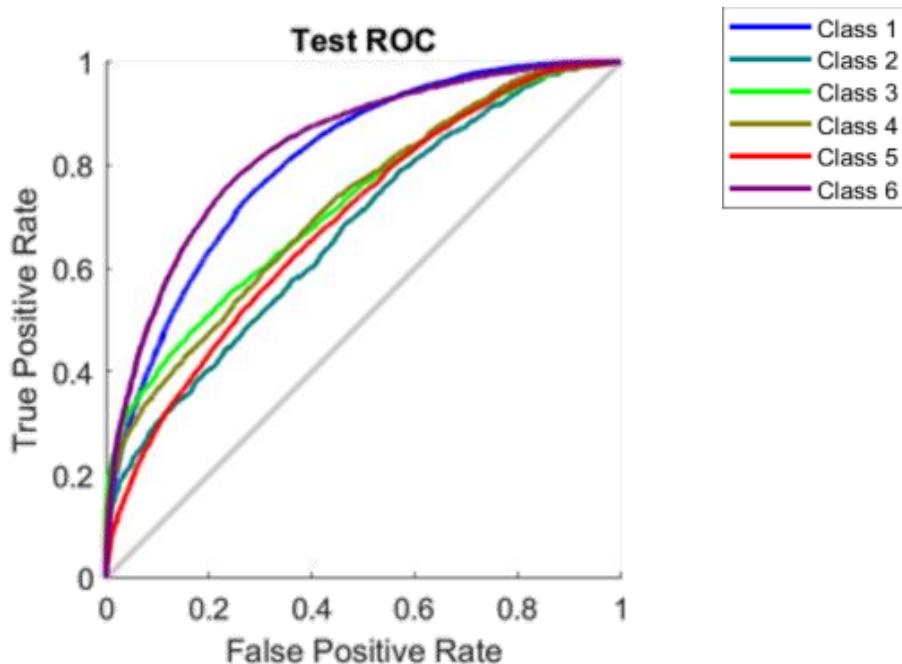


Abbildung 9: ROC Trainingsergebnis für BC2 (Hidden Layer 10, Bigram 2-3)

4.4.2. Positives Sentiment

Tabelle 2: MLF Lernergebnisse für Positives Sentiment

Id.	# Neuronen im versteckten Layer	n-Gram Bereich	Lernepochen	Lernzeit	Gesamt Testerfolg
PS1	10	1 – 1	555	10m 28s	82.9%
PS2	10	2 – 3	156	3m 10s	81.0%
PS3	10	2 – 4	402	7m 34s	82,6%
PS4	10	3 – 6	388	25m 48s	81.6%
PS5	100	3 - 6	727	51m 35s	85.2%
PS6	500	3 - 6	765	4h 42m 51s	84.6%
PS7	1000	3 – 6	587	6h 4m 5s	84.0%

4.4.1. Negatives Sentiment

Tabelle 3: MLF Lernergebnisse für Negatives Sentiment

Id.	# Neuronen im versteckten Layer	n-Gram Bereich	Lernepochen	Lernzeit	Gesamt Testerfolg
NS1	10	1 – 1	321	6m 21s	91.0%
NS2	10	2 – 3	398	8m 12s	91.5%
NS3	10	2 – 4	337	5m 26s	91.3%
NS4	10	3 – 6	374	40m 30s	90.4%
NS5	100	3 – 6	364	25m 33s	92.2%
NS6	500	3 – 6	178	1h 8m 35s	90.3%
NS7	1000	3 – 6	300	3h 41m 1s	91.0%

4.5. Anwendung des Neuronalen Netzes

Gemäss Abbildung 4 (Prediktphase) wurden neue Daten erstellt, um die neuronalen Netze zu testen. Diese Daten entstanden aus eigenen Formulierungen hypothetischer Tweets und verwendeten Hashtags, die in der UN-Foundation Domäne gängig sind. Ein Programm wurde geschrieben, um für einen Tweet analog dem Verfahren der Lernphase des neuronalen Netzwerkes vorzugehen und alle Klassifizierungsergebnisse gemeinsam als Histogramm darzustellen.

Die neuerstellten Test-Tweets wurden mittels Word-Vektorisierung (siehe Abschnitt 3.7) für die neuronalen Netze aufbereitet und in diese eingespeist. Jedes einzelne Tweet wurde durch Netzwerke mit verschiedenen N-Grams (Unigram, N-Gram mit min. 2 und max. 3, N-Gram mit min. 2 und max. 4 und N-Gram mit min. 3 und max. 6) geprüft. Mit den neuronalen Netzen für Betweenness Centrality, positives Sentiment

und negatives Sentiment wurden folgende Ergebnisse erreicht. In Abbildung 10 wird beispielhaft gezeigt, wie der mögliche Tweet («*When people are healthy, countries thrive. Learn how universal health coverage can help #EndPoverty*») eine sehr hohe Meinungsführerschaft bewirken würde und ein hoch positives Sentiment besitzt. Negatives Sentiment ist nur im geringen Masse vorhanden (1 auf einer Scala von 1 bis 7). Dieser Tweet hat also ein hohes Potenzial Meinungsführerschaft zu zeigen und wirkt zudem positiv und frei von Negativität. Weitere solche Beispiele sind im Anhang F aufgeführt.

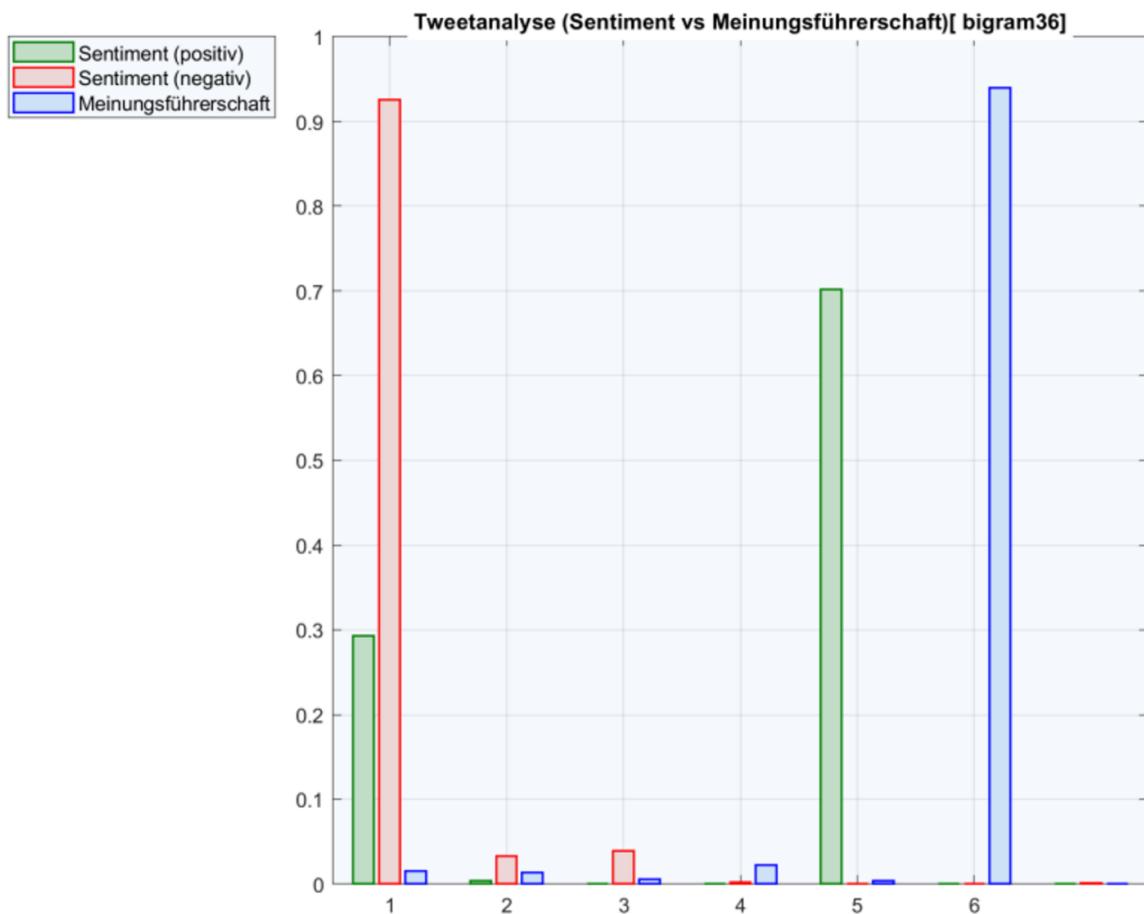


Abbildung 10: Beispielhaftes Ergebnis zu dem Test Tweet:
When people are healthy, countries thrive. Learn how universal health coverage can help #EndPoverty

4.6. Interpretation der Ergebnisse

Alle Lernvorgänge sind erfolgreich durchgeführt worden. Die Training State Diagramme zeigen in allen Fällen eine konsistente und sukzessive Annäherung zum Zielzustand, über mehrere hundert Epochen. Die ROC Ergebnisse sind alle als reliabel einzuschätzen, bestätigt durch absichtlich durchgeführte Wiederholungen der Trainings, wie z.B. BC5. Innerhalb der einzelnen Klassen gibt es nur leichte Abweichungen zwischen den einzelnen Testläufen. Im Sinne der neuronalen Netzwerktechnik sind die Ergebnisse von gleichmäßig sehr guter Qualität (vgl. alle Validation Performance Diagramme im Anhang E) und deuten darauf hin, dass sowohl die Basisdaten (von Twitter) ausreichend in der Menge, Konsistenz und Qualität waren. Die Datenanreicherung durch die NodeXL Netzwerkanalyse funktionierte, wie geplant.

Es fällt auf in den ROC Diagramme für Betweenness Centrality, dass die Klassen 1 und 6 konsistent die höchsten Trainingserfolgsquoten haben (beispielhaft gezeigt an Abbildung 9). Dieser Effekt scheint daher zu kommen, dass insgesamt mehr Daten für diese beiden Klassen vorhanden sind (vgl. Confusion Diagramme), und verursachen eine bessere Wirkung des neuronalen Netzes wegen höherer statistischer Sicherheit. Eine praktische Auswirkung dürfte sein, dass Einteilungen in diese Klassen eine höhere Zuverlässigkeit für die Opinion Leadership Prognosen besitzen werden.

Insgesamt sind die Ergebnisse für Betweenness Centrality weniger klar, als für Sentiment-Analyse, was für die Komplexität der Identifikation von Meinungsführerschaft spricht. Fast unabhängig von den gewählten Parametern (Grösse der versteckten Lagen im Netzwerk, verschiedene N-Gram Kombinationen) wird ein Gesamttestergebnis von rund 61% erreicht. Bei der Sentiment-Analyse sind die Ergebnisse sehr überzeugend (> 80%) und noch eindeutiger für negatives als für positives Sentiment. Diese Ergebnisse

bestätigen die Funde von Thelwall wie bereits in Kapitel 2.2 erwähnt. Bei genauerer Betrachtung der Daten fällt auf, dass nur wenige stark negative Tweets in den Klassen 5 und 7 vorhanden sind. Somit vereinfacht sich der Lernvorgang leicht und könnte die höhere Erfolgsquote von über 90% erklären.

Die wahrscheinlichste Erklärung für die Diskrepanz zwischen Klassifizierung von vorhergesagten Betweenness Centrality versus Sentiment-Analyse liegt daran, dass die Sentiment-Analyse eine eher semantische Eigenschaft ist und lässt sich im Ganzen aus dem Tweet Text gewinnen. Die Betweenness Centrality ist hingegen nur indirekt mit dem Tweet Inhalt gekoppelt und wird schliesslich von anderen Tweets und sozialen Netzwerk-Aktivität beeinflusst.

Beim abschliessenden Tests mit selbsterstellten Tweets wurde ersichtlich, dass – je nach N-Gram Art – die prognostizierten Klassifizierungen relativ stark voneinander abwichen. Eine mögliche Erklärung ist, wie in 2.5.2 angerissen wurde, dass erst bei Multigramme die Aspekte der Wortreihenfolge und somit der Kontext des gesamten Tweets berücksichtigt werden kann. Dieser Aspekt gewinnt an Bedeutung mit n-Grams von höherer Ordnung, setzt aber grössere Mengen an Trainingsdaten voraus, als z.B. bei Unigramme nötig wäre.

5. Konklusion

Es ist möglich, die Ergebnisse einer Netzwerkanalyse zu verwenden, um neuronale Netze zu trainieren, welche die Essenz des zugrundeliegenden Sozialen Netzes einfangen. Die so erstellten neuronalen Netze, können anschliessend sehr einfach und schnell eingesetzt werden, um wahrscheinliche Auswirkungen eines neuen Tweets (Betweenness Centrality, positives und negatives Sentiment) in Hinsicht auf Meinungsführerschaft

vorherzusagen. Die Erfolge der Techniken sind dabei statistisch markanter im Bereich der Sentiment-Analyse als bei Vorhersagen zu Betweenness Centrality, wenngleich eine deutlich besser als zufällige Vorhersage von hohen Zentralitäten erreicht wird.

Es liegt in der Natur von Hashtags sehr schnelllebig zu sein und, dass neue Hashtags immer wieder bei neuen Ereignissen und aktuellen Themen entstehen werden. Auch wenn in diesem Projekt eigene Word Embeddings entstanden sind, welche das Vokabular der Hashtags zu einem bekannten Thema (hier Diskussionsbereiche rundum die UN-Foundation Organisationen) einbinden, wäre es notwendig, die Lernprozesse fortlaufend zu wiederholen. Somit können die neuesten Hashtags einen Effekt in der Bewertung zeigen. Im Gegensatz dazu, ist die Bewertung von Sentiment, die im Wesentlichen semantisch und eine viel eher auf Standardsprache bezogene Eigenschaft ist, lässt sich mit hoher Konstanz mit den Methoden dieses Projektes beziffern (ersichtlich in 4.4.2 und 4.4.1).

Es ist für Twitter User gelegentlich sinnvoll, selbst ein neues, eigenes Hashtag in Twitter einzuführen. Eine solche Vokabular-Erweiterung dürfte besonders gut zu einem Opinion Leader passen und da diese Originalität mit den hier präsentierten Methoden unerkannt bleiben dürfte, wird dieser Aspekt von Meinungsführerschaft auf andere Art und Weise bewertet werden müssen. Der Tweet-Inhalt wird ein Effekt auf die Meinungsführerschaft haben können, aber erst in der Summe von mehreren Tweets ist ein wirklich entscheidender Effekt zu erwarten. Auch mit einem «perfekt» beschaffinem Tweet ist die Wahrscheinlichkeit umgehend zum Opinion Leader auf Twitter zu mutieren, sehr gering. Vielmehr müsste über einem gewissen Zeitraum Tweets mit Eigenschaften eines Meinungsführers erfasst werden.

Ein wichtiger Einfluss der in dieser Arbeit ausser Acht gelassen wurde, ist der Einfluss, den die Verfasser der Tweets ausserhalb des Twitter-Universums haben. Der

grössere Einfluss kann von anderweitiger Bekanntheit ausserhalb der Sozialen Medien seinen Ursprung haben (vgl. 2.1).

Bezogen auf der Forschungsfrage kann gesagt werden, dass mit den hier präsentierten Techniken ein vorgefasster Tweet in Hinsicht auf Qualitäten der Meinungsführerschaft optimiert werden kann. Insbesondere kann ein gewollt positives oder negatives Sentiment objektiv zuverlässig beurteilt werden, sofern komplexe Aspekte wie Ironie ausser Acht gelassen werden. Opinion Leadership tendiert themenbezogen zu sein und eine thematische Anwendung von ANNs wird entsprechend vorausgesetzt. Sehr dynamische Aspekte eines Themas (Erstellung von neunen Hashtags, zum Beispiel) verursachen eine Notwendigkeit des häufigen Nachtrainierens der ANNs.

6. Ausblick und Limitation der angewandten Methode

Obwohl im Projekt deutlich Abstand von Datenbereinigung genommen wurde, besteht in sozialen Netzwerken das Problem des bewussten Versuchs Einfluss zu nehmen durch Spammer und Bots (maschinell erstellte Soziale Netzwerkbeiträge). In den meisten Szenarien wäre es wünschenswert, solche Interventionen auszuschliessen. Einige Methoden dazu sind von Kwak et al umrissen worden (Kwak, Lee, Park, & Moon , 2010). In künftiger Forschung, da die Häufigkeit von automatisierten Spam-Techniken sich zunehmend verbreitet, sollte über eine effiziente Erkennung und ein Ausschluss an Spam-Daten gedacht werden.

Die Untersuchungen in diesem Projekt verwenden Daten, die über einen Zeitraum von einem Jahr gesammelt werden, in der Annahme, dass zuverlässigere und zahlreichere Muster das neuronalen Netz aus grösseren Datenmengen antrainiert werden können. Dabei werden temporale Faktoren aber nicht berücksichtigt. Es ist denkbar und wäre

wertvoll zu untersuchen, ob und wie sich Meinungsführerschaft mit fortschreitender Zeit anpassen muss. Zumindest müsste klarwerden, für wie lange ein neuronales Netz Gültigkeit besitzt, mit den Techniken, die in diesem Projekt angewendet wurden.

Natürliche Sprache lässt sich nicht immer mit simplen Mitteln maschinell analysieren. Ein Satz wie «Don't you just love all those politicians who are ruining our economy? » könnte – einfach gesehen – zur Hälfte positiv (“don't you just love[...]”) und zur Hälfte negativ (“[...] ruining our economy”) interpretiert werden. Wenn man dazu noch ein Mittelwert für den ganzen Satz errechnen würde, käme sogar noch eine neutrale Bewertung dabei heraus. Tatsächlich aber, soll die Ironie des Satzes, die Negativität noch bekräftigen. Solche Feinheiten zeigen Grenzen für das erstellte neuronale Netz auf. Auch wenn in diesem Projekt die gleichzeitige Erkennung von Positivität und Negativität demonstriert werden konnte, bleibt die Frage offen, was das in der Summe bedeutet.

Schliesslich ist anzumerken, dass ca. 40% von Tweets, Bilder oder Video-Material enthalten (Lee, 2016). In diesem Projekt wurde die Analyse auf ausschliesslich textuelle Inhalte beschränkt. In anderer Forschung wurde erkannt, dass Bilder, Videos, URLs und weitere Medien zusätzlich zu dem Text eine höhere Aufmerksamkeit generieren, dementsprechend auch häufig eingesetzt werden und ein höheres Potenzial zur Meinungsführerschaft aufweisen könnten (Bakshy, Hofman, Mason, & Watts, 2011; Suh, Hong, Pirolli, & Chi, 2010). Die künftige Forschung sollte sich aus diesem Grund auf visuelle Stimuli ausdehnen.

Bibliografie

- Bakshy, E., Hofman, J., Mason, W., & Watts, D. (2011). Everyone's an Influencer: Quantifying Influence on Twitter. *The 11th ACM International Conference on Web Search and Data Mining*, (S. 1-10). Hong Kong, China. Abgerufen am 25. Oktober 2017 von <http://www.wsdm2011.org/wsdm2011/home>
- Biganzoli , E., Boracchi , P., Mariani, L., & Marubini, E. (1998). Feed Forward Neural Networks for the Analysis of Consored Survival Data: A Partial Logistic Regression Approach. *Statistics In Medicine*, S. 1169-1186.
doi:10.1002/(SICI)1097-0258(19980530)17:10<1169::AID-SIM796>3.0.CO;2-D
- Bonfadelli, H., Friemel, T. N., & Wirth, W. (2010). Meienwirkungsforschung. In H. Bonfadelli, O. Jarren, & G. Siegert (Hg.), *Einführung in die Publizistikwissenschaft* (3. Ausg., S. 607 - 646). Stuttgart: UTB Verlag.
- Cha, M., Haddadi, H., Benevenuto, F., & Gummadi, K. (2010). Measuring User Influence in Twitter: The Million Follower Fallacy. *International AAAI Conference on Weblogs and Social Media*. Association for the Advancement of Artificial Intelligence. Abgerufen am 25. Oktober 2017 von <https://www.aaai.org/home.html>
- Dang-Xuan, L., Stieglitz, S., Wladarsch, J., & Neuberger, C. (2013). An Investigation of Influentials and the Role of Sentiment in Political Communication on Twitter During Election Periods. *Information, Communication & Society*, 16(5), S. 795–825. Von <http://www.tandfonline.com/doi/abs/10.1080/1369118X.2013.783608> abgerufen
- Djellali, C., & Adda, M. (2017). A New Data-Driven Deep Learning Model for Pattern Categorization using Fast Independent Component Analysis and Radial Basis Function Network.Taking Social Networks resources as a case. *Procedia Computer Science*, 113, p. 97-104. doi:10.1016/j.procs.2017.08.320
- Easley, D., & Kleinberg, J. (2010). *Networks, Crowds, and Markets: Reasoning about a Highly Connected World*. New York: Cambridge University Press. Abgerufen

am 9. Feubuary 2016 von <http://www.cs.cornell.edu/home/kleinber/networks-book/>

Ediger, D., Jiang, K., Riedy, J., Bader, D., Corley, C., Farber, R., & Reynolds, W. (2010). Massive Social Network Analysis: Mining Twitter for Social Good. *IEEE Computer Society*, S. 583-593. doi:10.1109

Faruqui, M., & Dyer, C. (2014). Improving Vector Space Word Representations Using Multilingual Correlation. *Proceedings of the 14th Conference of the European Chapter of the Association for Computational Linguistics* (S. 462 - 471). Gothenburg, Sweden: Association for Computational Linguistics.

Freeman, L. C. (1979). Centrality in Social Networks Conceptual Clarification. *Social Networks*, 1(3), S. 215-239. doi:10.1016/0378-8733(78)90021-7

Goikoetxea, J., Agirre, E., & Soroa, A. (2016). Single or Multiple? Combining Word Representations Independently Learned from Text andWordNet. *Proceedings of the Thirtieth AAAI Conference on Artificial Intelligence*, S. 2608 - 2614.

Häussling, R. (2008). Zur Verankerung der Netzwerkforschung in einem methodologischen Relationalismus. In C. Stegbauer, & R. Häussling (Hrsg.), *Netzwerkanalyse und Netzwerktheorie. Ein neues Paradigma in den Sozialwissenschaften*. (S. 65-78). Wiesbaden: VS Verlag für Sozialwissenschaften. Abgerufen am 9. Dezember 2017 von <https://link.springer.com/content/pdf/10.1007%2F978-3-531-91107-6.pdf>

Herrero, J., Valencia, A., & Dopazo, J. (2001). A hierarchical unsupervised growing neural network for clustering gene expression patterns. *Bioinformatics*, 17(2), S. 126-136. doi:10.1093/bioinformatics/17.2.126

Huisman, M., & van Duijn, M. A. (2016). A Reader's Guide to SNA Software. In J. S. Carrington, *The SAGE Handbook of Social Network Analysis*. London: SAGE Publications Ltd.

Integrated Knowledge Solutions. (13. April 2015). *Words as Vectors*. Tratto il giorno 4. Februar 2018 da From Data to Decisions; Integrated Knowledge Solutions: <https://iksinc.online/tag/continuous-bag-of-words-cbow/>

- Jungherr, A. (2014). The Logic of Political Coverage on Twitter: Temporal Dynamics and Content. *Journal of Communication*, 64, S. 239–259.
doi:10.1111/jcom.12087
- Katz, E. (1957). The Two-Step Flow of Communication: An Up-To-Date Report on an Hypothesis. *Political Opinion Quarterly*, 21(1), S. 61-78. doi:10.1086/266687
- Kennedy, H. (2012). Perspectives on Sentiment Analysis. *Journal of Broadcasting & Electronic Media*, 56(4), p. 435-450. doi:10.1080/08838151.2012.732141
- Kim, Y. (2014). Convolutional Neural Networks for Sentence Classification. *Conference on Empirical Methods in Natural Language Processing (EMNLP)*, (S. 1746–1751). Doha, Qatar. Abgerufen am 25. Oktober 2017 von <http://emnlp2014.org/papers/pdf/EMNLP2014181.pdf>
- Krempel, L. (2016). Network Visualization. In J. S. Carrington, *The SAGE Handbook of Social Network Analysis*. London: SAGE Publications, Ltd.
- Kwak, H., Lee, C., Park, H., & Moon , S. (2010). What is Twitter, a Social Network or a News Media? *World Wide Web Conference Committee*, (S. 1-10). Raleigh, North Carolina, USA. doi:10.1145/1772690.1772751
- Lazarsfeld, P., Berelson, B., & Gaudet, H. (1944). The People's Choice: How the voter makes up his mind in a presidential campaign. New York/London: Duell, Sloan and Pearce.
- Lee, K. (27. Januar 2016). *What 1 Million Tweets Taught Us About How People Tweet Successfully*. Tratto il giorno 6. Februar 2018 da Buffer:
<https://blog.bufferapp.com/twitter-data-1-million-tweets>
- Luo, Z., Liu, L., Yin, J., Li, Y., & Wu, Z. (2017). Deep Learning of Graphs with Ngram Convolutional Neural Networks. *IEEE Transactions on Knowledge and Data Engineering*, 29(10), S. 2125-2139. doi:10.1109/TKDE.2017.2720734
- Ma, Z., Sun, A., & Cong, G. (2013). On Predicting the Popularity of Newly Emerging Hashtags in Twitter. *Journal of the American Society for Information Science and Technology*, 64(7), S. 1399–1410. doi:10.1002/asi.22844

- O'Leary, D. (2015). Twitter Mining for Discovery, Prediction and Causality: Applications and Methodologies. *Intelligent Systems in Accounting, Finance and Management*, 22, S. 227–247. doi:10.1002/isaf.1376
- Pang, B., & Lee, L. (2008). Opinion mining and sentiment analysis. *Foundations and Trends in Information Retrieval*, 2(1-2), p. 1–135. doi:10.1561/1500000011
- Pennington, J., Socher, R., & Manning, C. (2014). GloVe: Global Vectors for Word Representation. *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)* (S. 1532–1543). Doha, Qatar: Association for Computational Linguistics. Abgerufen am 14. November 2017 von <https://nlp.stanford.edu/projects/glove/>
- Reinecke Flynn, L., Goldsmith, R., & Eastman, J. (1996). Opinion Leaders and Opinion Seekers: Two New Measurement Scales. *Journal of the Academy of Marketing Science*, 24(2), S. 137-147. doi:10.1177/0092070396242004
- Smith, M., Rainie, L., Shneiderman, B., & Himelboim, I. (20. Februar 2014). *Mapping Twitter Topic Networks: From Polarized Crowds to Community Clusters*. Abgerufen am 26. Oktober 2017 von Pew Research Center Internet & Technology: <http://www.pewinternet.org/2014/02/20/mapping-twitter-topic-networks-from-polarized-crowds-to-community-clusters/>
- Smith, M., Shneiderman, B., Milic-Frayling, N., Mendes Rodrigues, E., Barash, V., Dunne, C., . . . Gleave, E. (2009). Analyzing (Social Media) Networks with NodeXL. *Proc. Communities & Technologies Conference*. Springer. Tratto il giorno 6. 10 2017 da <http://www.cs.umd.edu/localphp/hcil/tech-reports-search.php?number=2009-11>
- Song, X., Chi, Y., Hino, K., & Tseng , B. (2007). Identifying Opinion Leaders in the Blogosphere. *Conference on Information and Knowledge Management* (p. 971-974). Lisbon, Portugal: York, ACM Association for Computing Machinery New. doi:10.1145/1321440.1321588
- Sosa, P., & Sadigh, S. (2016). *Twitter Sentiment Analysis with Neural Networks*. Abgerufen am 25. Oktober 2017 von http://konukoii.com/blog/wp-content/uploads/2016/12/sosa_sadigh_twitter_sentiment_nn.pdf

- Stehr, P., Rössler, P., Leissner, L., & Schönhardt, F. (2015). Parasocial Opinion Leadership Media Personalities' Influence within Parasocial Relations: Theoretical Conceptualization and Preliminary Results. *International Journal of Communication*, 9, S. 982–1001.
- Suh, B., Hong, L., Pirolli, P., & Chi, E. (2010). Want to be Retweeted? Large Scale Analytics on Factors Impacting Retweet in Twitter Network. *IEEE International Conference on Privacy, Security, Risk and Trust*, (S. 177-184). Palo Alto, CA, U.S.A. doi:10.1109/SocialCom.2010.33
- Svozil, D., Kvasnicka, V., & Pospichal, J. (1997). Introduction to multi-layer feed-forward neural networks. *Chemometrics and Intelligent Laboratory Systems*, 39(1), S. 43-62. doi:10.1016/S0169-7439(97)00061-0
- Thelwall, M., Buckley, K., & Paltoglou, G. (2011). Sentiment in Twitter Events. *Journal of the American Society for Information Science and Technology*, 62(2), p. 406–418. doi:10.1002/asi.21462
- Trepte, S., & Scherer, H. (2010). Opinion leaders - Do they know more than others about their area of interest? (W. d. Gruyter, Hrsg.) *Communications*, 35. doi:10.1515/COMM.2010.007
- Tumasjan, A., Sprenger, T., Sandner, P., & Welpe , I. (2010). Predicting Elections with Twitter: What 140 Characters Reveal about Political Sentiment. *Proceedings of the Fourth International AAAI Conference on Weblogs and Social Media* (S. 178–185). Association for the Advancement of Artificial Intelligence. Abgerufen am 25. Oktober 2017 von <https://www.aaai.org/ocs/index.php/ICWSM/ICWSM10/paper/viewFile/1441/1852>
- United Nations Foundation. (2013). *United Nations Foundation*. Tratto il giorno 6. Februar 2018 da United Nations Foundation: <http://www.unfoundation.org/>
- Valente, T., & Pumpuang, P. (2007). Identifying Opinion Leaders to Promote Behavior Change. *Health Education & Behavior*, 34(6), S. 881-896. doi:10.1177/1090198106297855

- Vergeest, L. (2014). *Using N-grams and Word Embeddings for Twitter Hashtag Suggestion*. Tilburg: Tilburg University.
- Winter, S., & Neubaum, G. (2016). Examining Characteristics of Opinion Leaders in Social Media: A Motivational Approach. *Social Media + Society*, p. 1-12. doi:10.1177/2056305116665858
- Xu, W., Sang, Y., Blasiola, S., & Park, H. (2014). Predicting Opinion Leaders in Twitter Activism Networks: The Case of the Wisconsin Recall Election. *American Behavioral Scientist*, 58(10), S. 1278–1293. doi:10.1177/0002764214527091
- Zhu, L. (2017). A novel social network measurement and perception pattern based on a multi-agent and convolutional neural network. *Computers and Electrical Engineering*, 000, S. 1-17. doi:10.1016/j.compeleceng.2017.05.019
- Zubiaga, A., Spina, D., Martínez, R., & Fresno, V. (2015). Real-Time Classification of Twitter Trends. *Journal of the Association for Information Science and Technology*, 66(3), S. 462–473. doi:10.1002/asi.23186

Anhang A

Twitter Advanced Search

Mit der “Twitter Advanced Search” (Verfügbar unter der URL: <https://twitter.com/search-advanced?lang=de>) kann sehr flexibel und ohne Programmierarbeit nach Twitter Datensätzen gesucht werden.

The screenshot shows the Twitter Advanced Search interface. At the top, there are navigation links: Startseite, Mitteilungen, Nachrichten, a Twitter icon, and a search bar labeled "Twitter durchsuchen". To the right of the search bar is a user profile icon and a blue "Twitter" button. The main area is titled "Erweiterte Suche". It is divided into several sections:

- Wörter**:
 - Alle diese Wörter:
 - Genau dieser Satz:
 - Irgendeines dieser Wörter:
 - Keines dieser Wörter:
 - Diese Hashtags:
 - Geschrieben in:
- Personen**:
 - Von diesen Accounts:
 - An diese Accounts:
 - Diese Accounts erwähnen:
- Orte**:
 - Nahe dieses Standortes: [Standort hinzufügen](#)
- Daten**:
 - Von diesem Datum an: bis

At the bottom left is a blue "Suchen" button.

Abbildung 11: Twitter Advanced Search Maske

Anhang B

Apigee API Console

Eine eigene Twitter-App (<https://apps.twitter.com/app/14314956>) wurde registriert mit einer Verbindungsauthentisierung mittels Public/Private-Keys über OAuth²². Mit diesem Zugang war es auch möglich, eigene Anwendungen zu entwickeln, die Daten von Twitter beziehen welche notwendig für das Projekt sind. Die Apigee Console ermöglicht – sofern eine eigene Anwendung für Twitter registriert ist (hier in Abbildung 12 wird die Verbindung mittels der Anwendung mit der ID «twitter-JaniceB07542310» hergestellt) – den Zugang zu allen Twitter Programmierschnittstellen (API Methods). Es sind bei diesen Schnittstellen, wo Daten von Twitter aus gewonnen werden können.

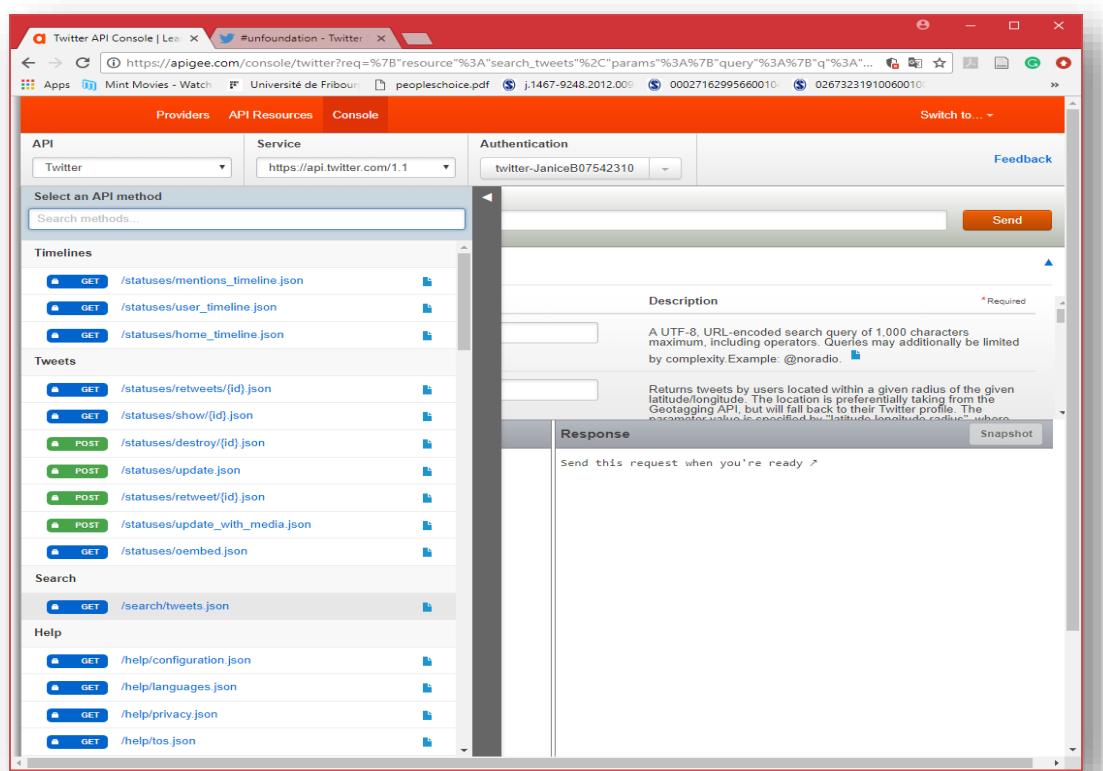


Abbildung 12: Apigee API Console, Selektion der Methode

²² Alle Anwendungen, welche die Twitter-API verwenden, müssen sich identifizieren und autorisieren lassen. Dies erfolgt mit dem Open Source Library OAuth und Keys, die von Twitter bereitgestellt werden.

Die Twitter REST-Schnittstelle bedeutet, dass die Query aus der URL-Zeile des Browsers (s. Abbildung 13) entnommen, und an einer anderen Stelle (Abbildung 14) eingesetzt werden kann, um ausführliche Twitter-Daten (der «Response» in json-Format) zur weiteren, programmatischen Verwendung zu erhalten.

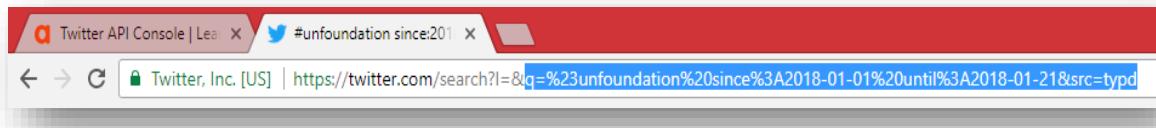


Abbildung 13: Twitter Advanced Search (Suchbegriff)

The screenshot shows the Apigee API Console interface. The top navigation bar includes 'Providers', 'API Resources', 'Console' (which is selected), and 'Feedback'. Below this, there are dropdown menus for 'API' (set to 'Twitter'), 'Service' (set to 'https://api.twitter.com/1.1'), and 'Authentication' (set to 'twitter-JaniceB07542310').

In the main area, under 'Request URL', a GET request is shown with the URL: <https://api.twitter.com/1.1/search/tweets.json?q=%23unfoundation%20since%3A2018-01-01%20until%3A2018-01-21&src=typd>. The 'Query' tab is selected in the 'Headers' section.

The 'Request' section contains the raw HTTP request:

```
GET /1.1/search/tweets.json?
q=%23unfoundation%20since%3A2018-01-01%20until%3A2018-
01-21&src=typd
Authorization: OAuth
oauth_consumer_key="DC0sePOBbQ8bydC8r4Smg";
oauth_signature=
SHA1";
oauth_timestamp="1516555351";
oauth_nonce="+11wcbMDT01sIXvxzr0q4fYnuBcsAb";
oauth_signature="kmedbsd1K
Host: api.twitter.com
x-target-uri: https://api.twitter.com
Connection: Keep-Alive
```

The 'Response' section shows the raw JSON response from Twitter:

```
HTTP/1.1 200 OK
x-frame-options: SAMEORIGIN
x-rate-limit-remaing: 179
last-modified: Sun, 21 Jan 2018 17:22:31 GMT
status: 200 OK
Content-Length: 65948
x-response-time: 162
Connection: keep-alive
x-transaction: 00da6aed00b18b40
Server: tsa_b
pragma: no-cache
cache-control: no-cache, no-store, must-revalidate, pre-check=0,
post-check=0
x-connection-hash: 63f04d2c386d25ae2d5d9bf02b4e5f01
x-xss-protection: 1; mode=block;
report=https://twitter.com/xss_report
x-content-type-options: nosniff
x-rate-limit-limit: 180
expires: Tue, 31 Mar 1981 05:00:00 GMT
Date: Sun, 21 Jan 2018 17:22:31 GMT
set-cookie:
personalization_id="v1_nLfmmxRrzs6bdTt2y1yvRg=";
Expires=Tue, 21 Jan 2020 17:22:31 UTC; Path=/; Domain=.twitter.com
set-cookie: lang=de; Path=/
set-cookie: guest_id=v1%3A151655535163525686; Expires=Tue, 21 Jan
2020 17:22:31 UTC; Path=/; Domain=.twitter.com
x-rate-limit-reset: 1516556231
content-disposition: attachment; filename=json.json
x-twitter-response-tags: BouncerCompliant
strict-transport-security: max-age=631138519
x-access-level: read-write-directmessages
```

Abbildung 14: Apigee API Console (Ergebnisse eines Suchbegriffes)

Anhang C

MATLAB Entwicklungsumgebung

Die MATLAB Entwicklungsumgebung ermöglicht es, Funktionen und die resultierenden Programme ablaufen zu lassen. Dabei können die Werte von Variablen im Arbeitsbereich (Workspace) jederzeit untersucht werden.

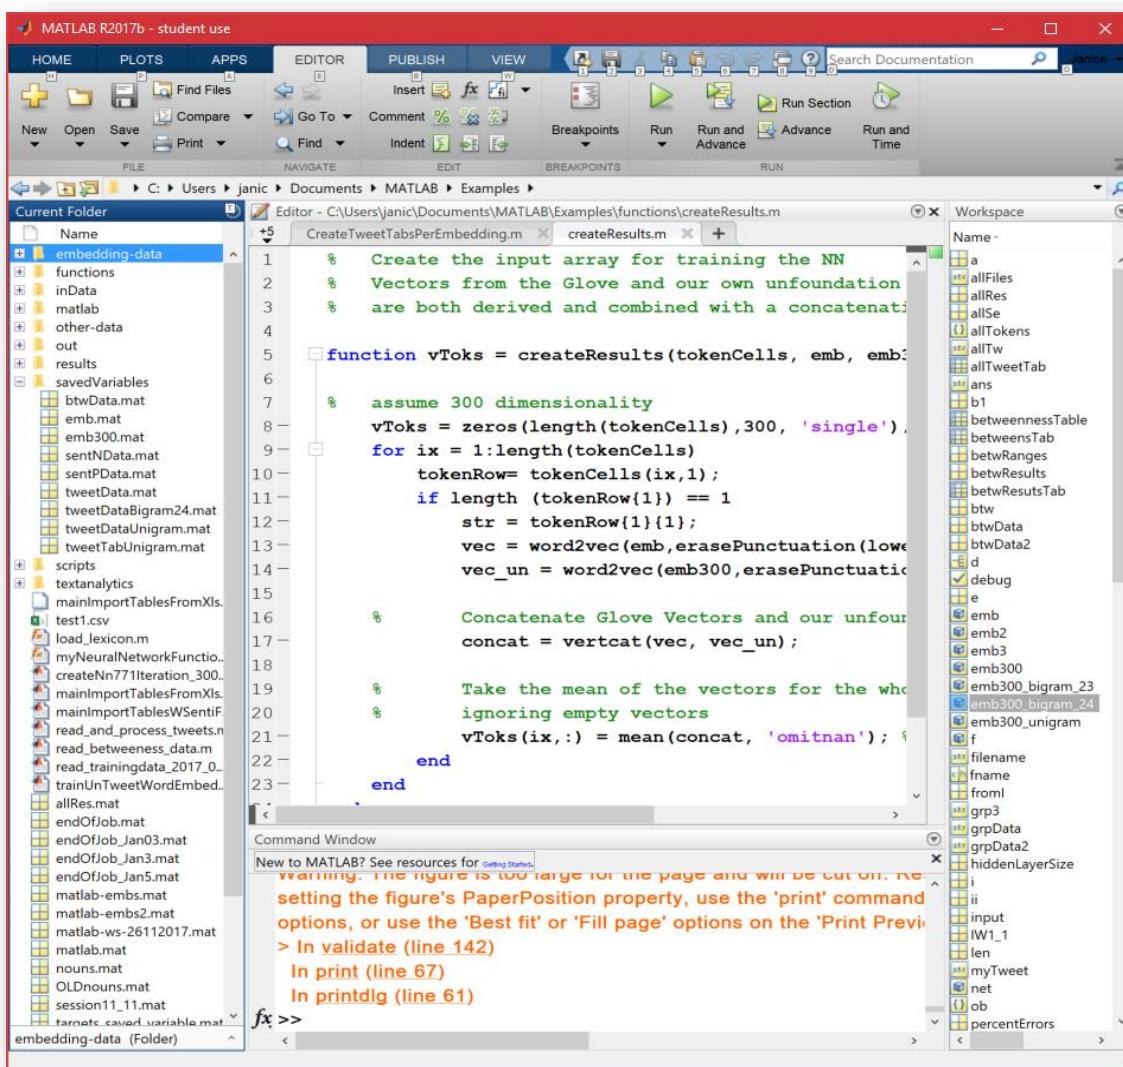


Abbildung 15: Die MATLAB Entwicklungsumgebung

Anhang D

Hier werden weitere numerische Ergebnisse der Netzwerkanalyse von den #unfoundation Daten von 09.11.2017 - 15.11.2017 dargestellt

Gruppierungen

Group	Vertices	Unique Edges	Edges With Duplicates	Total Edges	Self-Loops
G1	557	651	256	907	96
G2	343	559	201	760	26
G3	133	175	58	233	3
G4	95	94	326	420	9
G5	82	141	41	182	2
G6	78	135	71	206	17
G7	77	84	184	268	161
G8	39	33	17	50	50
G9	28	28	0	28	1
G10	24	42	5	47	0
G11	21	37	0	37	1
G12	16	13	6	19	0
G13	14	5	40	45	0
G14	14	39	6	45	0
G15	13	84	0	84	1
G16	12	0	58	58	0
G17	12	9	16	25	1
G18	12	13	0	13	2
G19	11	18	0	18	0
G20	10	9	0	9	0
G21	10	11	2	13	0
G22	9	16	3	19	0
G23	9	9	0	9	1
G24	9	7	16	23	0
G25	9	8	0	8	0
G26	9	9	2	11	0
G27	8	9	0	9	0
G28	8	7	0	7	0
G29	8	8	0	8	1
G30	8	18	0	18	0
G31	8	14	10	24	0
G32	7	9	0	9	1

Group	Vertices	Unique Edges	Edges With Duplicates	Total Edges	Self-Loops
G33	7	0	42	42	0
G34	7	11	0	11	0
G35	7	6	0	6	0
G36	7	13	0	13	0
G37	7	11	0	11	0
G38	6	6	0	6	1
G39	6	10	0	10	1
G40	6	6	0	6	1
G41	5	10	0	10	0
G42	5	2	10	12	0
G43	5	4	0	4	0
G44	4	3	0	3	0
G45	4	3	0	3	0
G46	4	6	0	6	0
G47	4	6	0	6	0
G48	4	5	0	5	0
G49	4	3	0	3	0
G50	4	4	0	4	1
G51	4	4	0	4	0
G52	4	5	0	5	0
G53	3	3	0	3	1
G54	3	2	0	2	0
G55	3	3	0	3	0
G56	3	3	0	3	1
G57	3	2	0	2	0
G58	3	3	0	3	1
G59	3	2	0	2	0
G60	3	3	0	3	0
G61	2	0	4	4	2
G62	2	2	0	2	1
G63	2	2	0	2	1
G64	2	2	0	2	1
G65	2	2	0	2	1
G66	2	2	0	2	1
G67	2	2	0	2	1
G68	2	1	0	1	0
G69	2	2	0	2	1
G70	2	2	0	2	1
G71	2	2	0	2	1
G72	2	2	0	2	1
G73	2	2	0	2	1

Führende Betweenness Zentralitäten

Top 10 Vertices, Ranked by Betweenness Centrality	Betweenness Centrality
unfoundation	2587458.159
global_renewal	139250.9752
un	120586.5684
andreaangulo	47791.20679
assi_duaa	44488
saifsaad80901	43583.18348
nilimajumder	40605.18413
cazacuofelia	32191.14075
who	31613.22601
climatedewed	29026.37688

Führende URLs, Hashtags und Wörter im Netzwerk

Top URLs in Tweet in Entire Graph	Entire Graph Count
https://betterworldcampaign.org/us-un-partnership/public-opinion-polling/	30
https://unoCHA.exposure.co/beyond-lifesaving-aid-in-chad?utm_content=bufferd6cae&utm_medium=social&utm_source=twitter.com&utm_campaign=buffer	29
http://unfoundationblog.org/reproductive-health-rights-age-inequality/	29
http://unfoundationblog.org/americans-un-meet-virginian-protecting-vulnerable-children/	22
https://fundraise.unfoundation.org/team/140140	13
https://shar.es/1PaNmK	9
http://unfoundationblog.org/part-americans-un-project-share-stories-americans-work-united-nations-talked-sean-kane-works-department-political-affairs/	8
https://www.instagram.com/p/BbAVGQZA7EI/?taken-by=climasphere	8
https://www.facebook.com/unitednationsfoundation/videos/10156079319145934/	8
http://unfoundationblog.org/focusing-talent-can-help-fight-hiv/	8

	Entire Graph Count
Top Domains in Tweet in Entire Graph	
twitter.com	731
unfoundationblog.org	77
facebook.com	34
exposure.co	30
betterworldcampaign.org	30
unfoundation.org	25
instagram.com	20
youtube.com	16
fb.me	12
globaldaily.com	10

	Entire Graph Count
Top Hashtags in Tweet in Entire Graph	
#uniting4climate	350
#eyeonclimate	338
#climateaction	325
#climatechange	282
#cop23	262
#climate	105
#walktogether	86
#rohingya	76
#education	69
#globalgoals	62

	Entire Graph Count
Top Words in Tweet in Entire Graph	
Words in Sentiment List#1: Positive	1625
Words in Sentiment List#2: Negative	830
Words in Sentiment List#3: Angry/Violent	2
Non-categorized Words	49033
Total Words	51488
unfoundation	2172
world	417
s	398
climate	368
uniting4climate	350

Top Word Pairs in Tweet in Entire Graph	Entire Graph Count
learn,more	158
show,world	129
climate,change	107
eyeonclimate,instagram	80
around,world	80
global,digital	73
unfoundation,s	73
kid,deserves	72
more,work	72
digital,surge	71

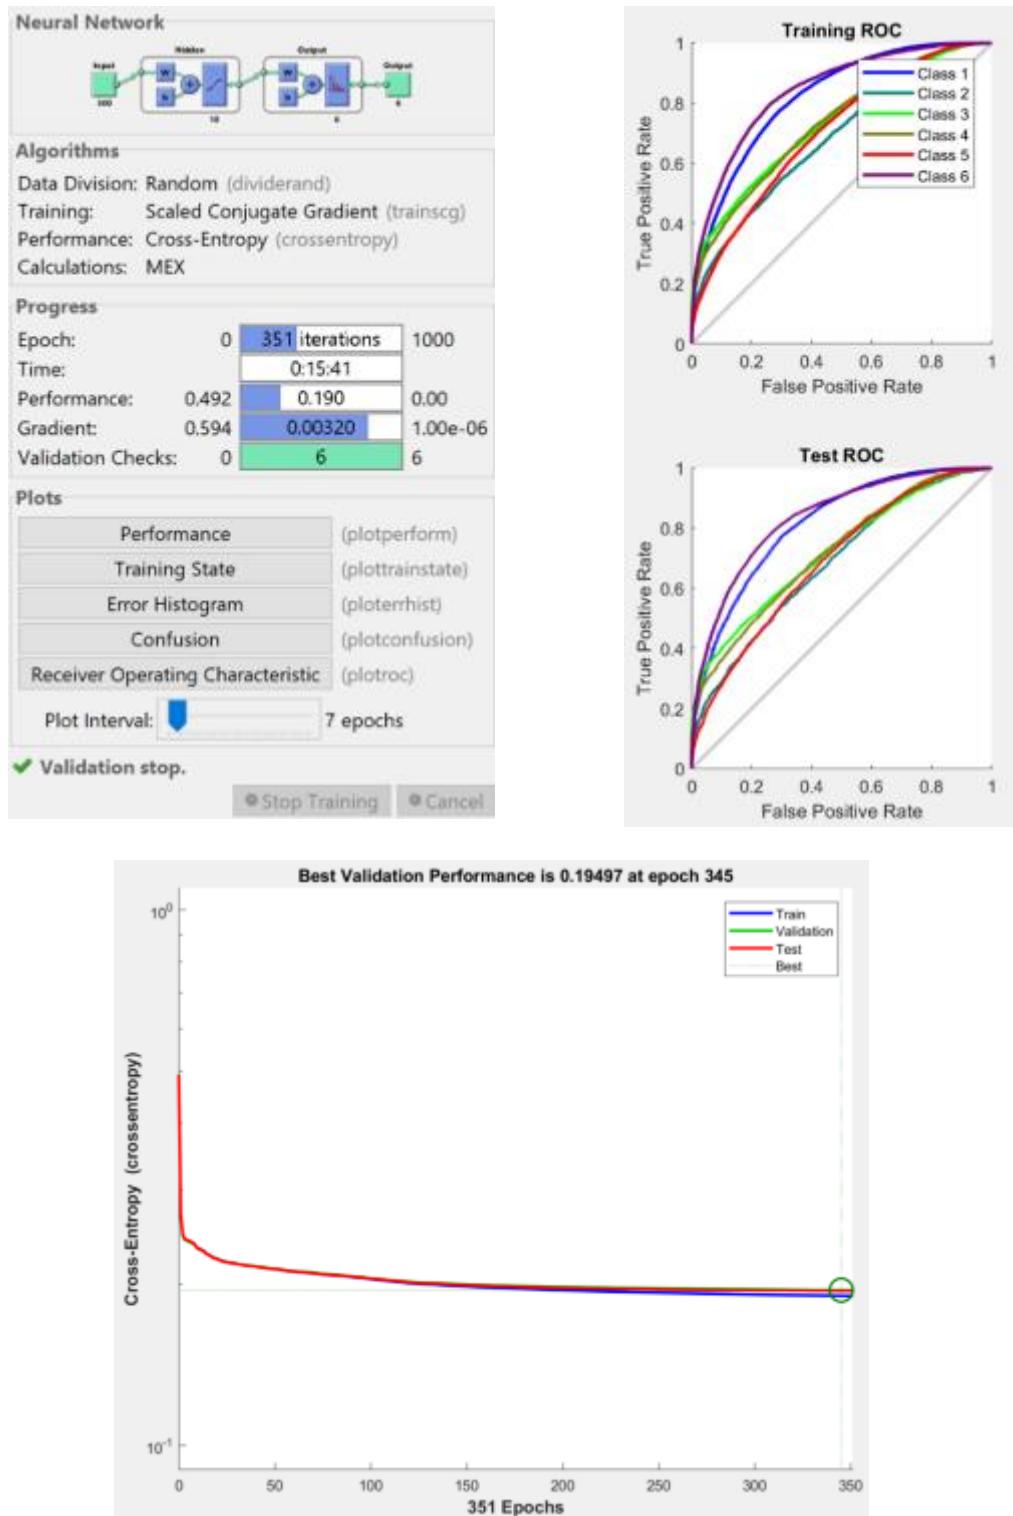
Top Replied-To in Entire Graph	Entire Graph Count
unfoundation	79
un	56
jmaccanada	7
saveaustralia1	4
potus	4
globalgoalsun	3
communityofdem	3
cmtiller	2
kennedy_school	2
unodc	2

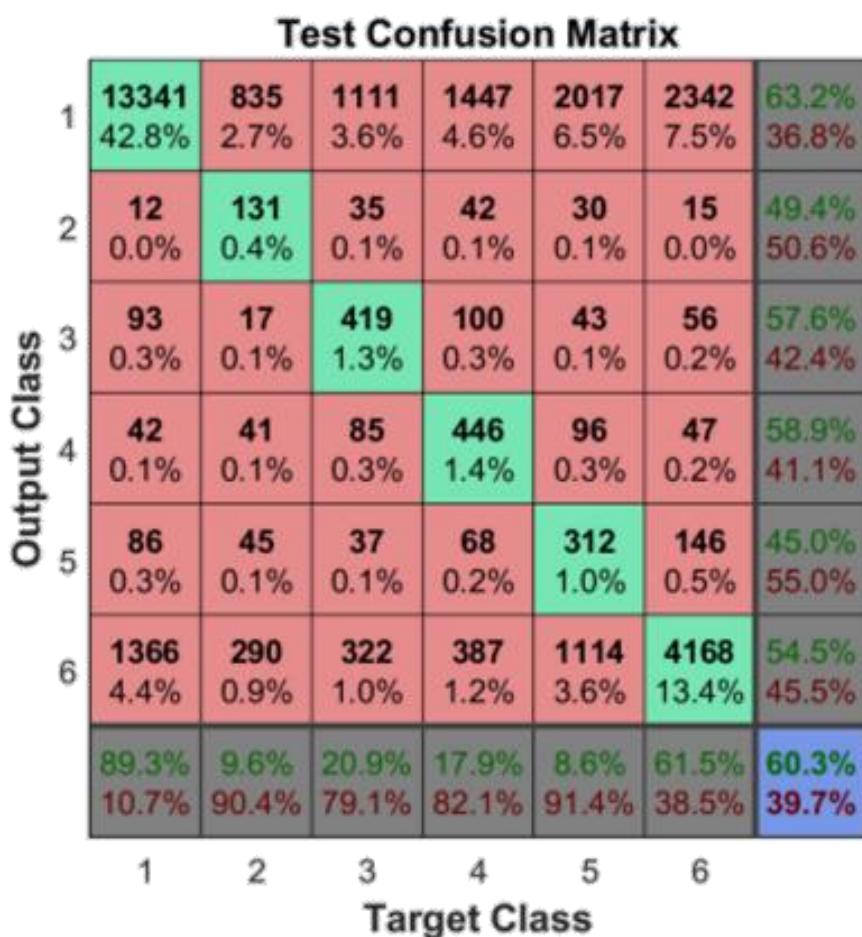
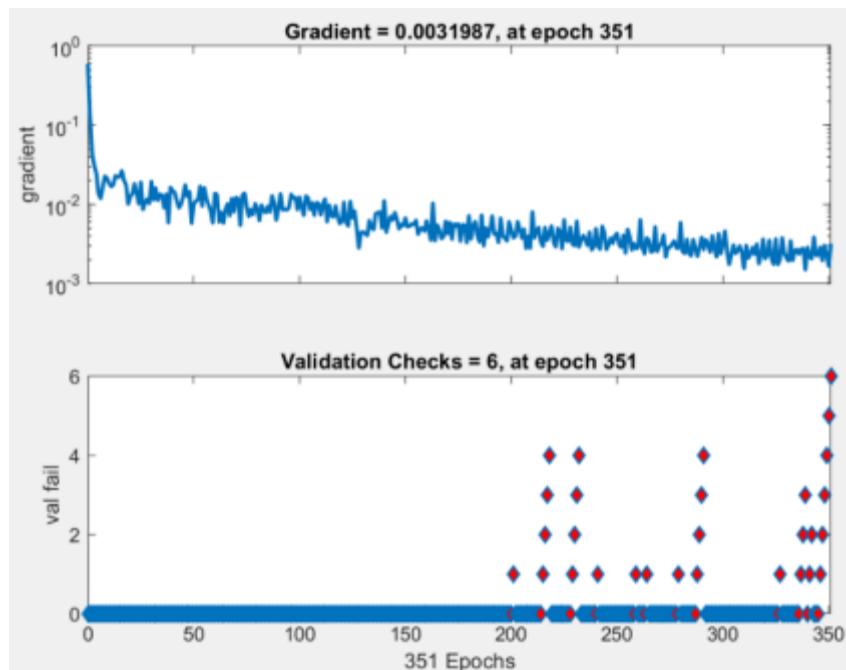
Top Mentioned in Entire Graph	Entire Graph Count
unfoundation	1896
un	346
un_women	117
unfpa	102
who	87
unfccc	78
unep	78
theelders	77
unhumanrights	71
unpeacekeeping	65

Top Tweeters in Entire Graph	Entire Graph Count
scarfizal	940956
socialenbogota	789598
nilimajumder	789280
honeymoongondol	718633
aha1r	710544
ehfoundation237	653769
nodesystems	629639
nneusj	587526
huffpost	492025
beingexample	456619

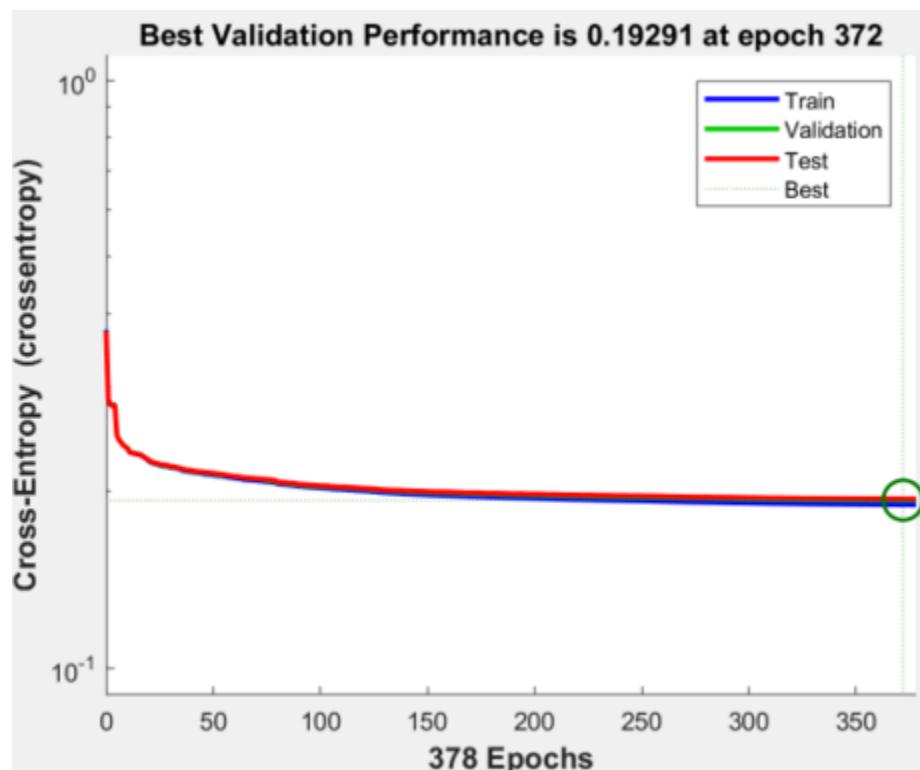
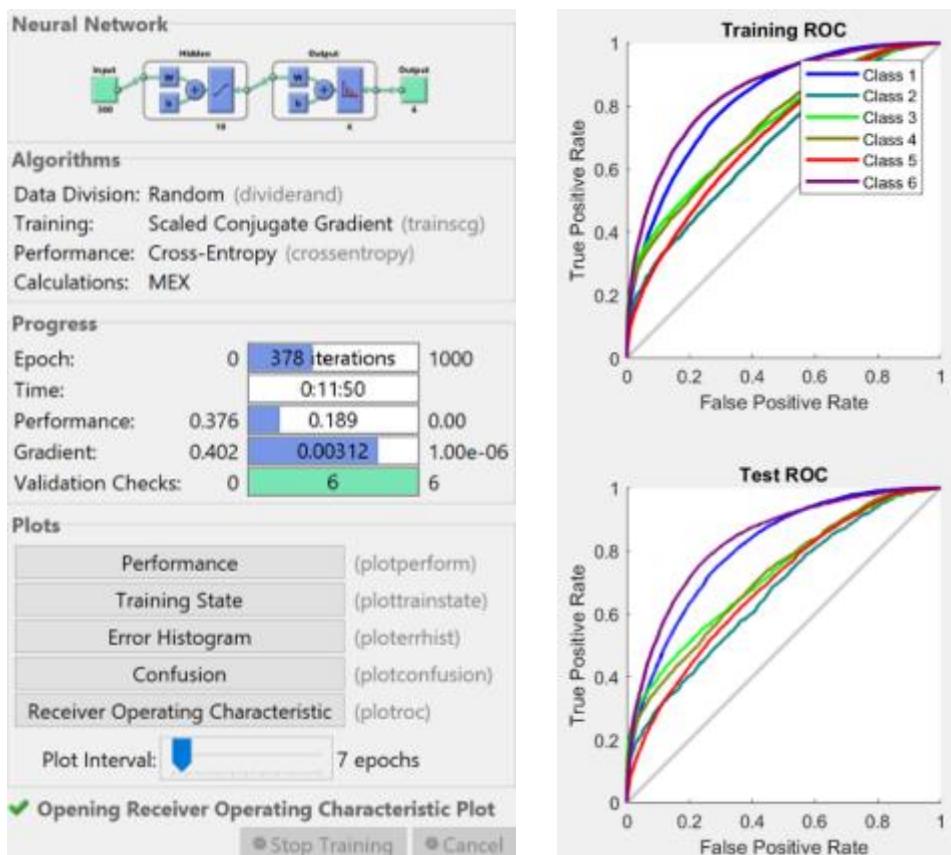
Anhang E

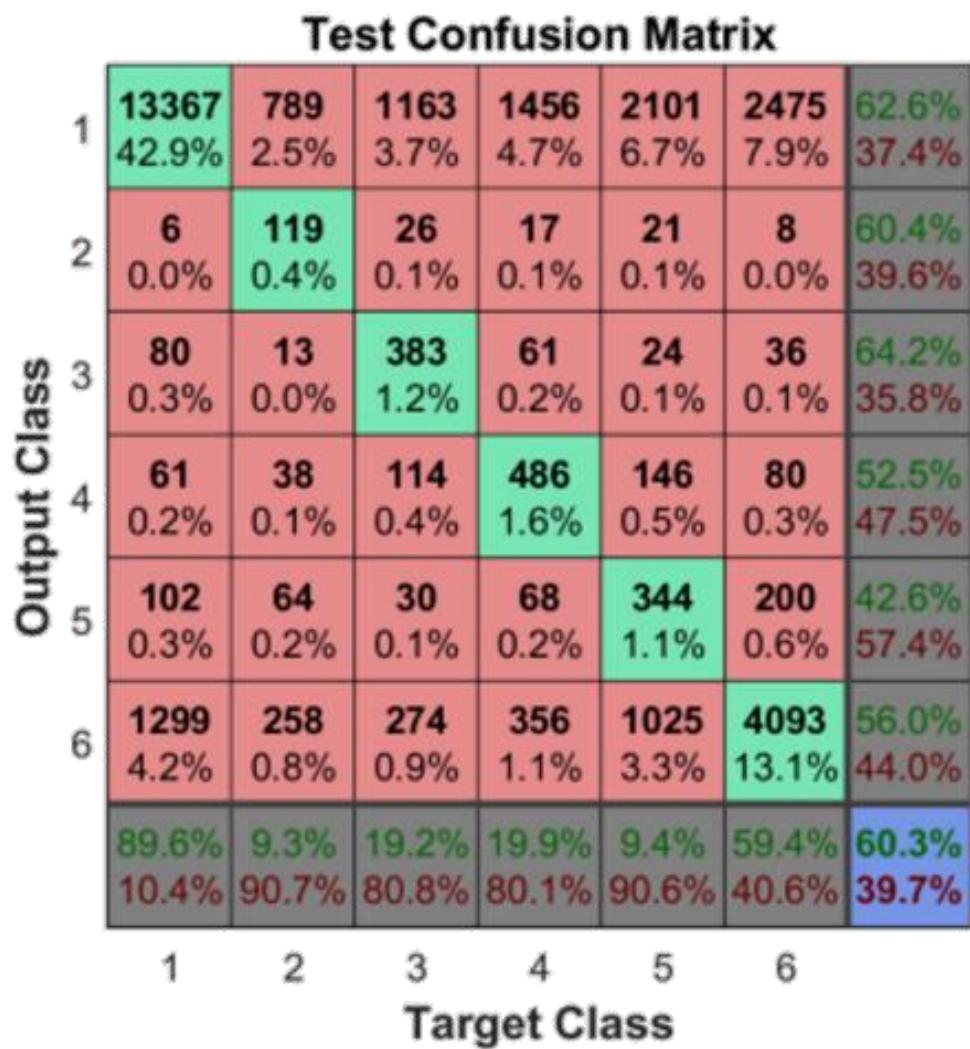
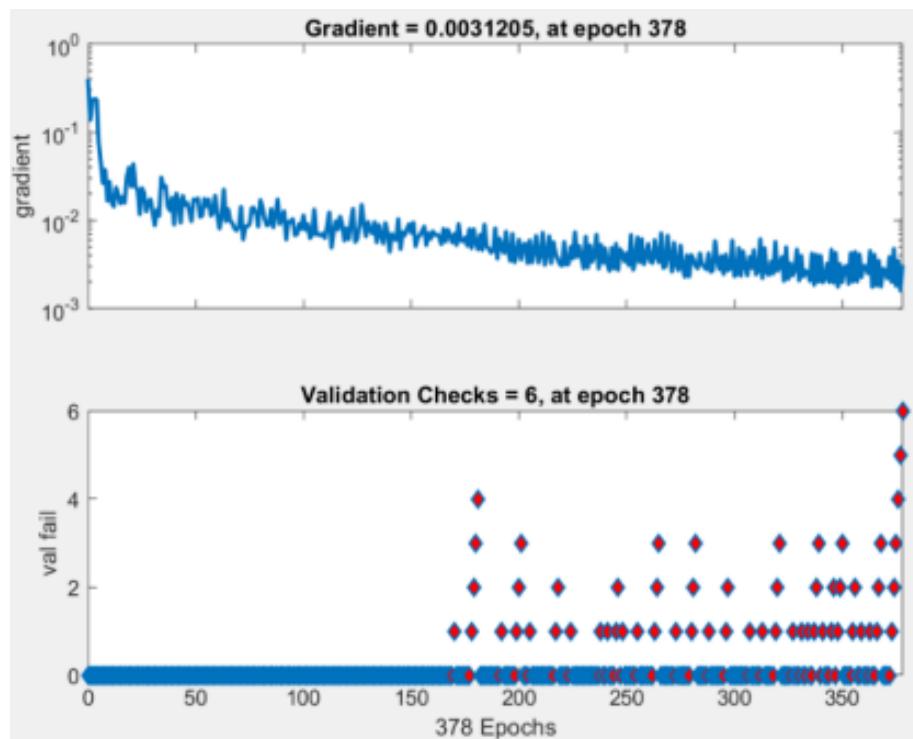
BC1: MLF Training für Betweenness Centrality. Versteckte Layer: 10 Neuronen ,
6 Output C lassen, N-Gram min 1, max 1 (Unigram)





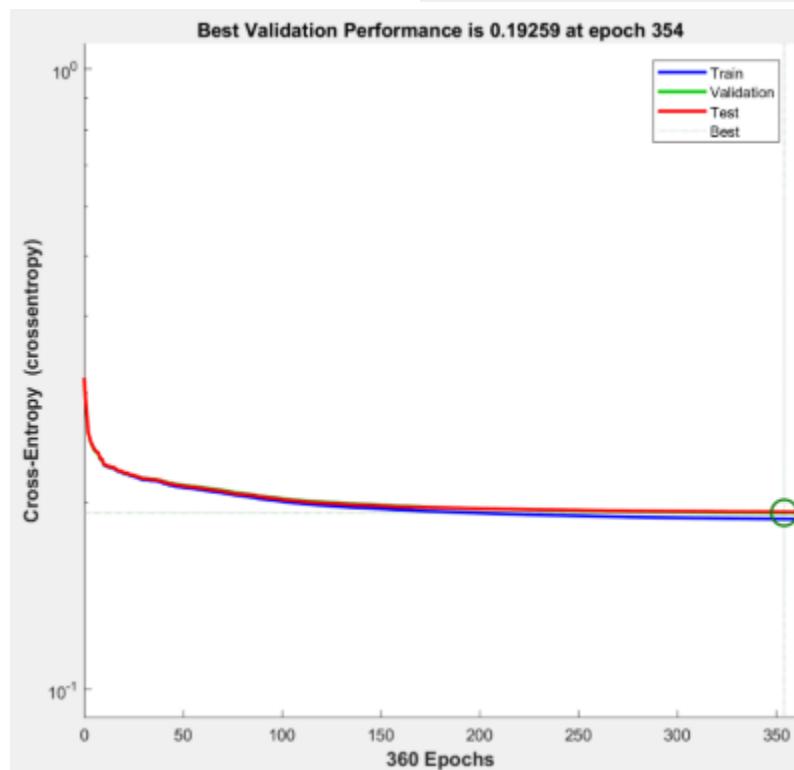
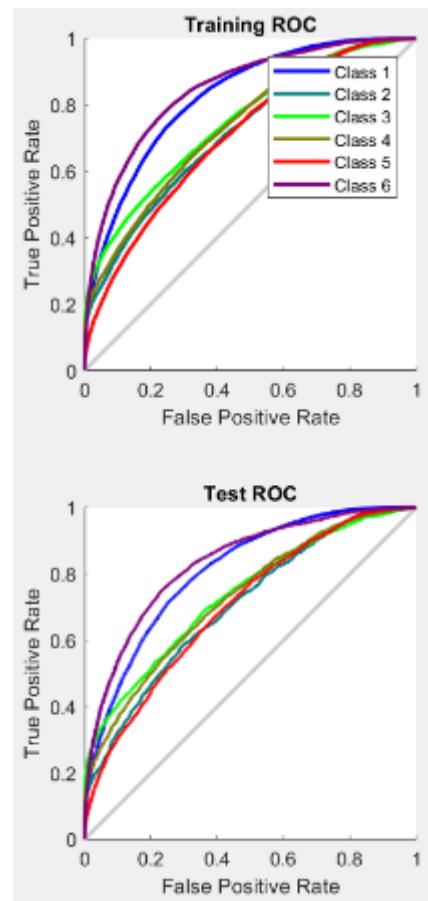
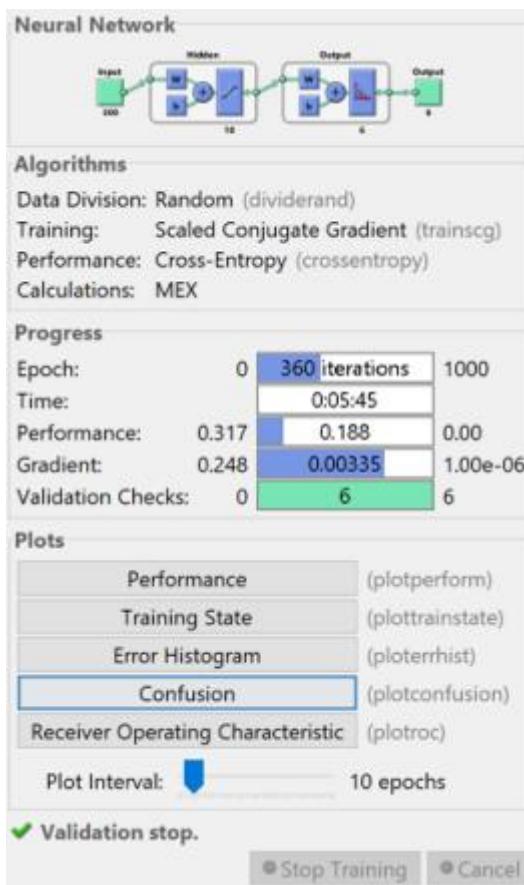
BC2: MLF Training für Betweenness Centrality. Versteckte Layer: 10 Neuronen ,
6 Output C lassen, N-Gram min 2, max 3

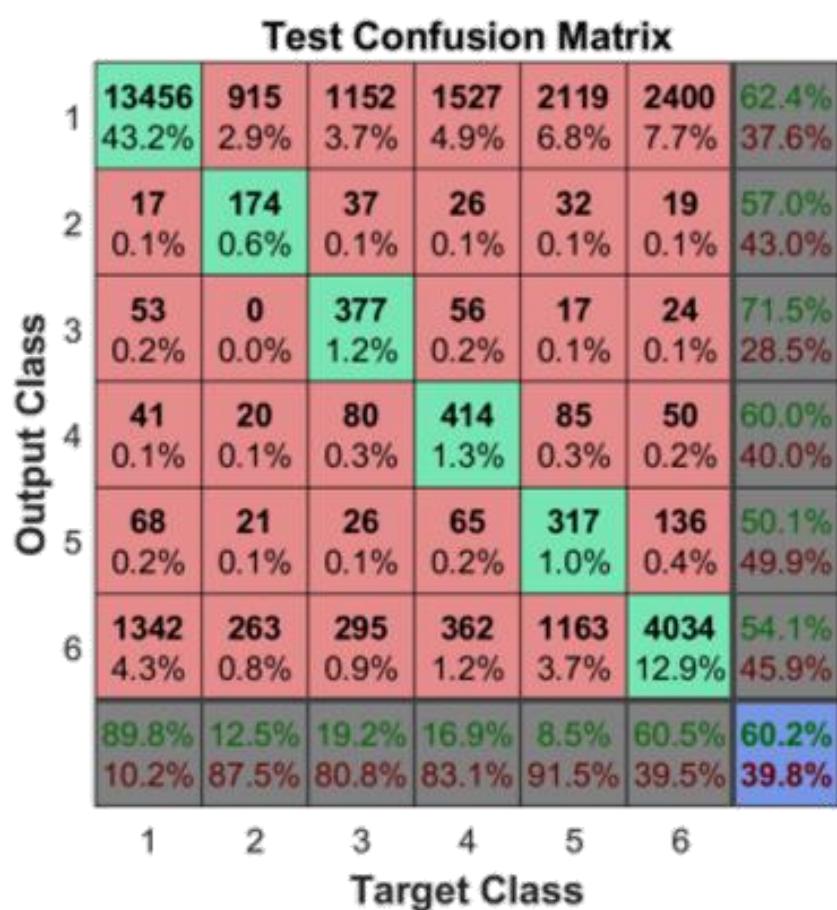
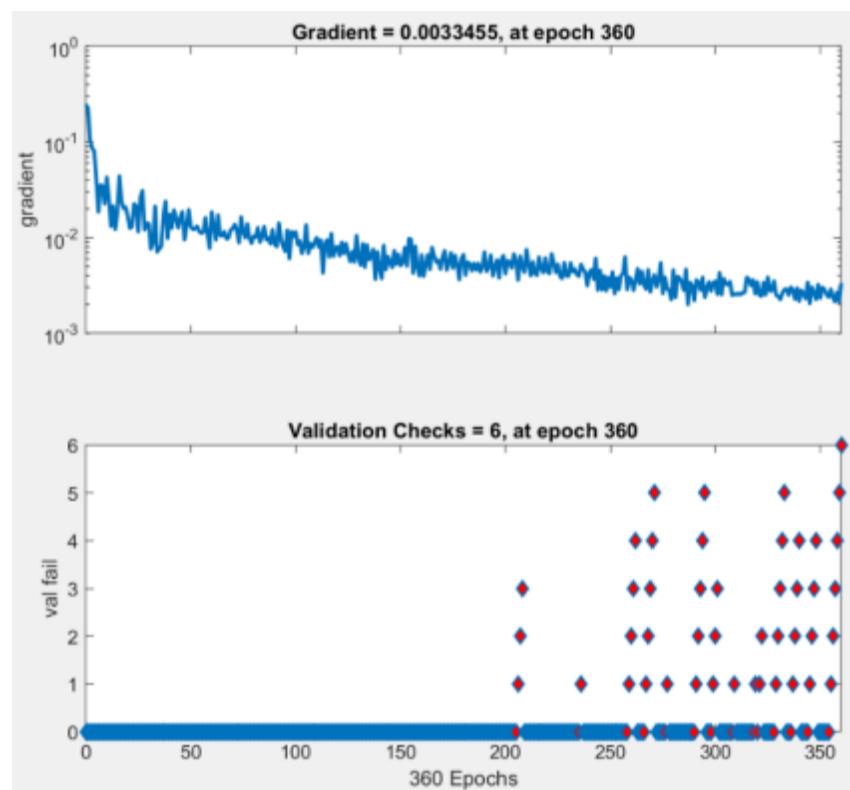




BC3: MLF Training für Betweenness Centrality. Versteckte Layer: 10 Neuronen ,

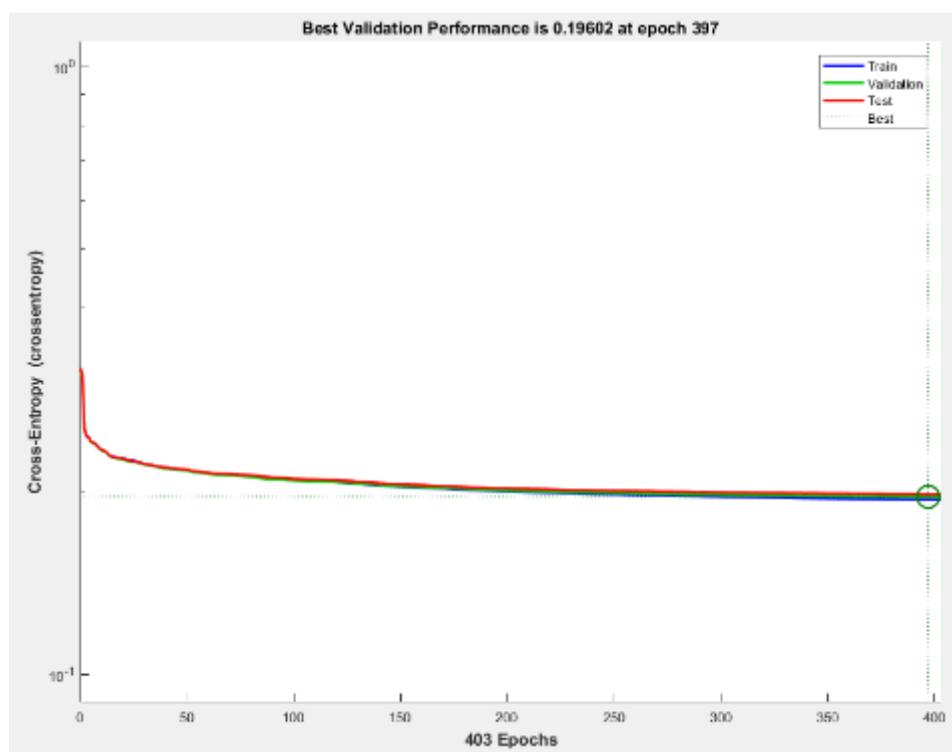
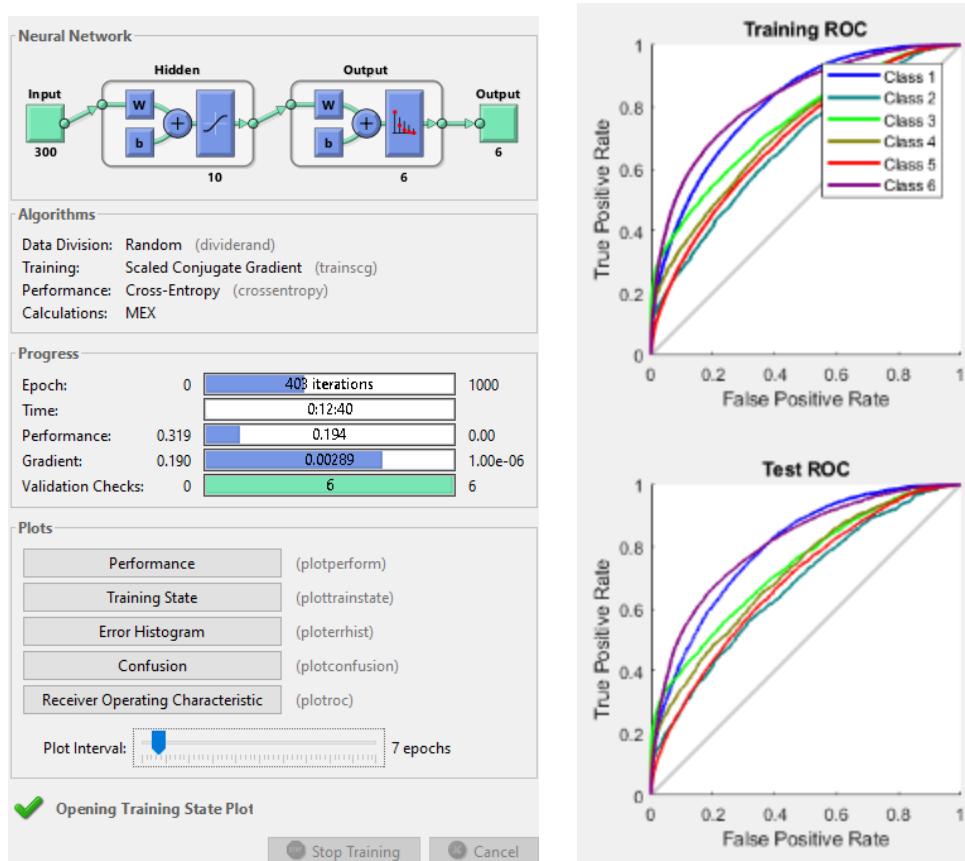
6 Output C lassen, N-Gram min 2, max 4

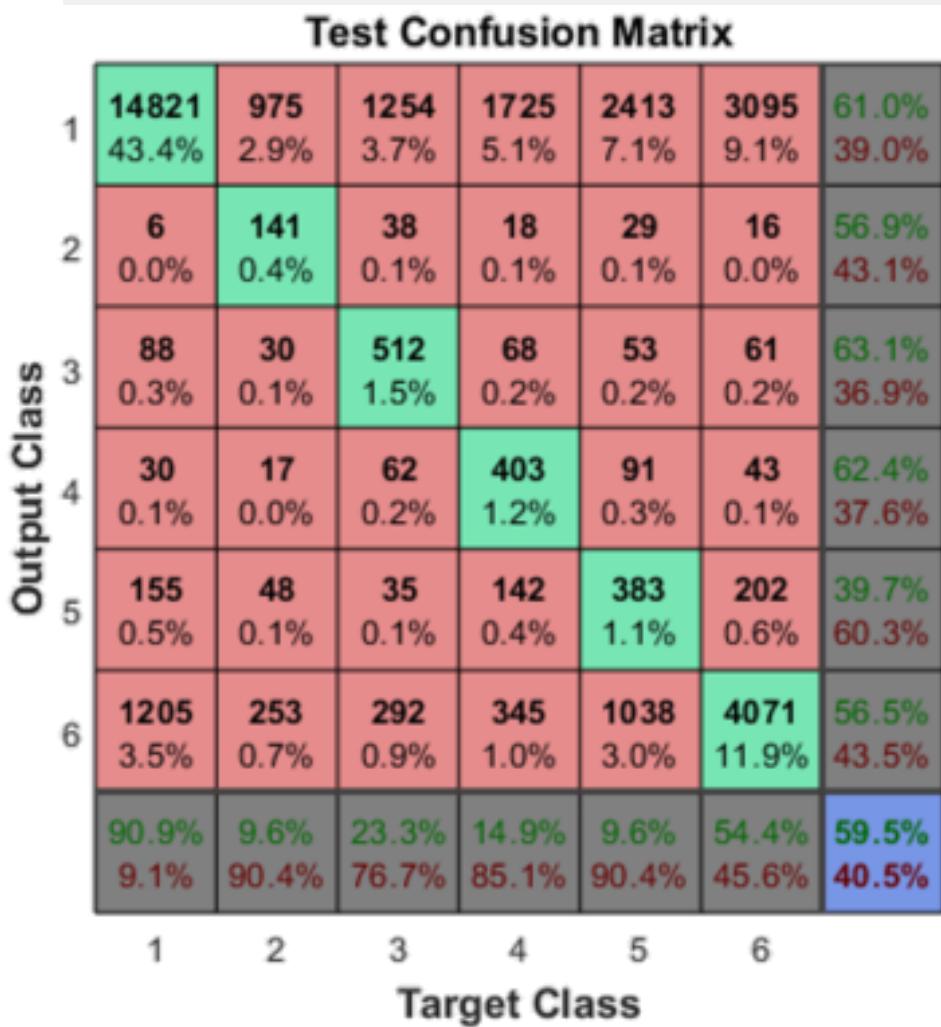
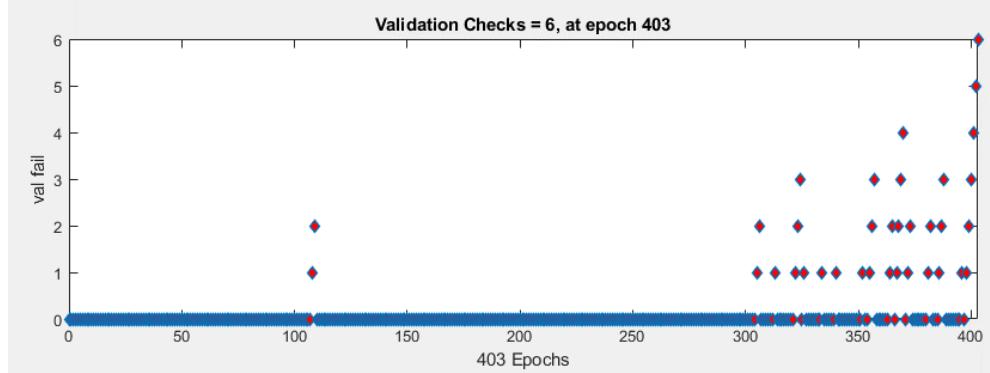
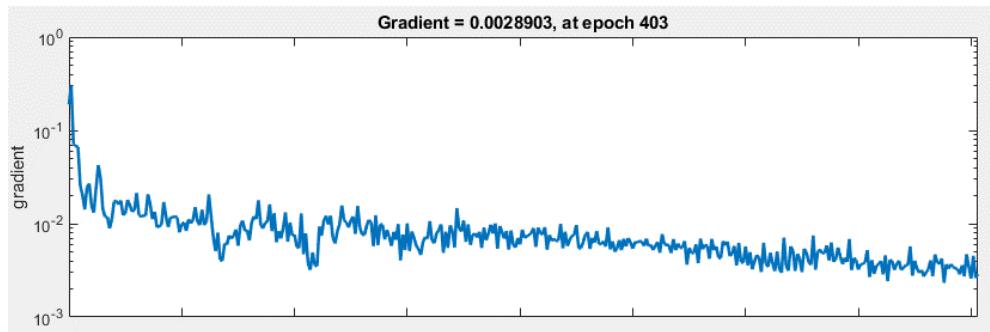




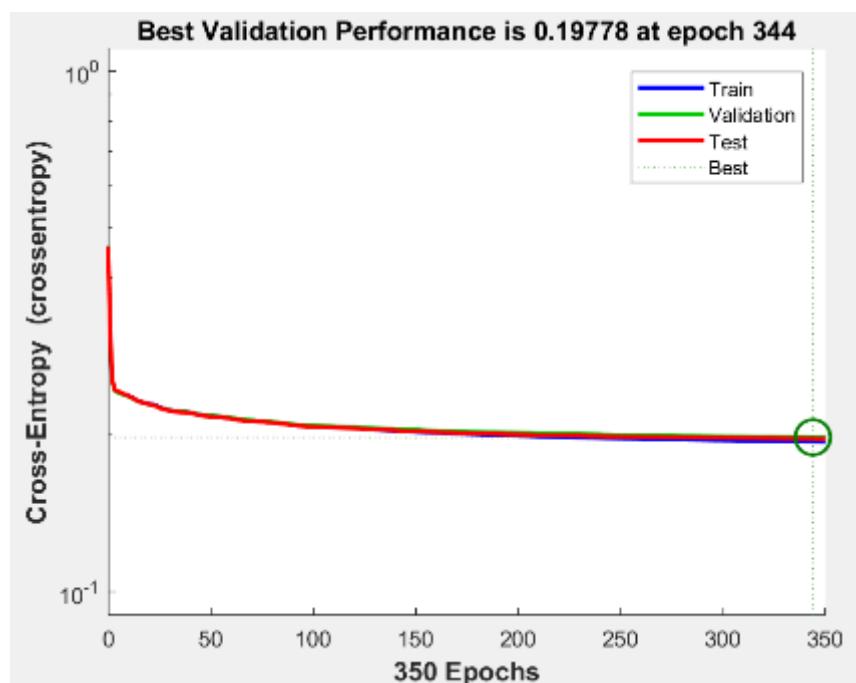
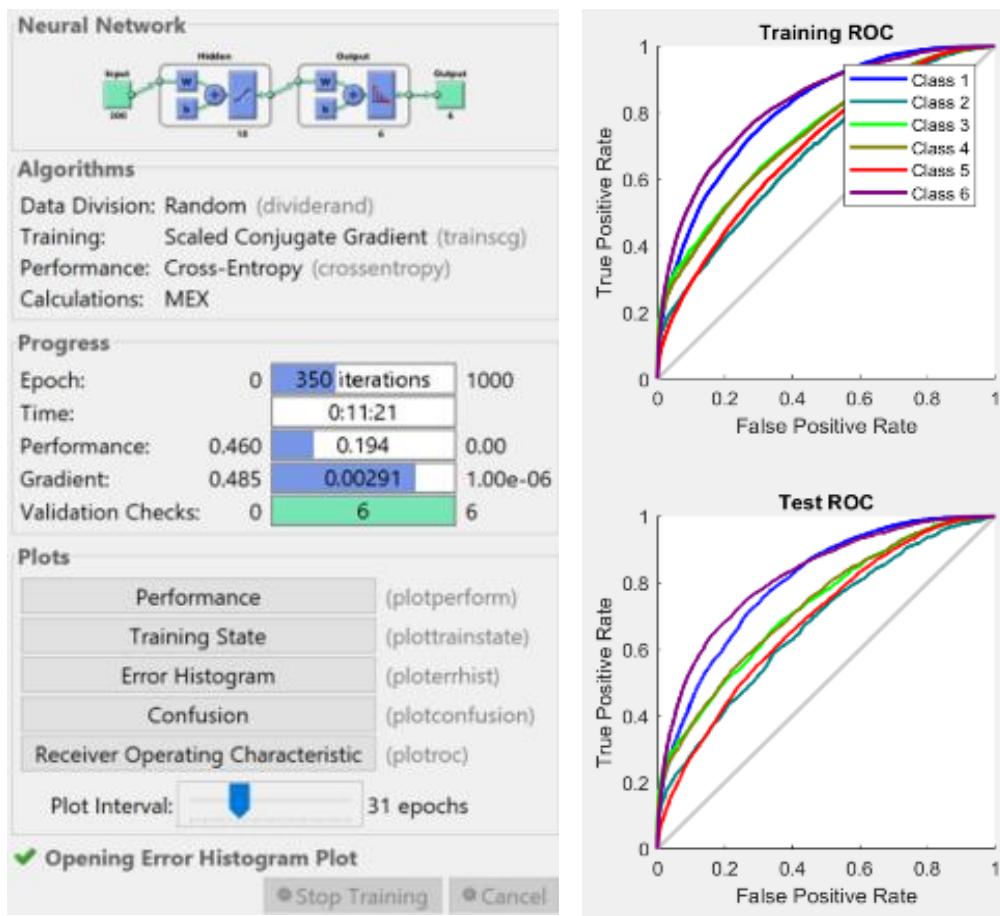
BC4: MLF Training für Betweenness Centrality. Versteckte Layer: 10 Neuronen ,

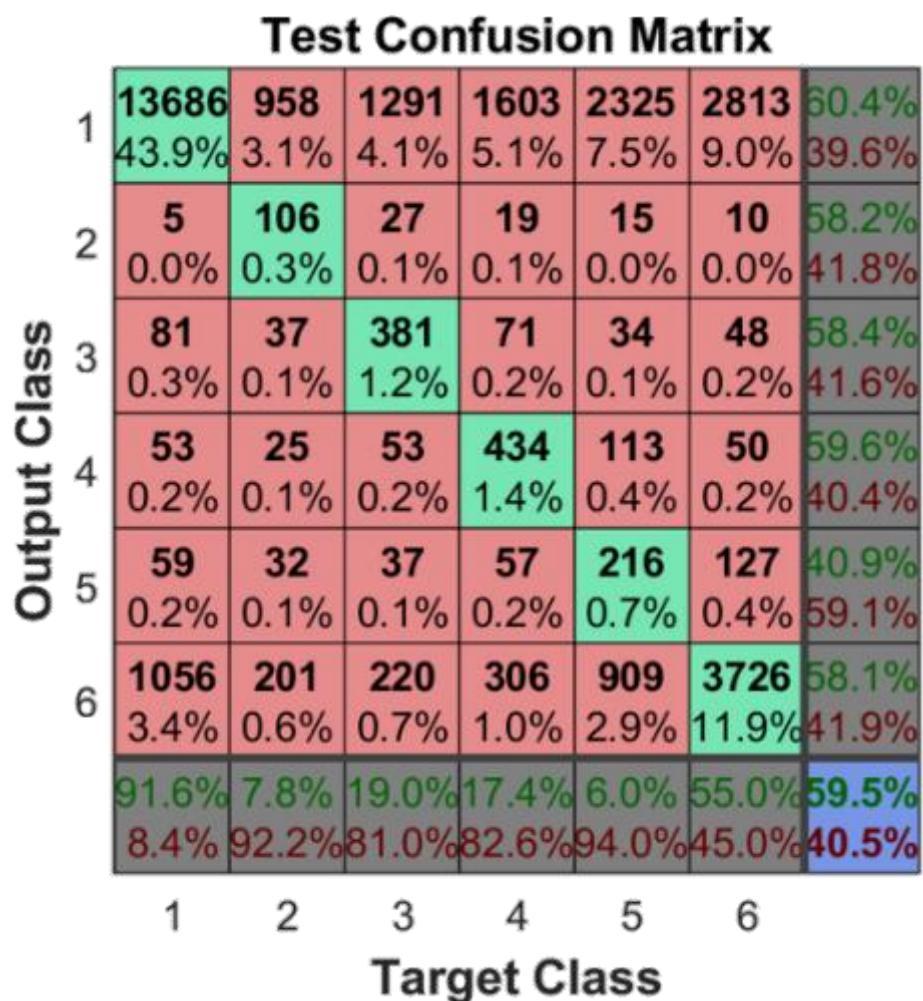
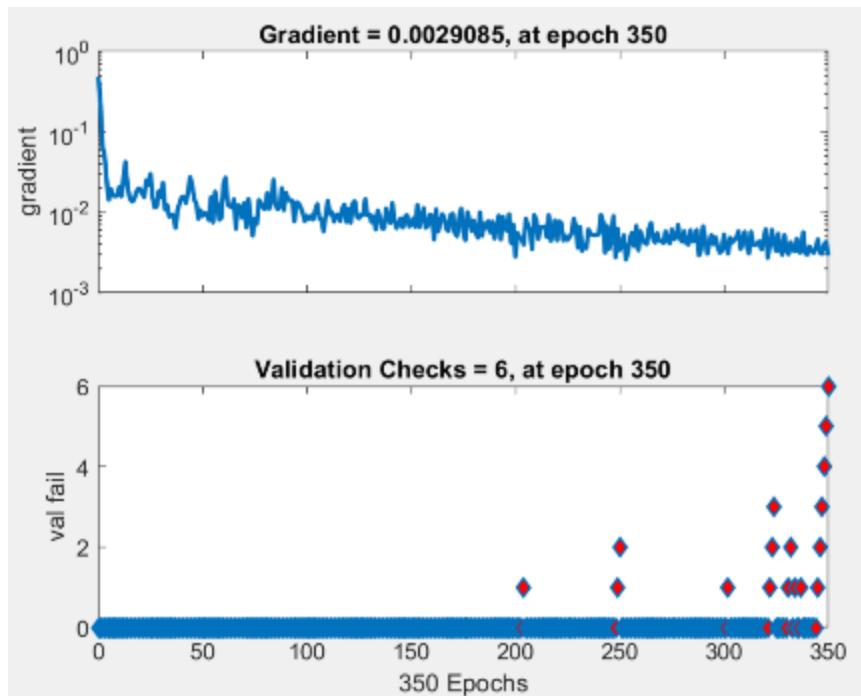
6 Output Classen, N-Gram von min 3, max 6





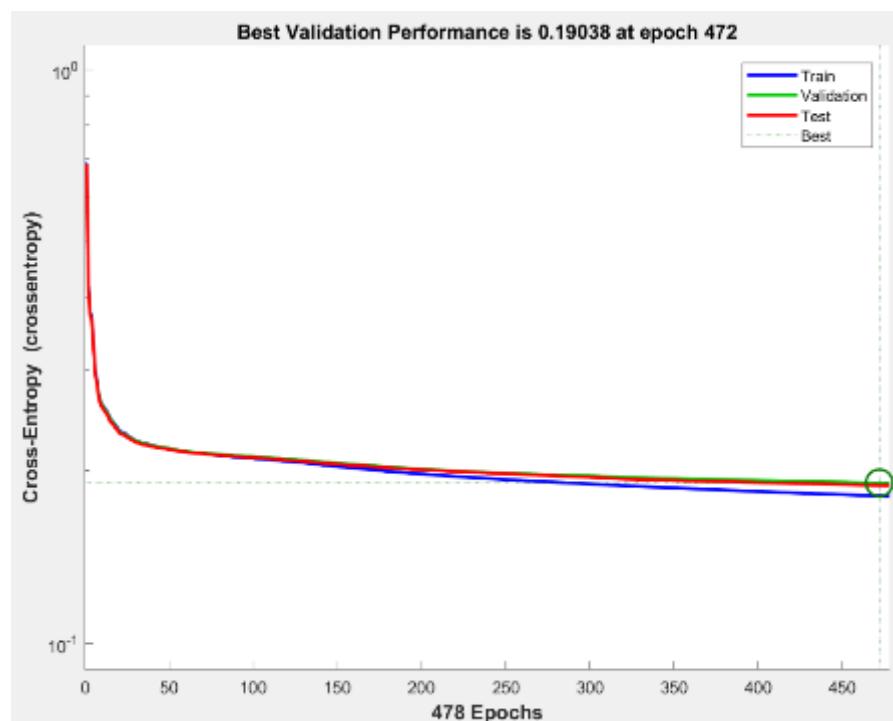
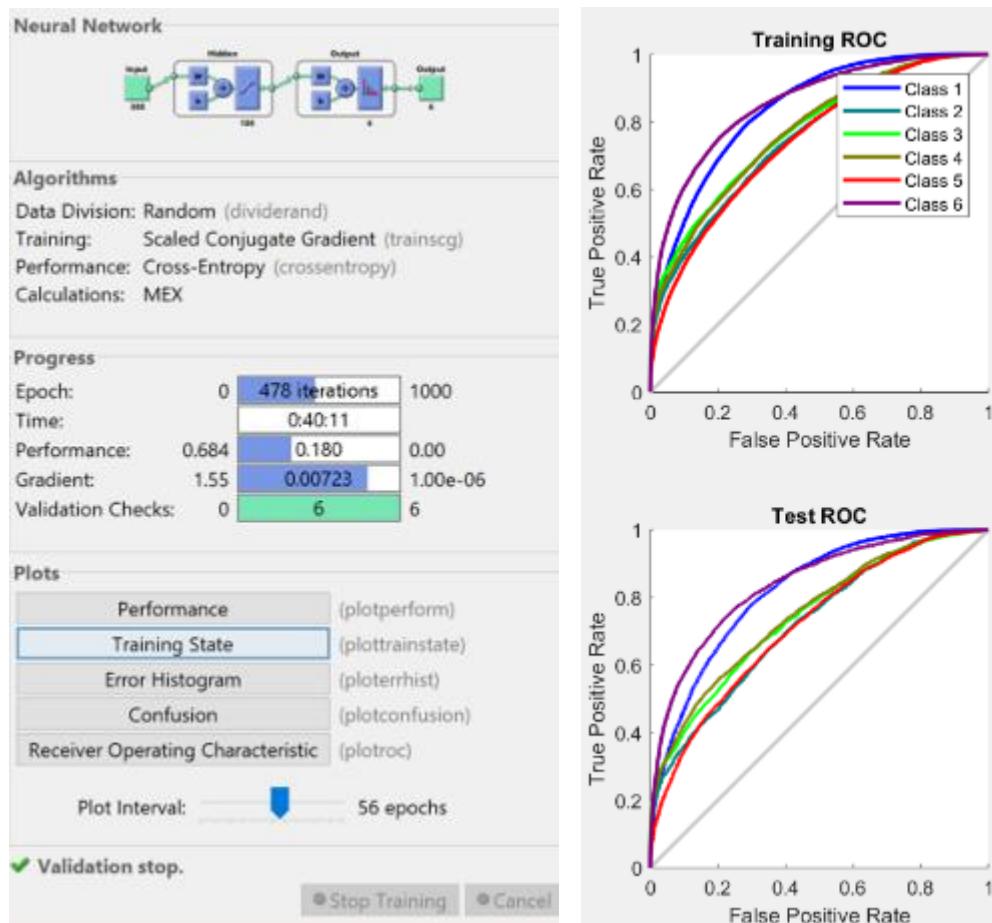
BC5: MLF Training für Betweenness Centrality. Versteckte Layer: 10 Neuronen , 6 Output Klassen, N-Gram von min 3, max 6

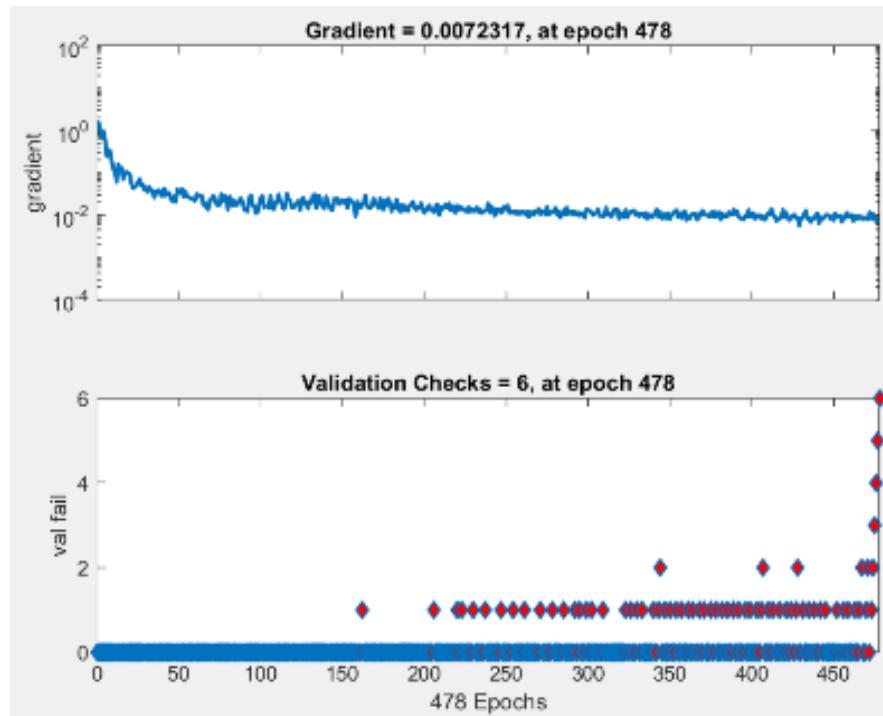




BC6: MLF Training für Betweenness Centrality. Versteckte Layer: 100 Neuronen

, 6 Output C lassen, N-Gram min 3, max 6



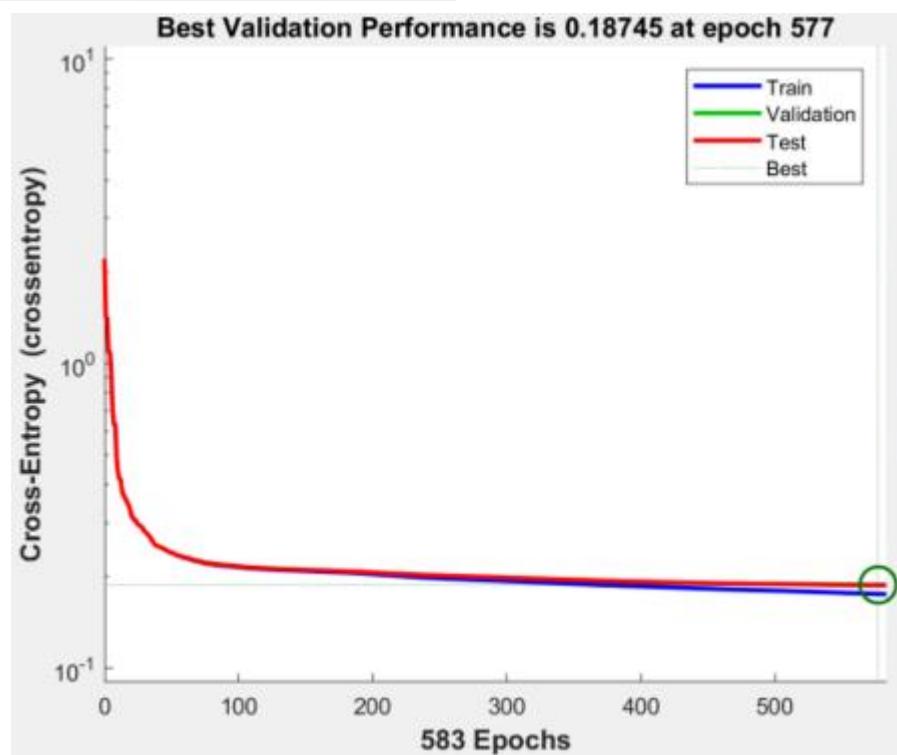
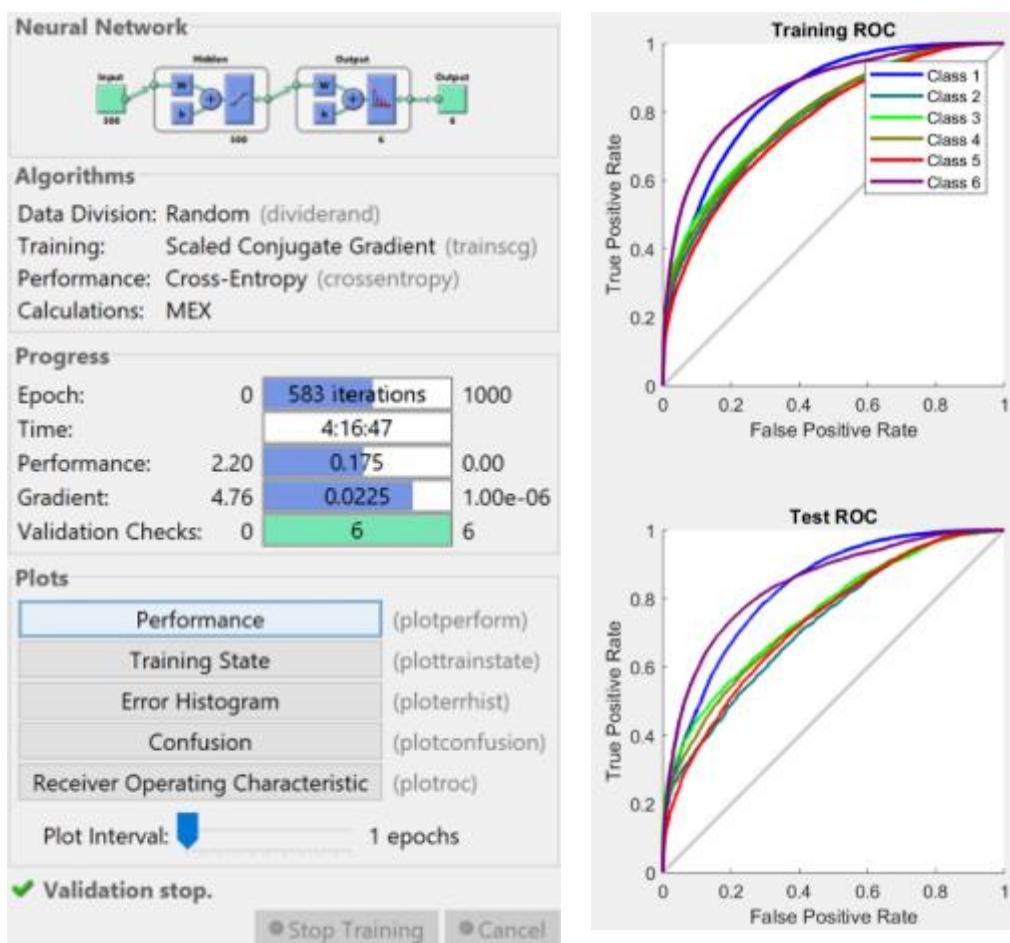


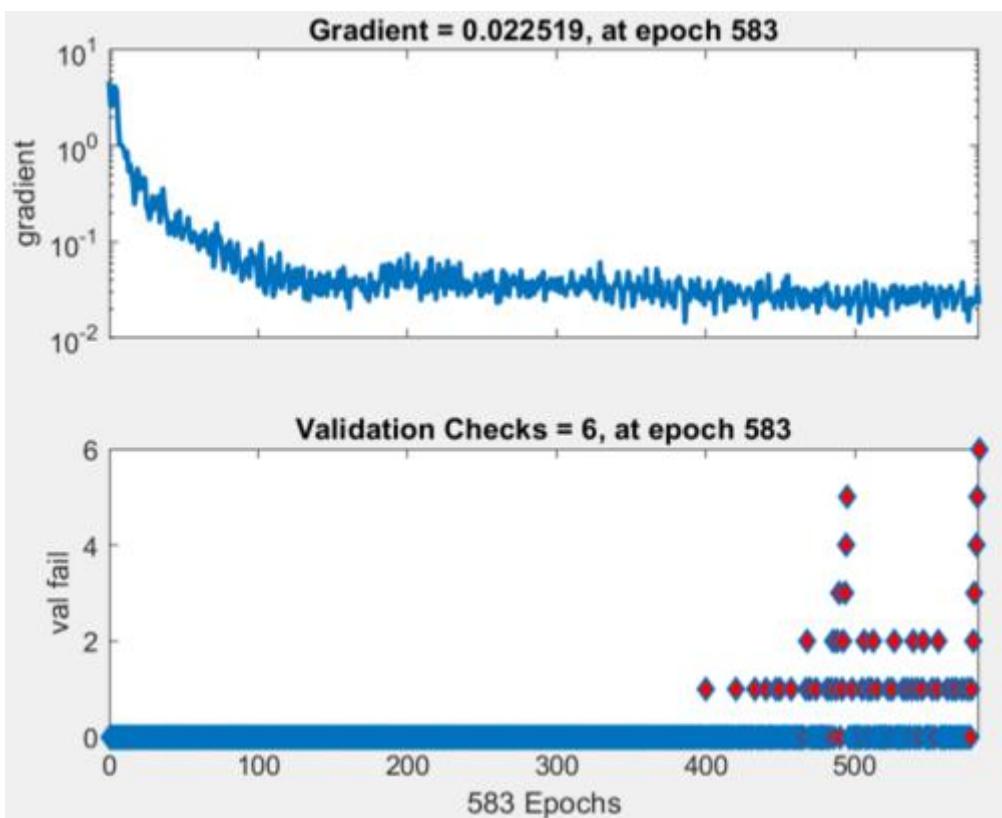
Test Confusion Matrix

Output Class							63.7% 36.3%
	1	2	3	4	5	6	
1	13823 44.3%	809 2.6%	1136 3.6%	1455 4.7%	2033 6.5%	2434 7.8%	63.7% 36.3%
2	46 0.1%	190 0.6%	27 0.1%	26 0.1%	31 0.1%	20 0.1%	55.9% 44.1%
3	21 0.1%	31 0.1%	365 1.2%	67 0.2%	37 0.1%	43 0.1%	64.7% 35.3%
4	60 0.2%	24 0.1%	70 0.2%	503 1.6%	127 0.4%	34 0.1%	61.5% 38.5%
5	199 0.6%	52 0.2%	91 0.3%	133 0.4%	585 1.9%	277 0.9%	43.8% 56.2%
6	1005 3.2%	226 0.7%	269 0.9%	286 0.9%	846 2.7%	3804 12.2%	59.1% 40.9%
	91.2% 8.8%	14.3% 85.7%	18.6% 81.4%	20.4% 79.6%	16.0% 84.0%	57.5% 42.5%	61.8% 38.2%

Target Class

BC7: MLF Training für Betweenness Centrality. Versteckte Layer: 500 Neuronen
, 6 Output Klassen, N-Gram von min 3, max 6

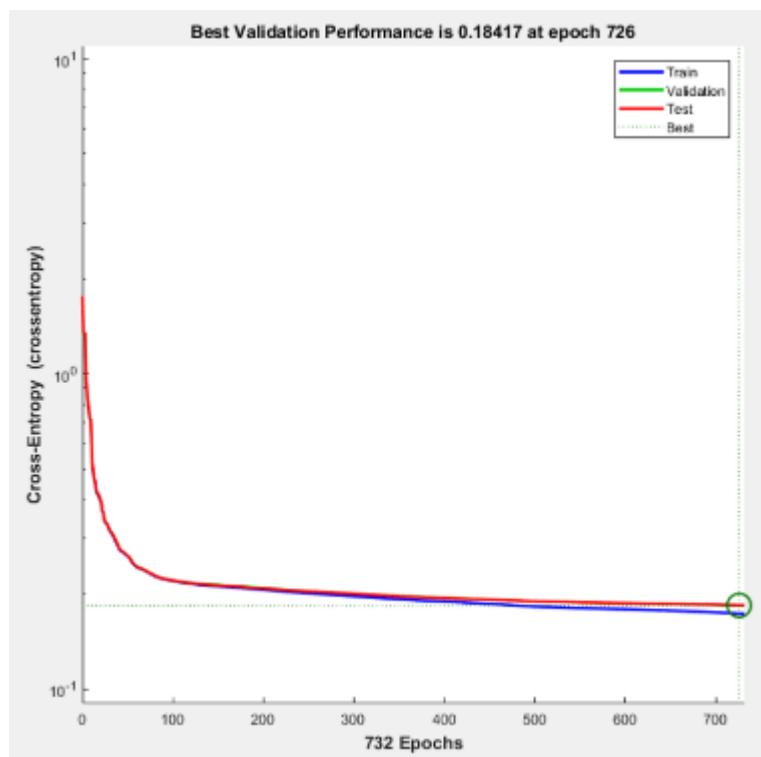
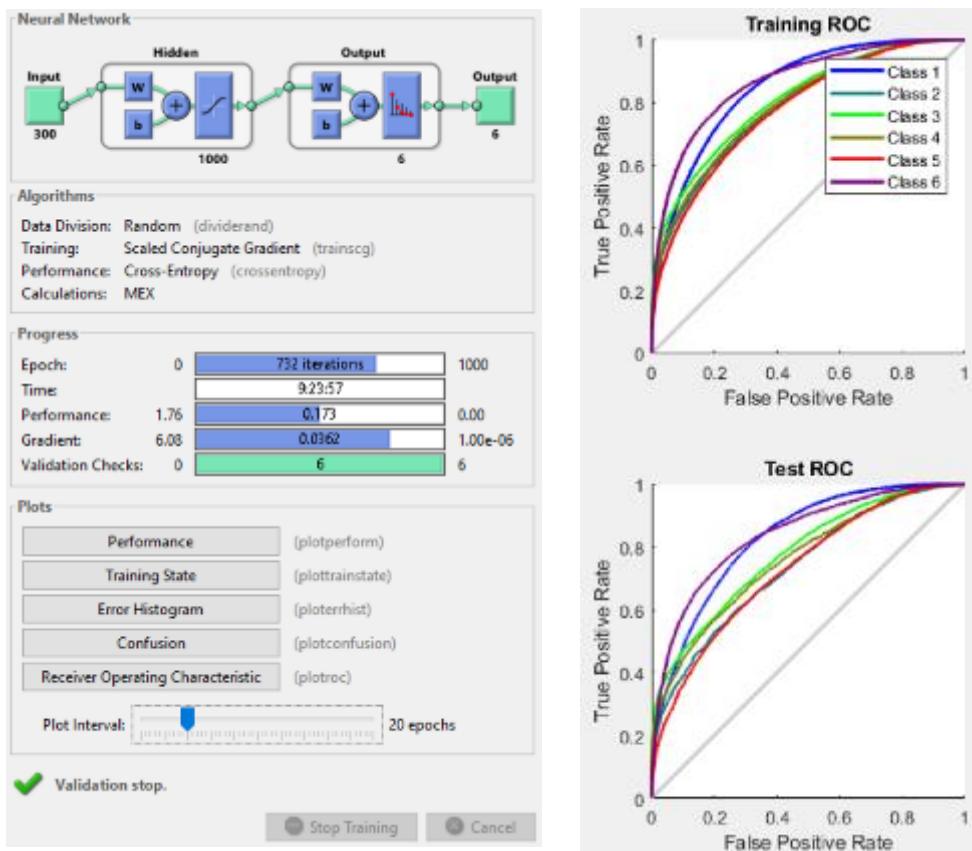


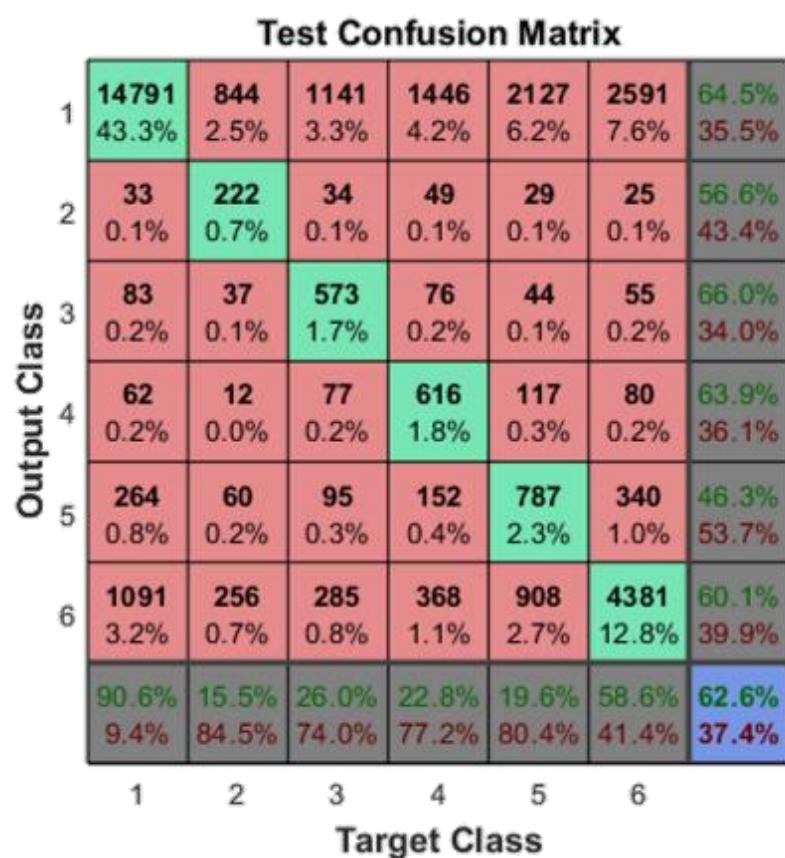
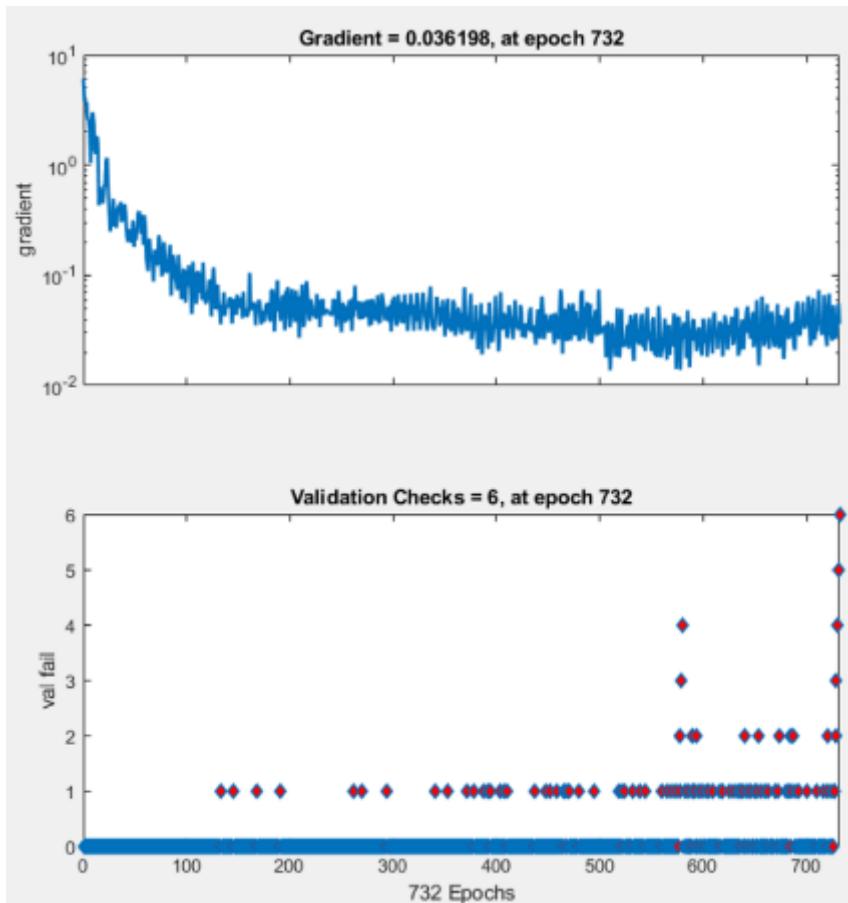


Test Confusion Matrix							
Output Class	1	2	3	4	5	6	
	13586 43.6%	770 2.5%	1084 3.5%	1359 4.4%	1792 5.7%	2211 7.1%	65.3% 34.7%
1	57 0.2%	215 0.7%	51 0.2%	46 0.1%	38 0.1%	29 0.1%	49.3% 50.7%
2	81 0.3%	27 0.1%	437 1.4%	70 0.2%	46 0.1%	56 0.2%	60.9% 39.1%
3	115 0.4%	16 0.1%	99 0.3%	551 1.8%	155 0.5%	72 0.2%	54.7% 45.3%
4	274 0.9%	64 0.2%	86 0.3%	143 0.5%	728 2.3%	317 1.0%	45.2% 54.8%
5	960 3.1%	234 0.8%	250 0.8%	315 1.0%	854 2.7%	3994 12.8%	60.5% 39.5%
6	90.1% 9.9%	16.2% 83.8%	21.8% 78.2%	22.2% 77.8%	20.1% 79.9%	59.8% 40.2%	62.6% 37.4%
Target Class							
1	2	3	4	5	6		

BC8: MLF Training für Betweenness Centrality. Versteckte Layer: 1000 Neuronen

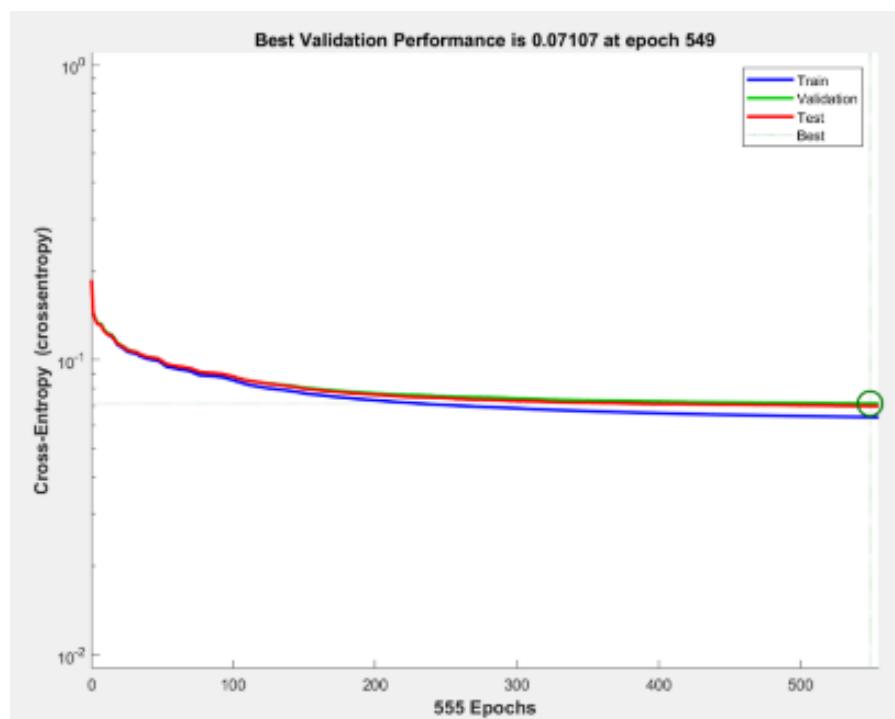
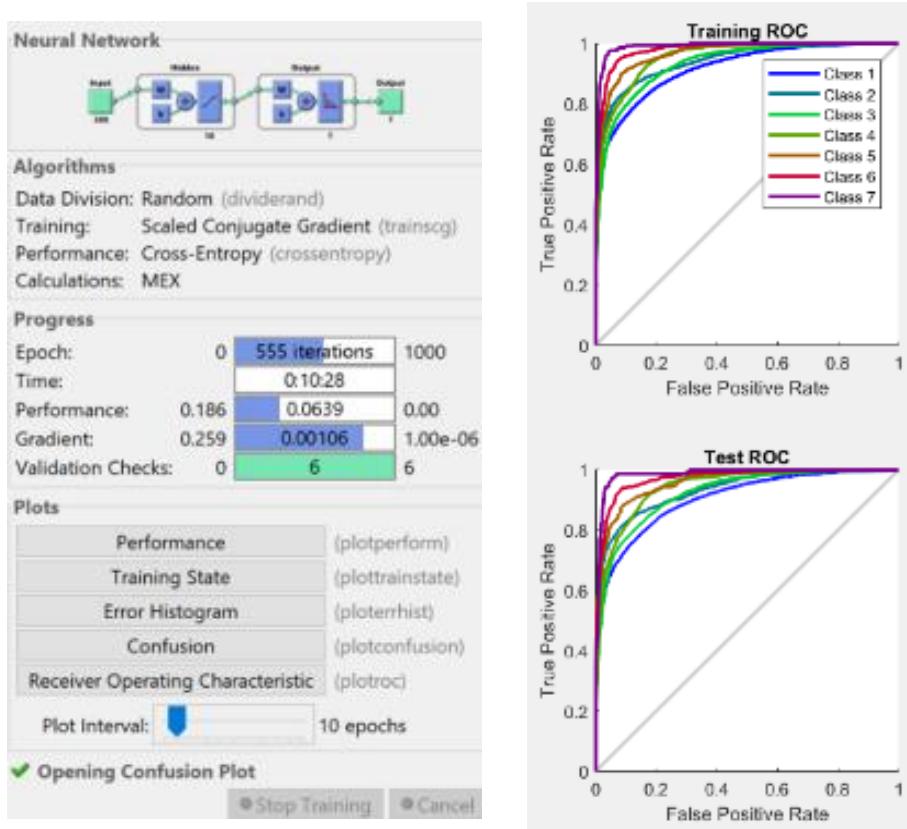
, 6 Output C lassen, N-Gram min 3, max 6

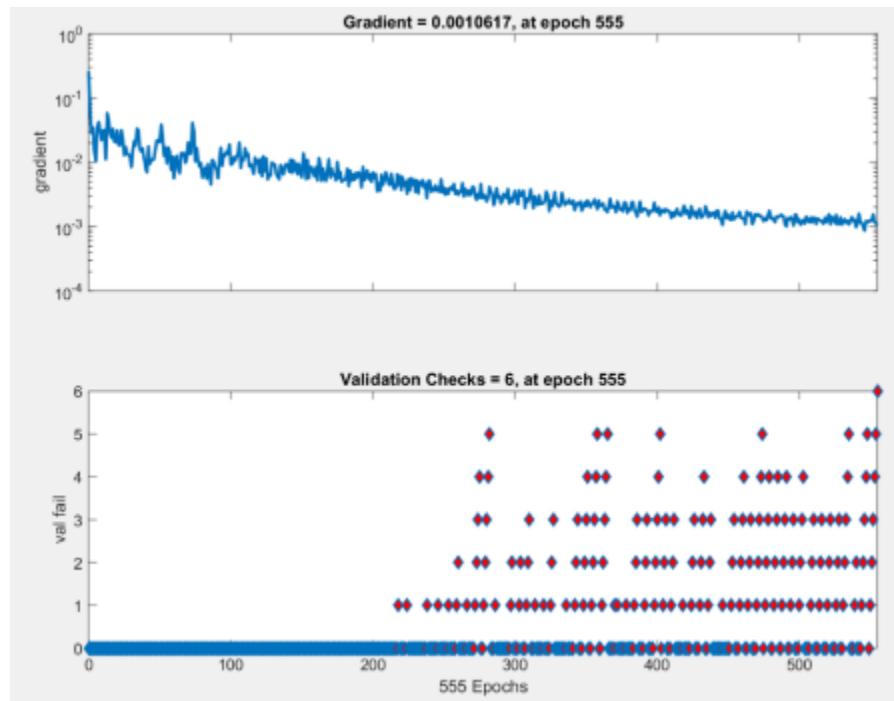




PS1: MLF Training für Positives Sentiment. Versteckte Layer: 10 Neuronen , 6

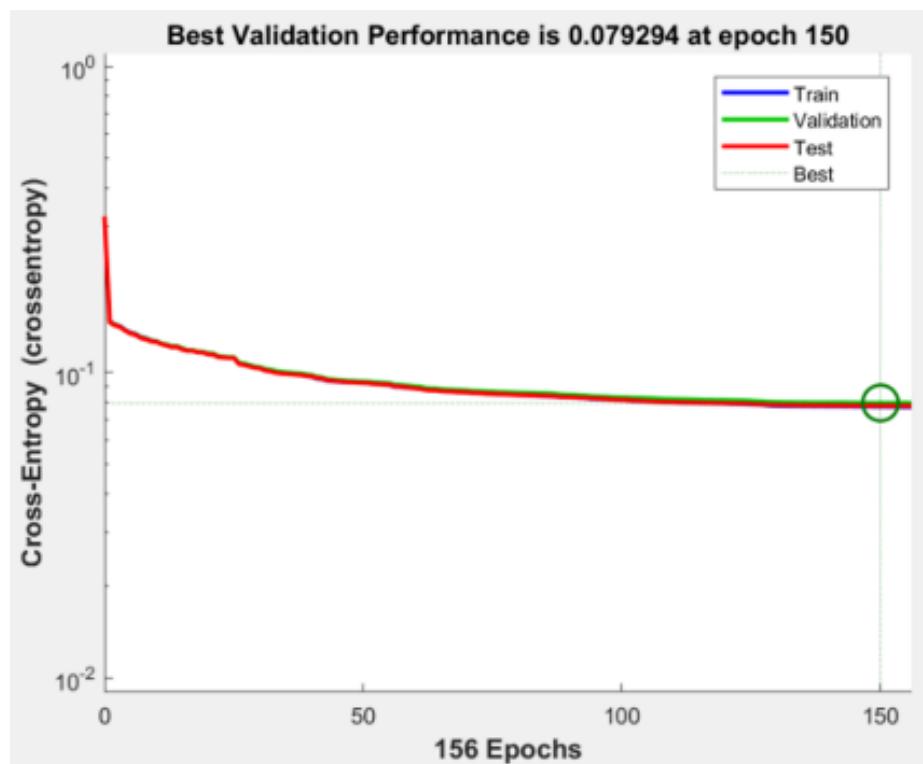
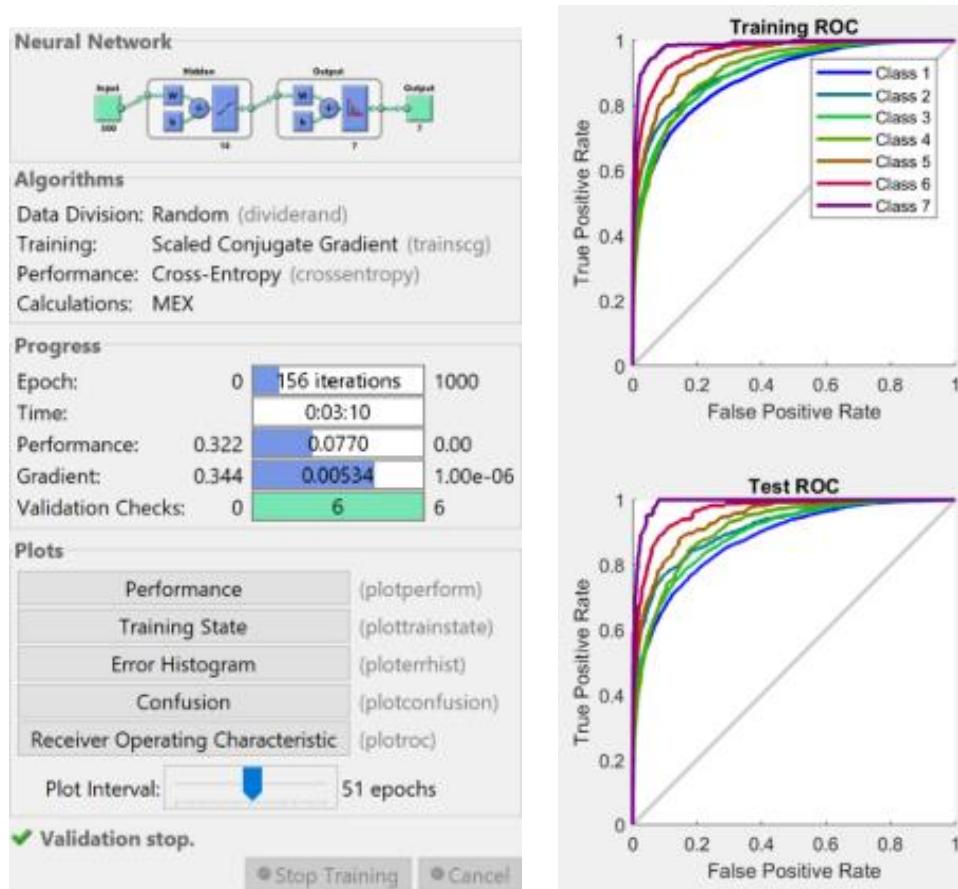
Output Klassen, N-Gram von min 1, max 1 (Unigram)

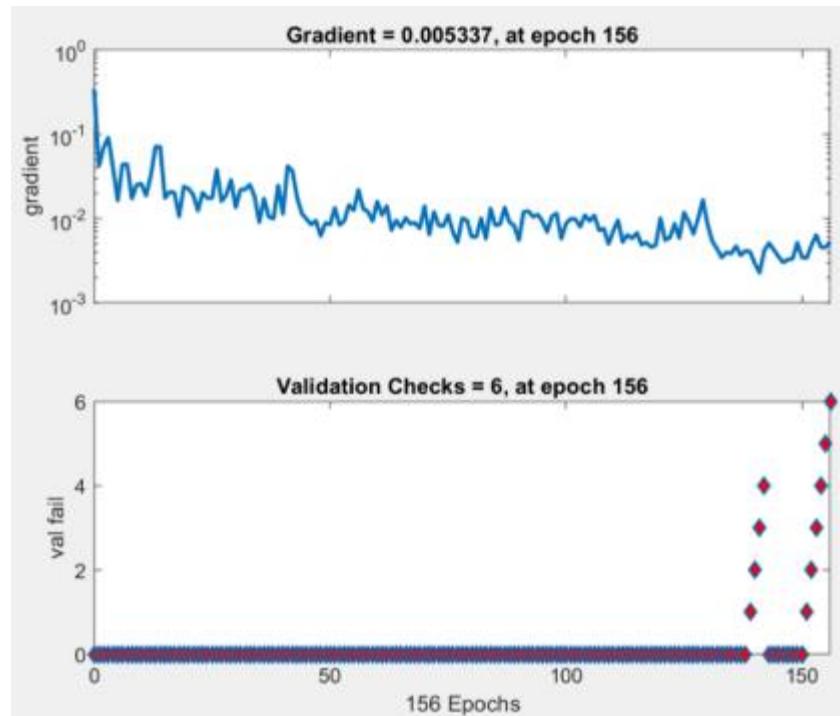




Test Confusion Matrix								
Output Class	1	2	3	4	5	6	7	
	21493 68.9%	623 2.0%	1757 5.6%	713 2.3%	267 0.9%	235 0.8%	53 0.2%	85.5% 14.5%
1	298 1.0%	723 2.3%	6 0.0%	19 0.1%	0 0.0%	0 0.0%	0 0.0%	69.1% 30.9%
2	690 2.2%	41 0.1%	2464 7.9%	16 0.1%	8 0.0%	9 0.0%	0 0.0%	76.3% 23.7%
3	246 0.8%	22 0.1%	48 0.2%	682 2.2%	11 0.0%	13 0.0%	0 0.0%	66.7% 33.3%
4	70 0.2%	5 0.0%	9 0.0%	4 0.0%	220 0.7%	1 0.0%	0 0.0%	71.2% 28.8%
5	79 0.3%	4 0.0%	20 0.1%	13 0.0%	7 0.0%	238 0.8%	15 0.0%	63.3% 36.7%
6	15 0.0%	0 0.0%	2 0.0%	3 0.0%	2 0.0%	17 0.1%	18 0.1%	31.6% 68.4%
7	93.9% 6.1%	51.0% 49.0%	57.2% 42.8%	47.0% 53.0%	42.7% 57.3%	46.4% 53.6%	20.9% 79.1%	82.9% 17.1%

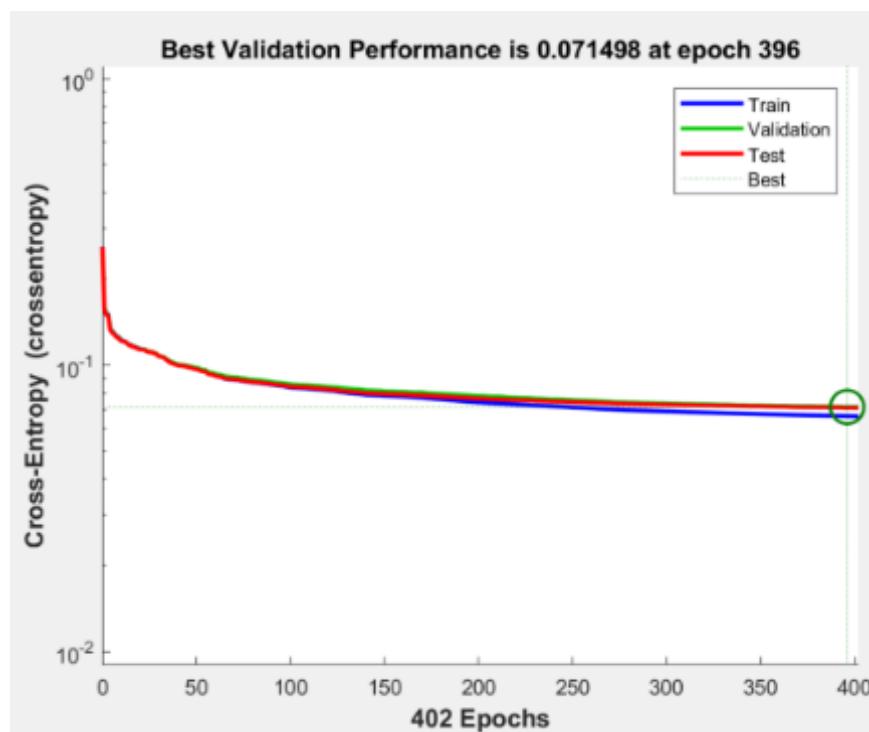
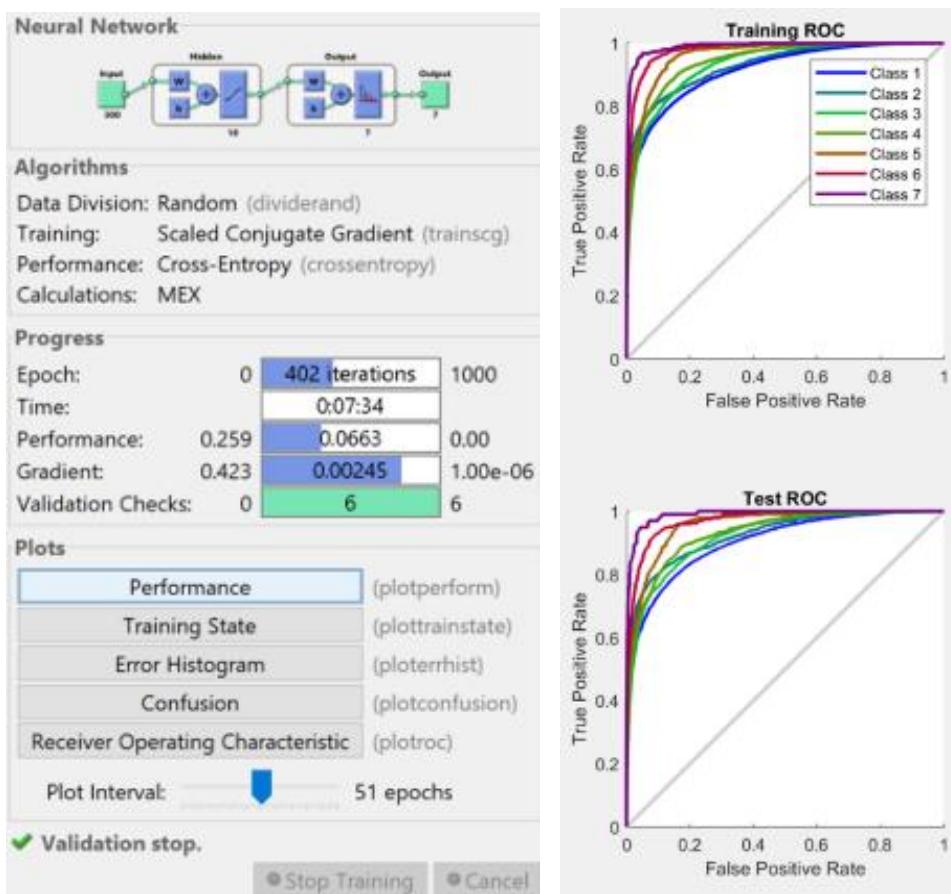
PS2: MLF Training für Positives Sentiment. Versteckte Layer: 10 Neuronen , 6 Output Klassen, N-Gram von min 2, max 3

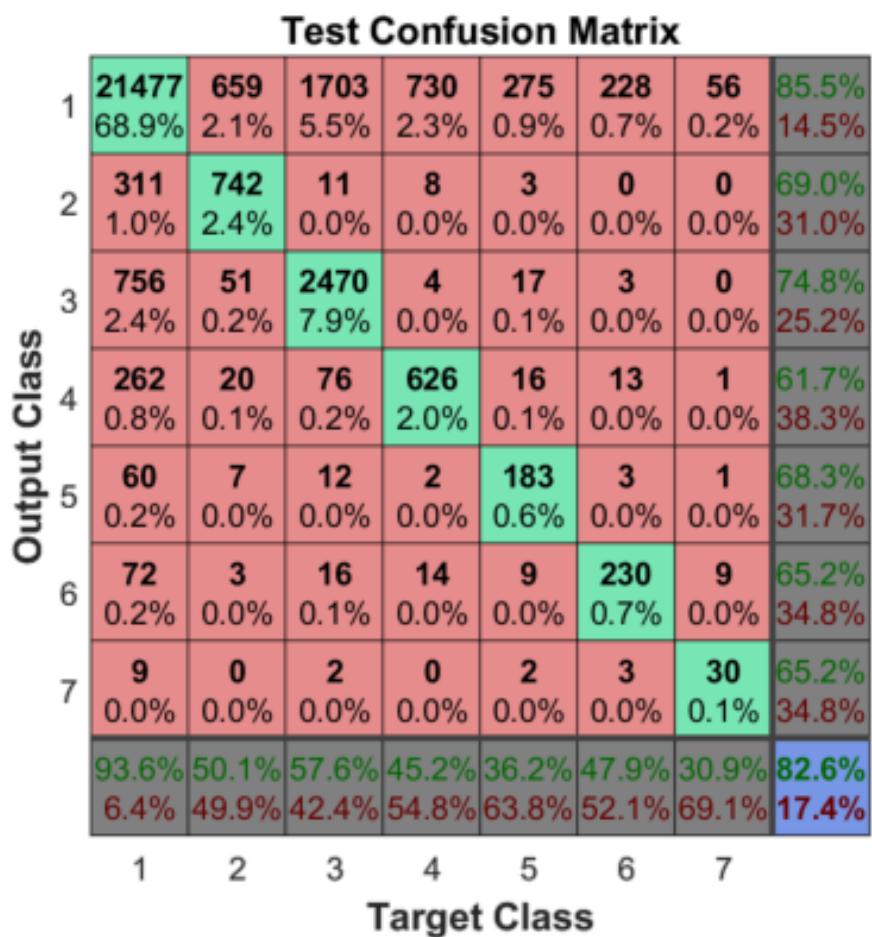
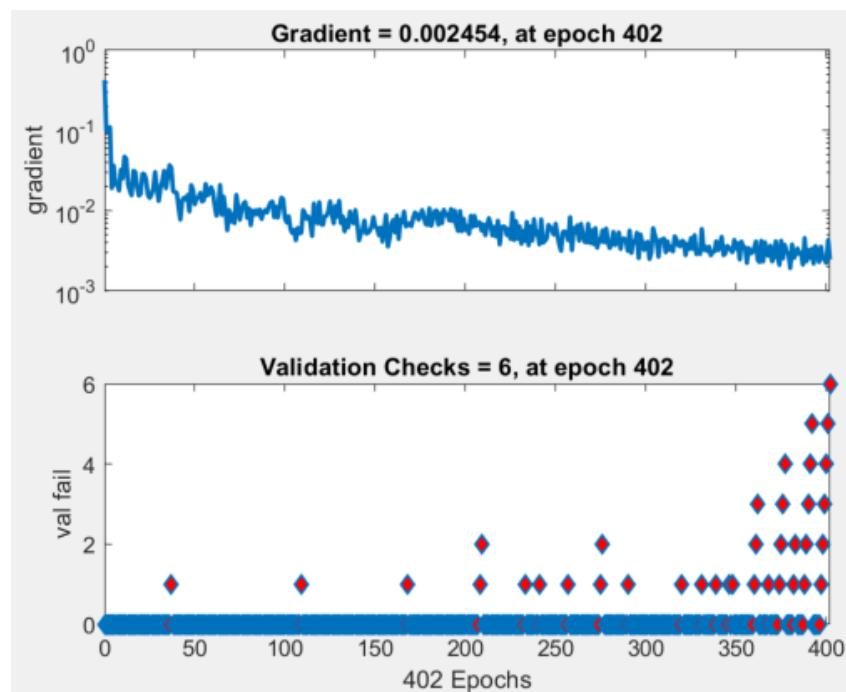




Test Confusion Matrix								
Output Class	1	2	3	4	5	6	7	
	21936 70.4%	751 2.4%	2241 7.2%	970 3.1%	315 1.0%	247 0.8%	46 0.1%	82.8% 17.2%
1	244 0.8%	584 1.9%	9 0.0%	5 0.0%	9 0.0%	1 0.0%	0 0.0%	68.5% 31.5%
2	497 1.6%	43 0.1%	1958 6.3%	40 0.1%	8 0.0%	26 0.1%	0 0.0%	76.1% 23.9%
3	149 0.5%	10 0.0%	35 0.1%	419 1.3%	11 0.0%	33 0.1%	17 0.1%	62.2% 37.8%
4	41 0.1%	6 0.0%	10 0.0%	6 0.0%	157 0.5%	6 0.0%	4 0.0%	68.3% 31.7%
5	70 0.2%	3 0.0%	16 0.1%	28 0.1%	5 0.0%	195 0.6%	13 0.0%	59.1% 40.9%
6	6 0.0%	0 0.0%	0 0.0%	0 0.0%	0 0.0%	3 0.0%	6 0.0%	40.0% 60.0%
7	95.6% 4.4%	41.8% 58.2%	45.9% 54.1%	28.5% 71.5%	31.1% 68.9%	38.2% 61.8%	7.0% 93.0%	81.0% 19.0%

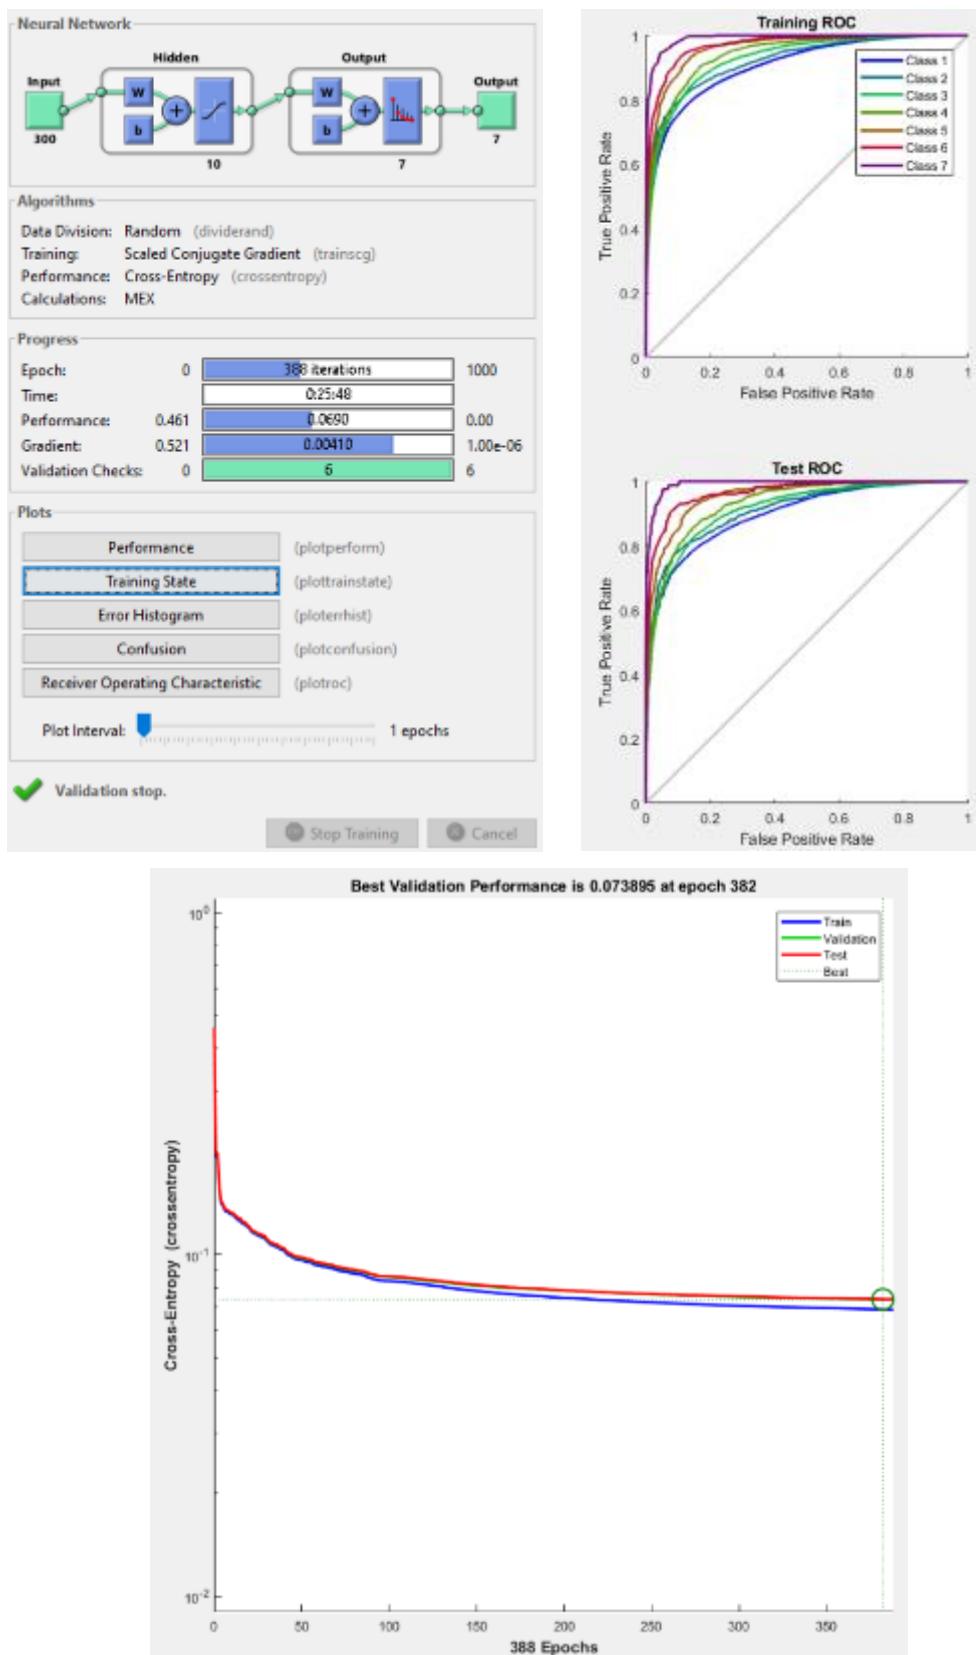
PS3: MLF Training für Positives Sentiment. Versteckte Layer: 10 Neuronen , 6 Output Klassen, N-Gram von min 2, max 4

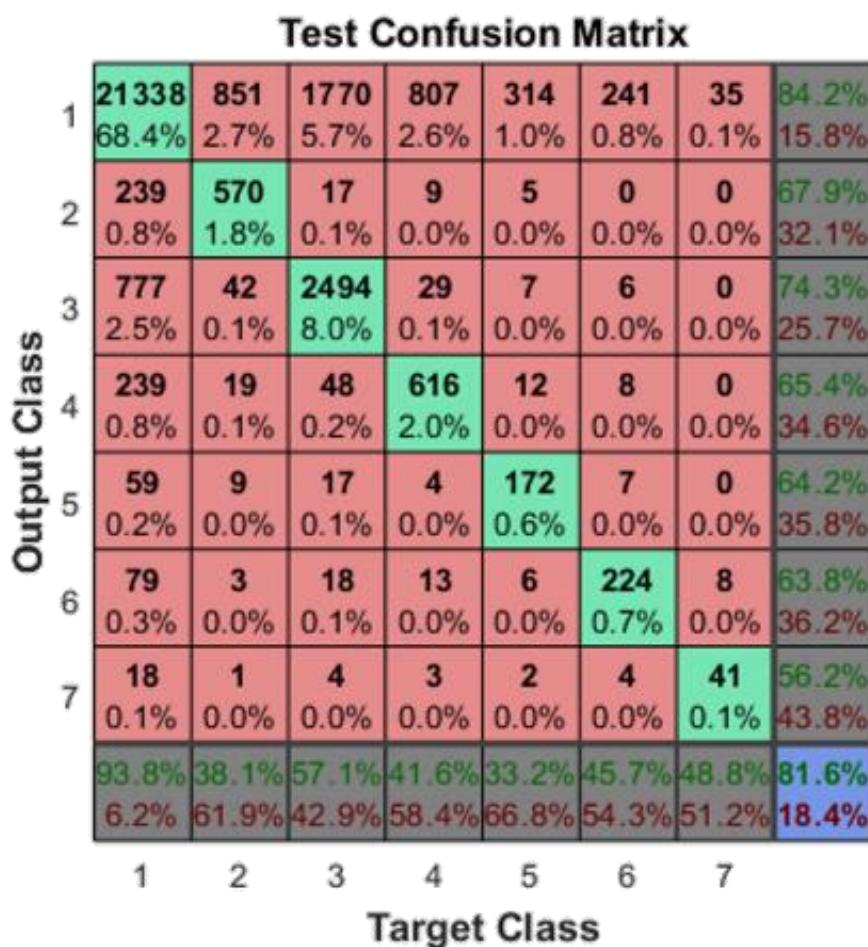
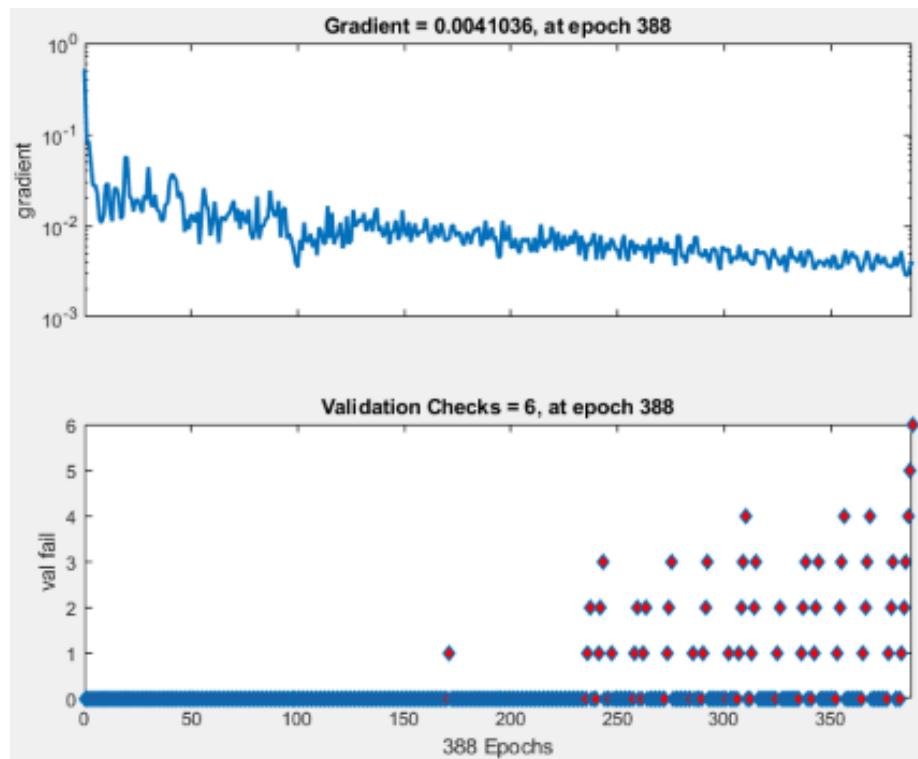




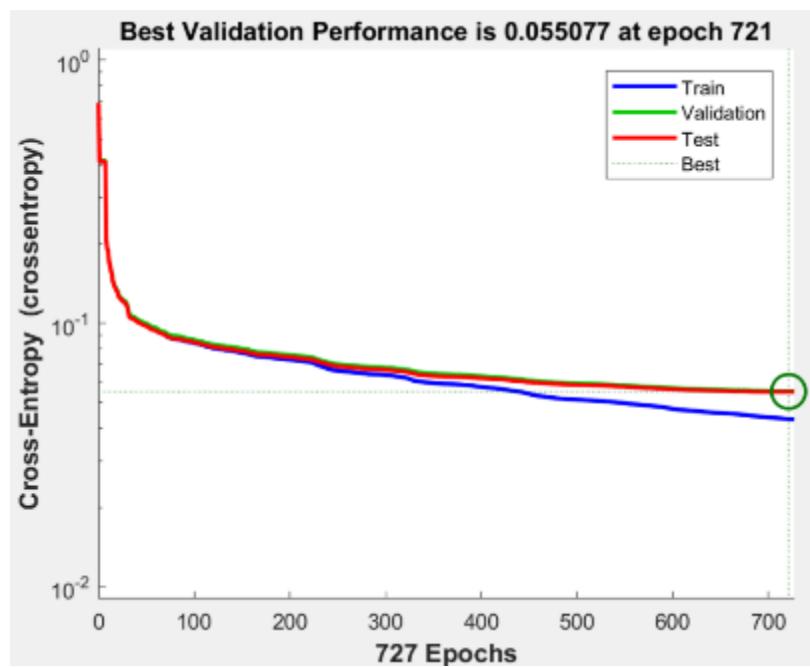
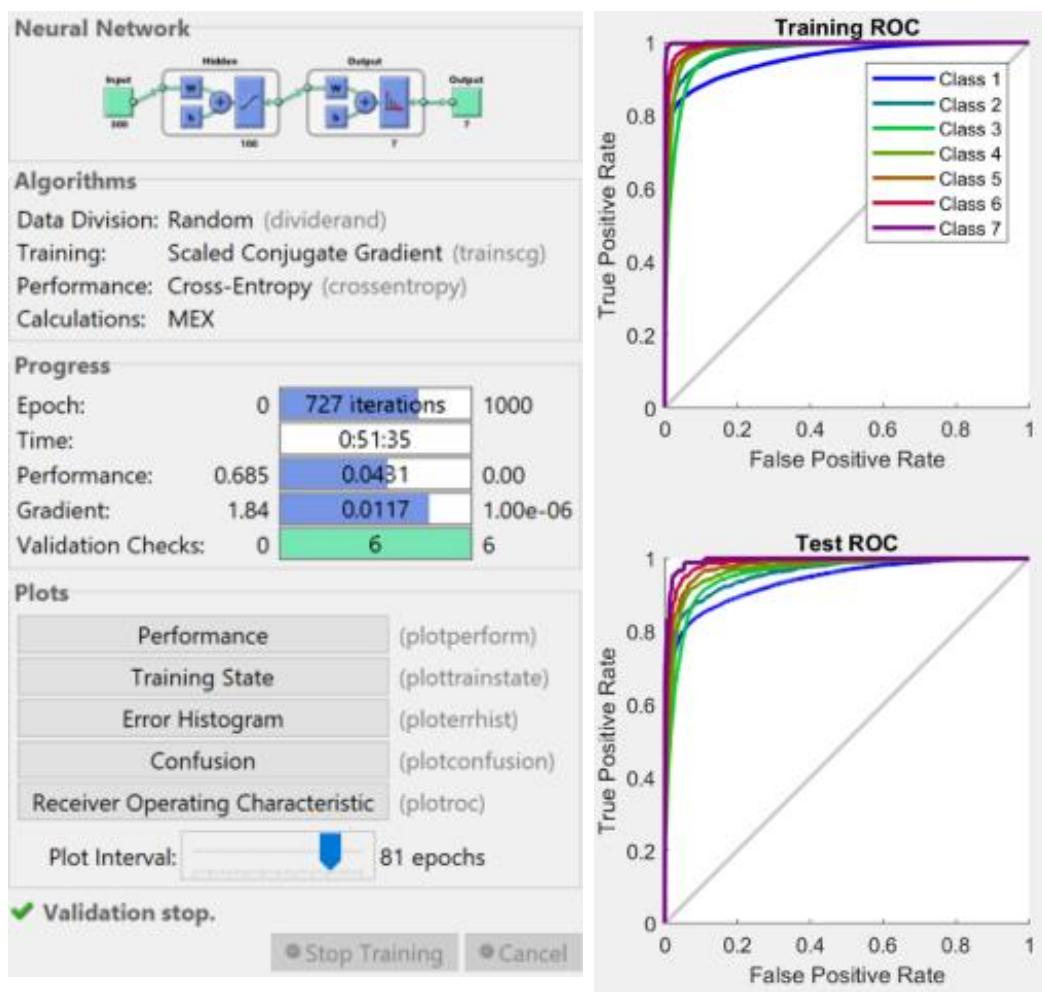
PS4: MLF Training für Positives Sentiment. Versteckte Layer: 10 Neuronen , 6 Output

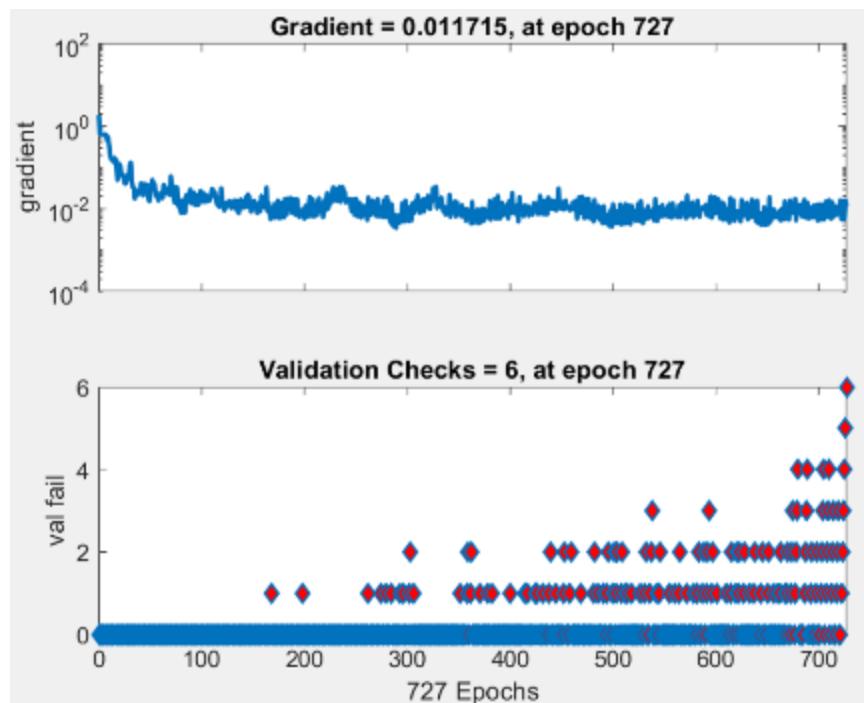
Classen, N-Gram von min 3, max 6





PS5: MLF Training für Positives Sentiment. Versteckte Layer: 100 Neuronen , 6 Output Klassen, N-Gram von min 3, max 6

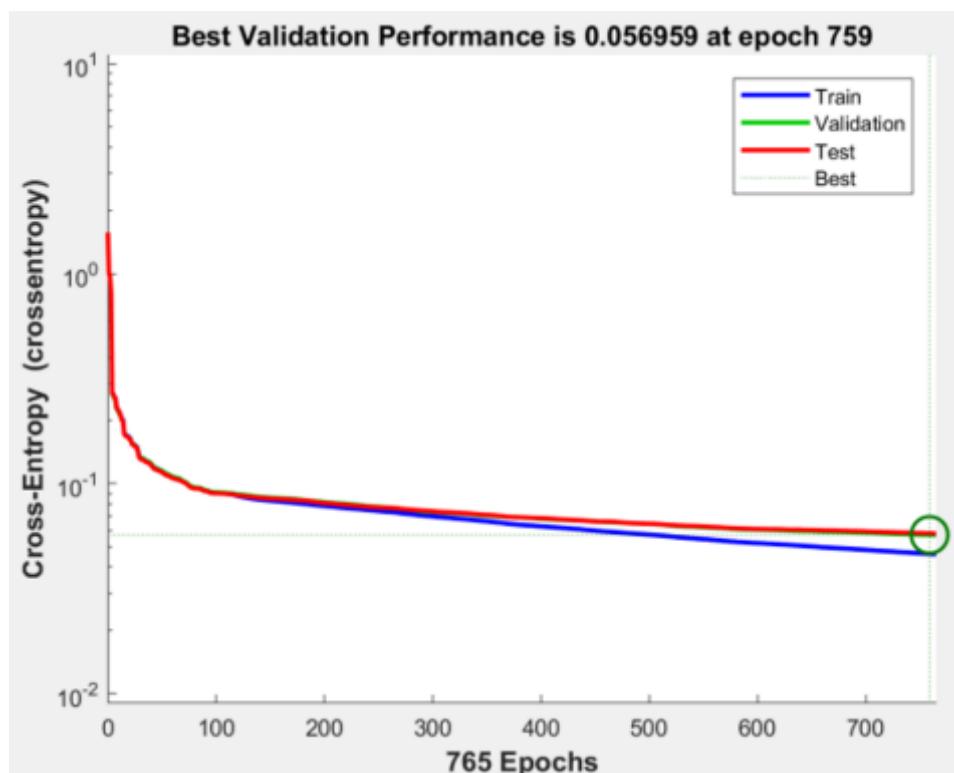
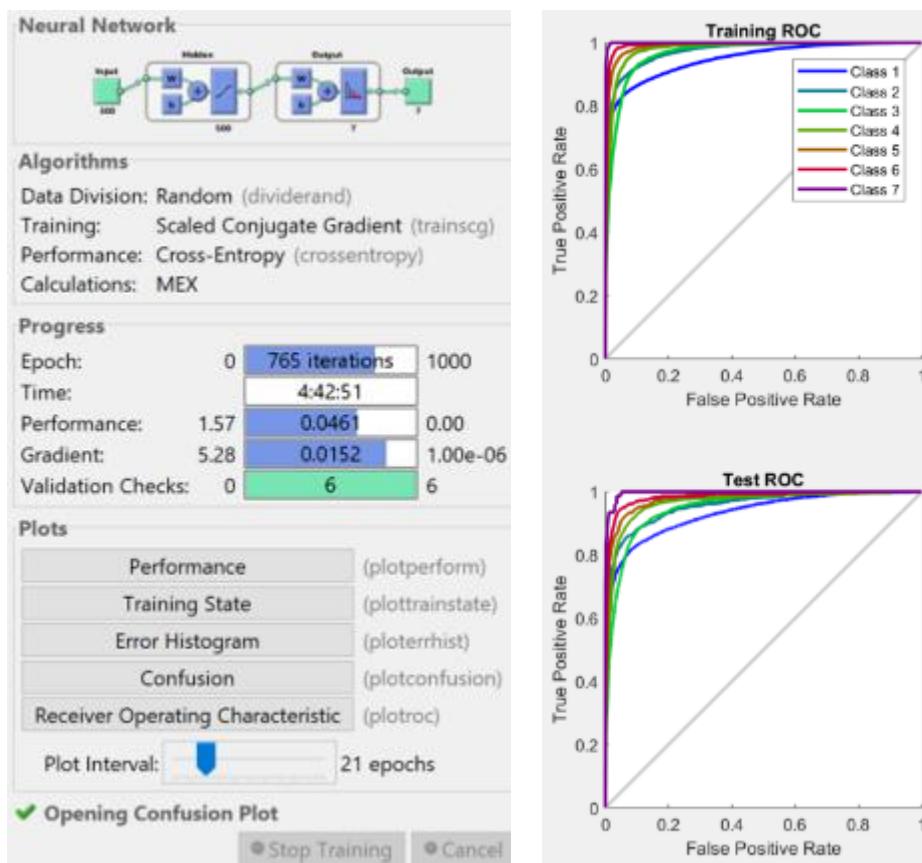


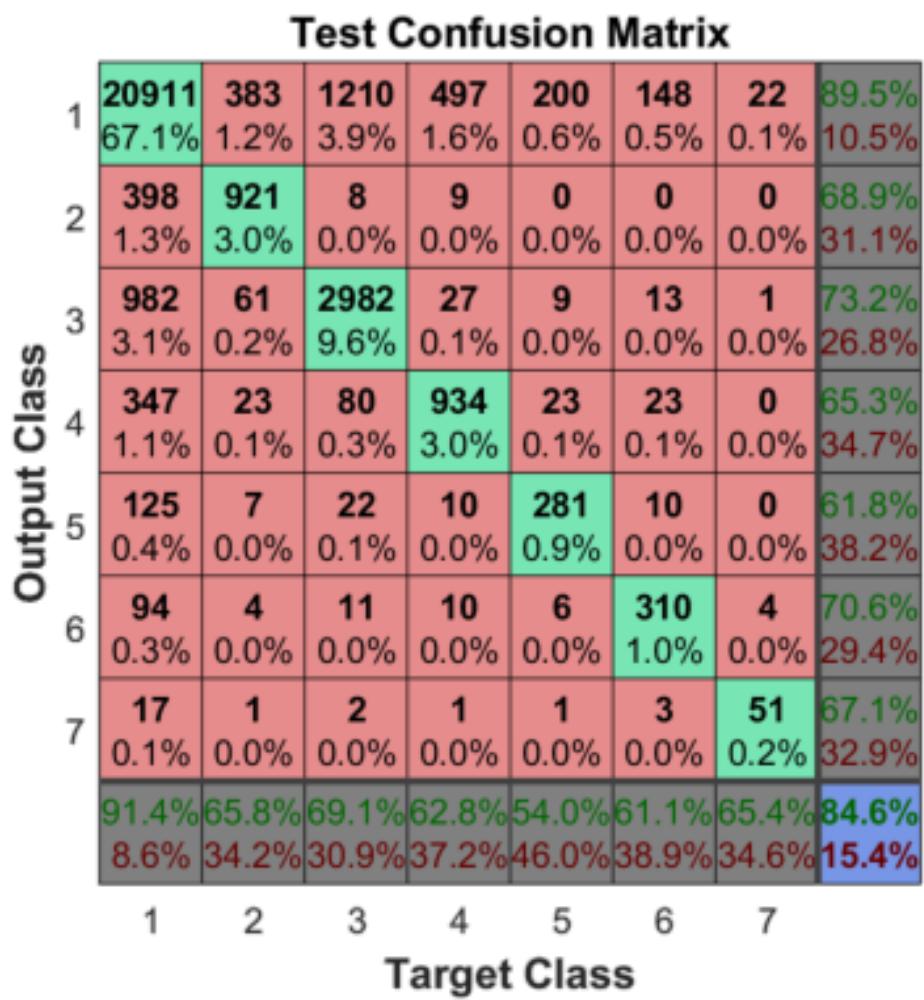
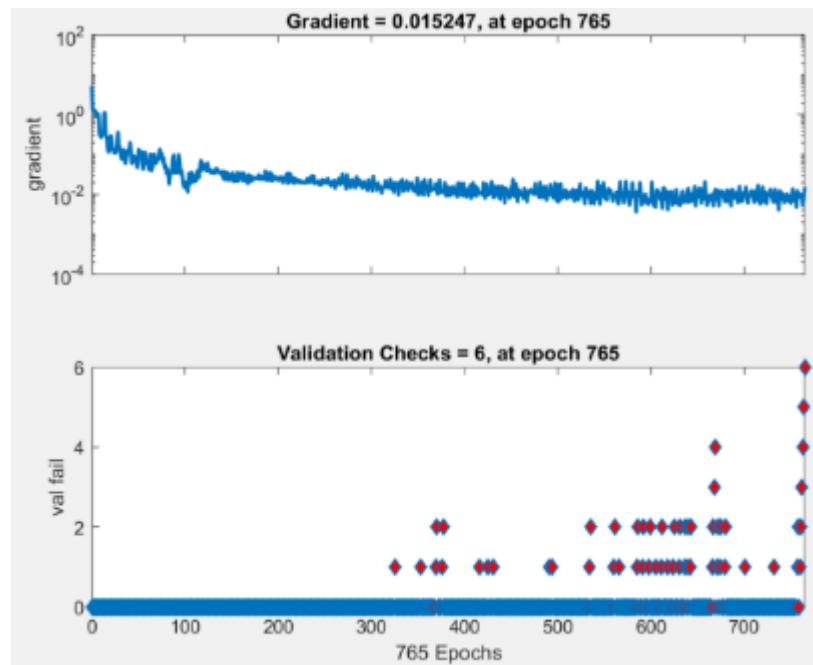


Test Confusion Matrix

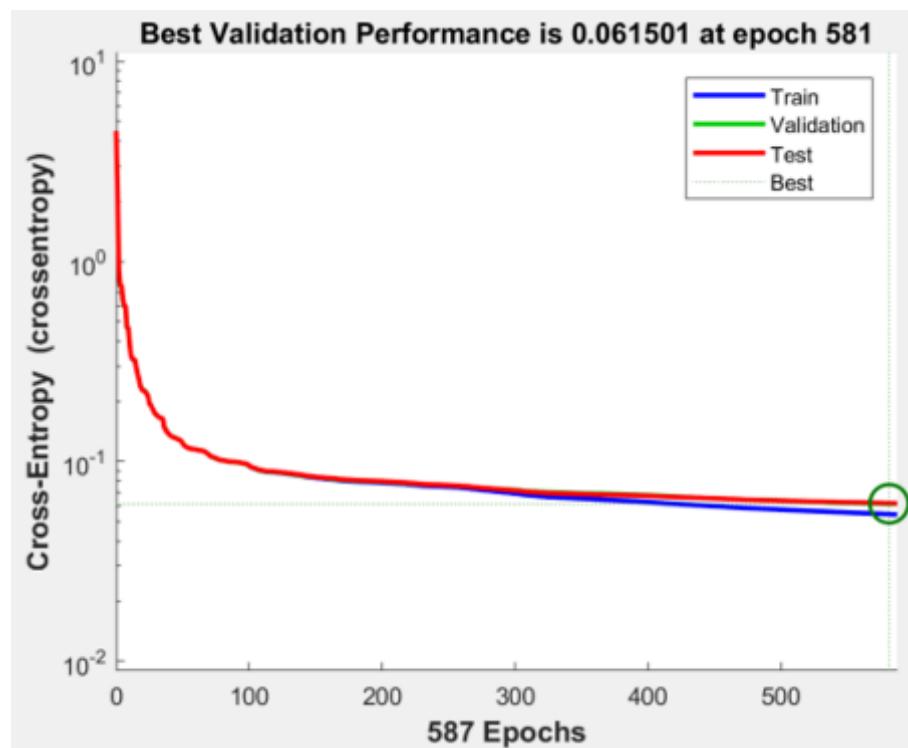
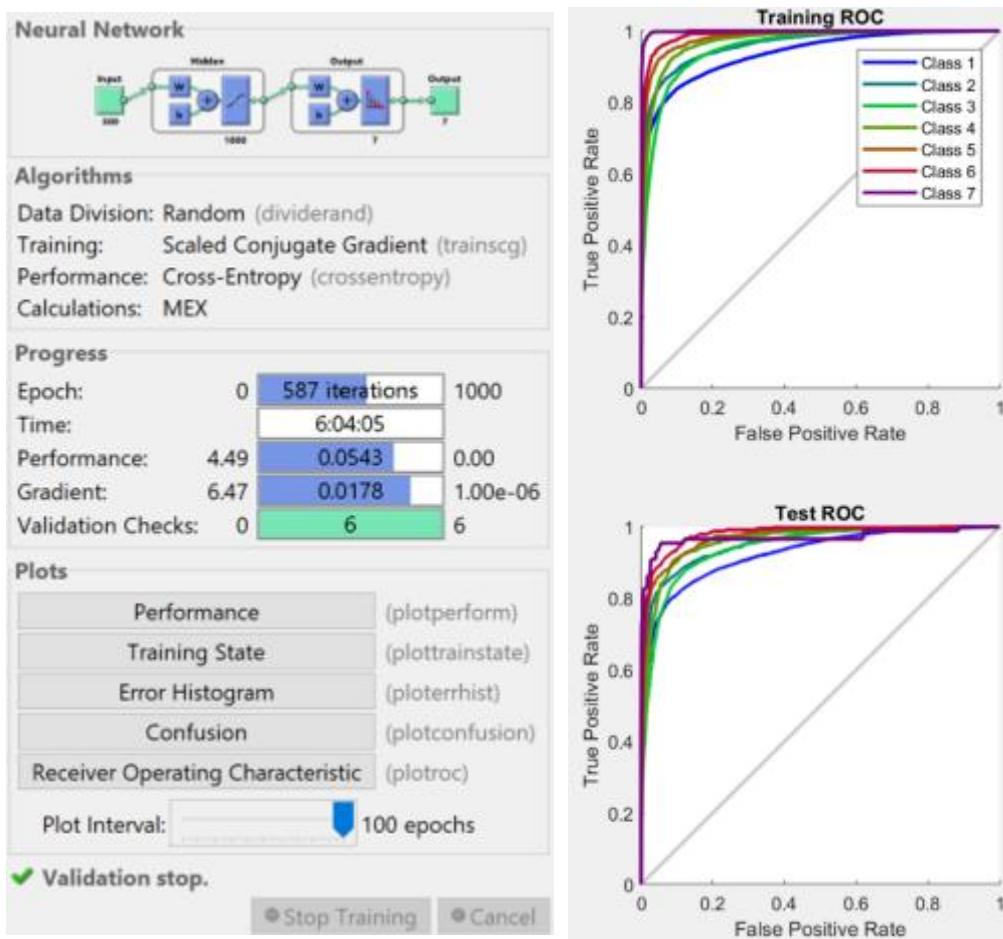
Output Class	Target Class							91.5% 8.5%
	1	2	3	4	5	6	7	
1	20678 66.3%	296 0.9%	950 3.0%	403 1.3%	127 0.4%	121 0.4%	19 0.1%	91.5% 8.5%
2	463 1.5%	1021 3.3%	13 0.0%	6 0.0%	1 0.0%	0 0.0%	1 0.0%	67.8% 32.2%
3	1059 3.4%	75 0.2%	3276 10.5%	69 0.2%	18 0.1%	28 0.1%	4 0.0%	72.3% 27.7%
4	384 1.2%	36 0.1%	75 0.2%	892 2.9%	30 0.1%	8 0.0%	2 0.0%	62.5% 37.5%
5	156 0.5%	10 0.0%	25 0.1%	15 0.0%	302 1.0%	11 0.0%	1 0.0%	58.1% 41.9%
6	117 0.4%	6 0.0%	19 0.1%	20 0.1%	11 0.0%	343 1.1%	7 0.0%	65.6% 34.4%
7	16 0.1%	0 0.0%	2 0.0%	3 0.0%	1 0.0%	6 0.0%	57 0.2%	67.1% 32.9%
		90.4% 9.6%	70.7% 29.3%	75.1% 24.9%	63.4% 36.6%	61.6% 38.4%	66.3% 33.7%	85.2% 14.8%

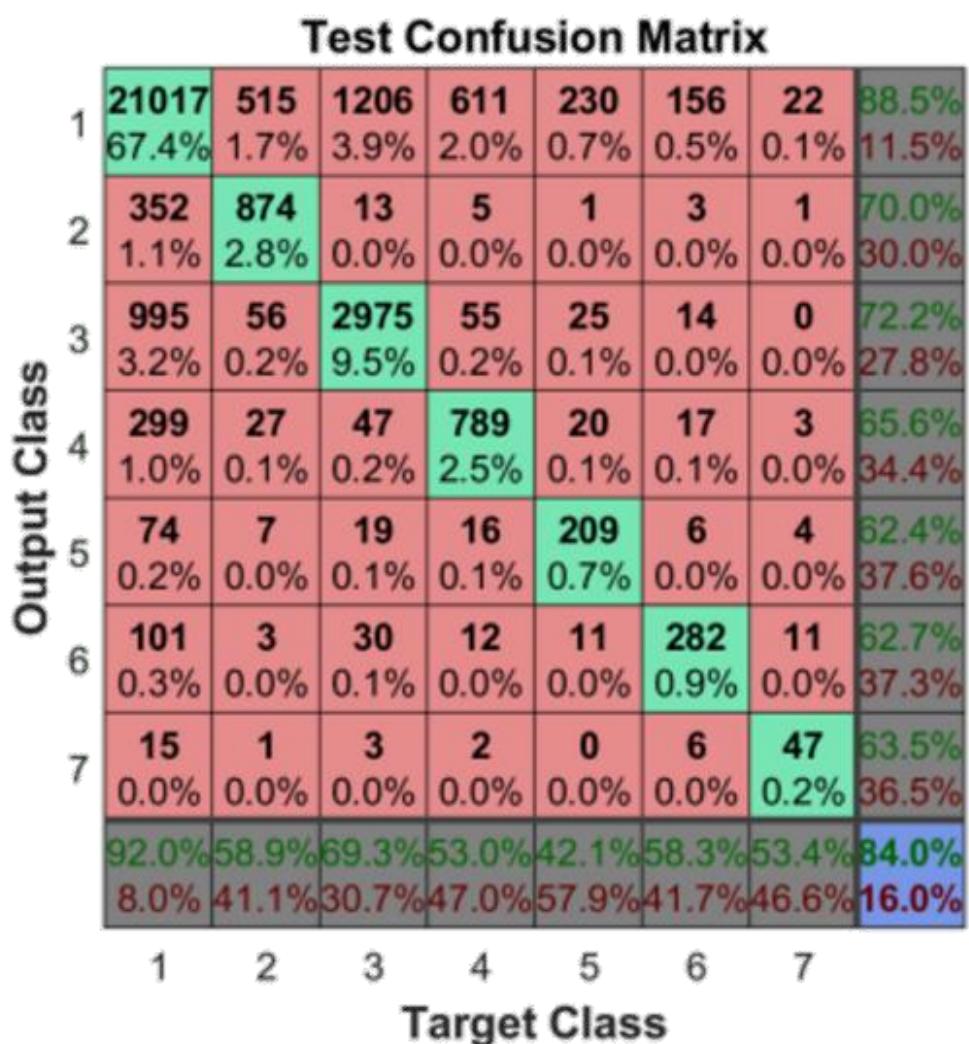
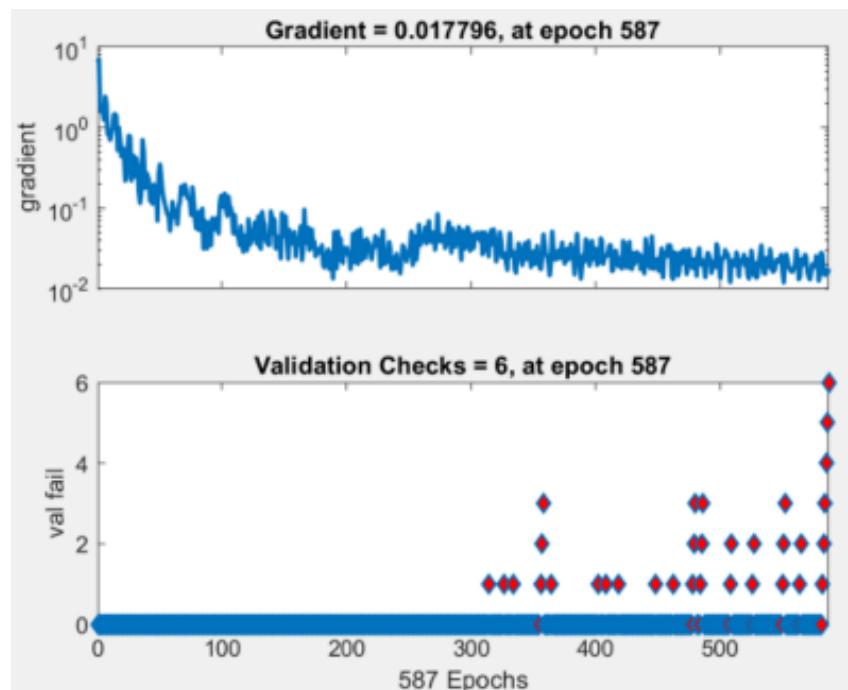
PS6: MLF Training für Positives Sentiment. Versteckte Layer: 500 Neuronen , 6 Output Klassen, N-Gram von min 3, max 6



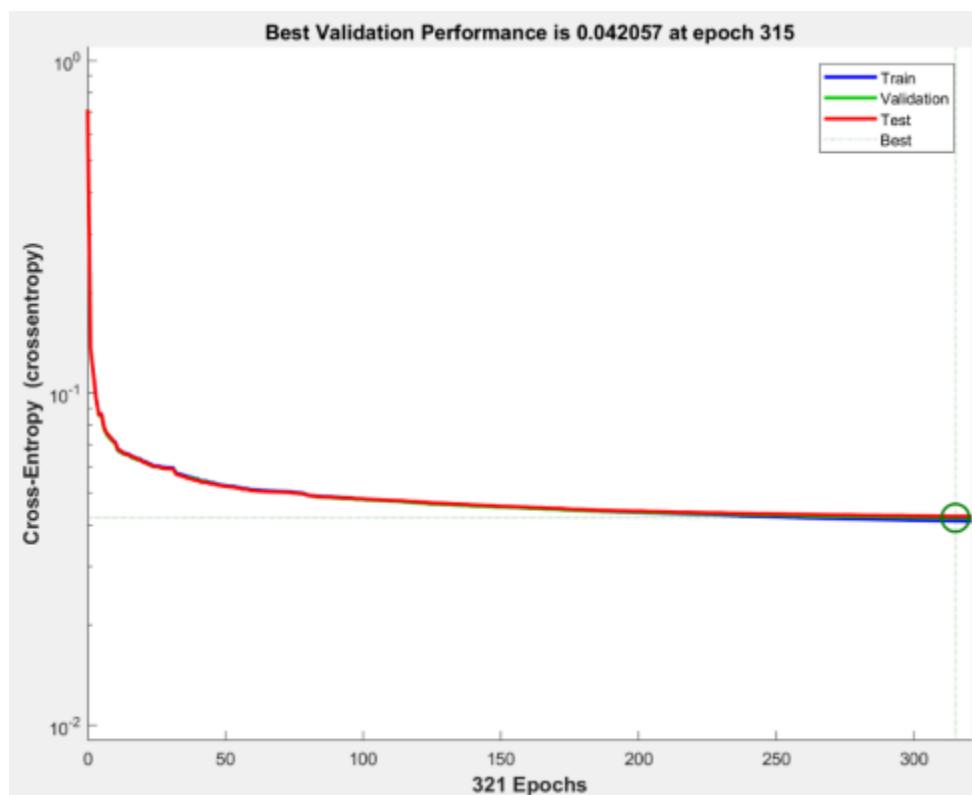
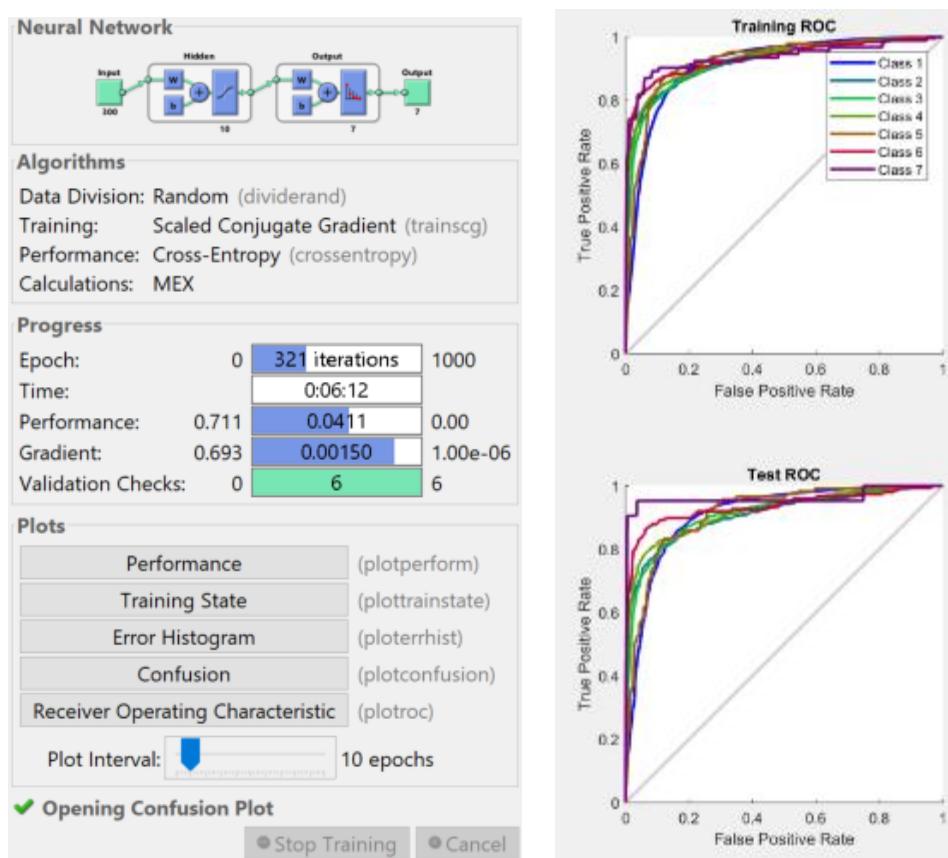


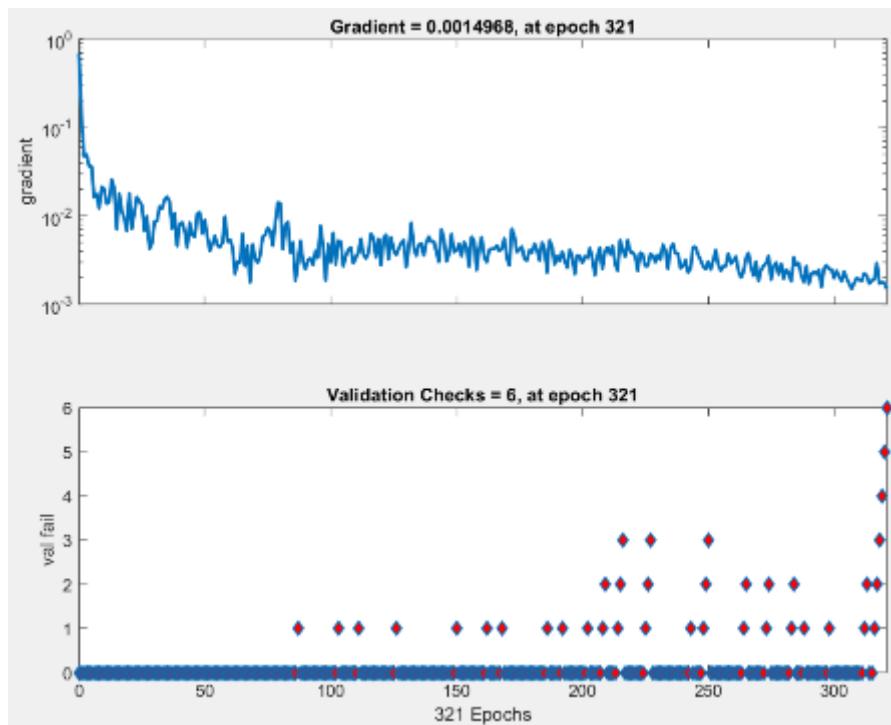
PS7: MLF Training für Positives Sentiment. Versteckte Layer: 1000 Neuronen , 6 Output Klassen, N-Gram von min 3, max 6





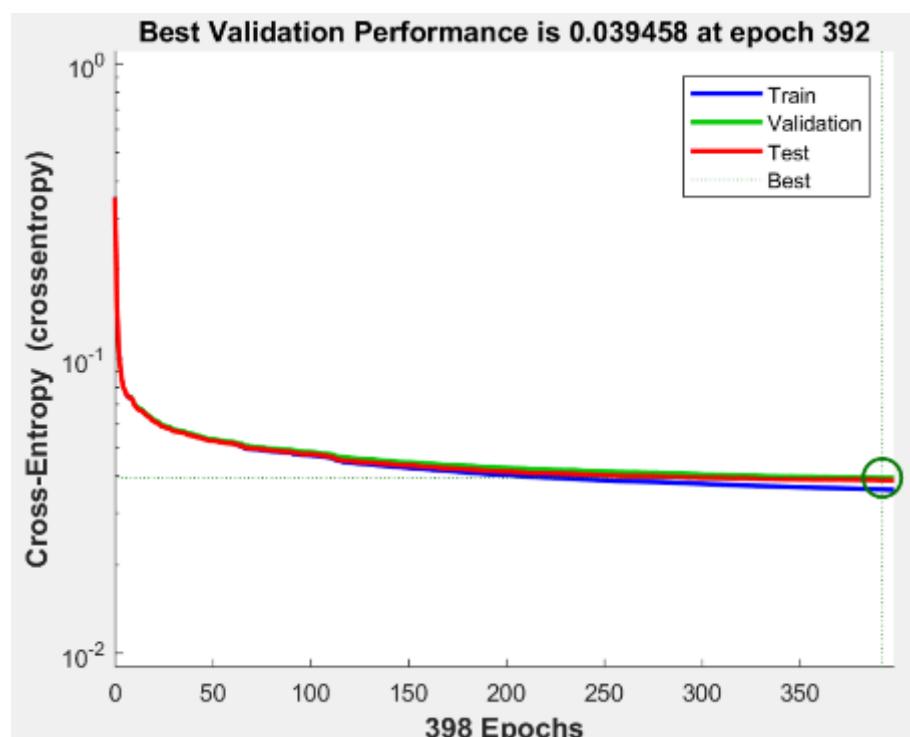
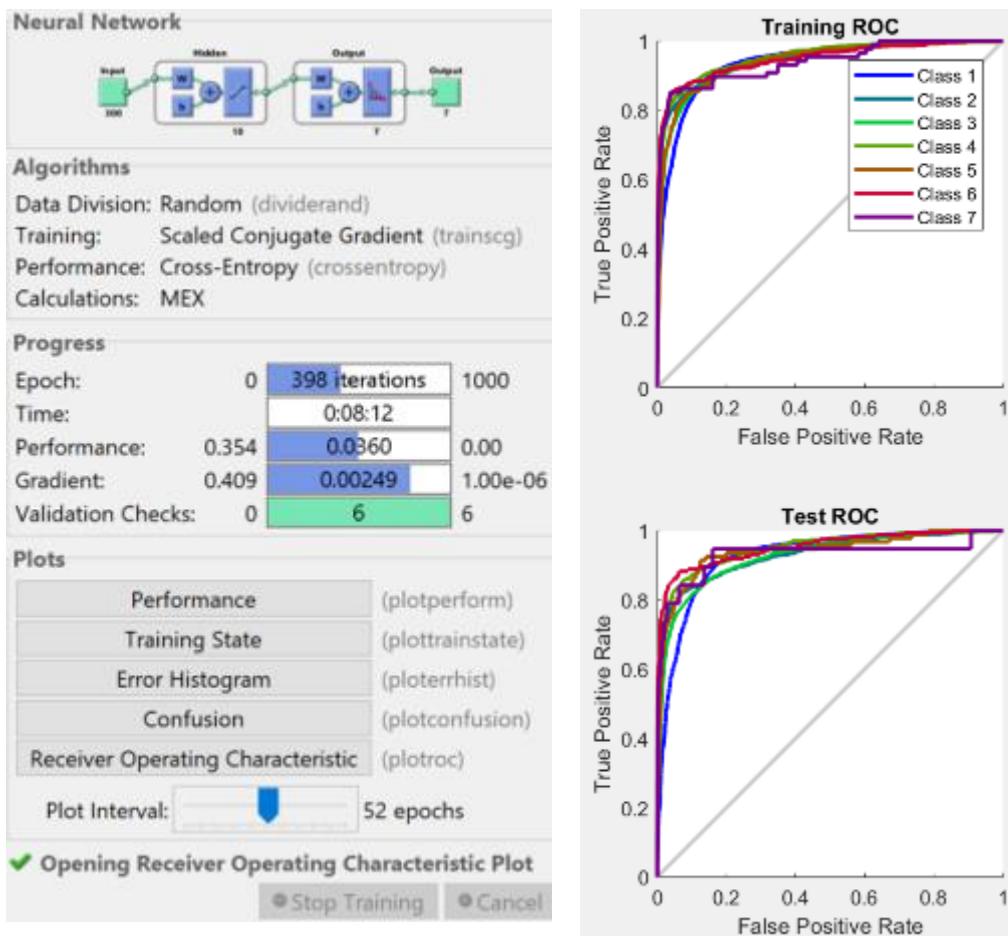
NS1: MLF Training für Negatives Sentiment. Versteckte Layer: 10 Neuronen , 6 Output Klassen, N-Gram von min 1, max 1 (Unigram)

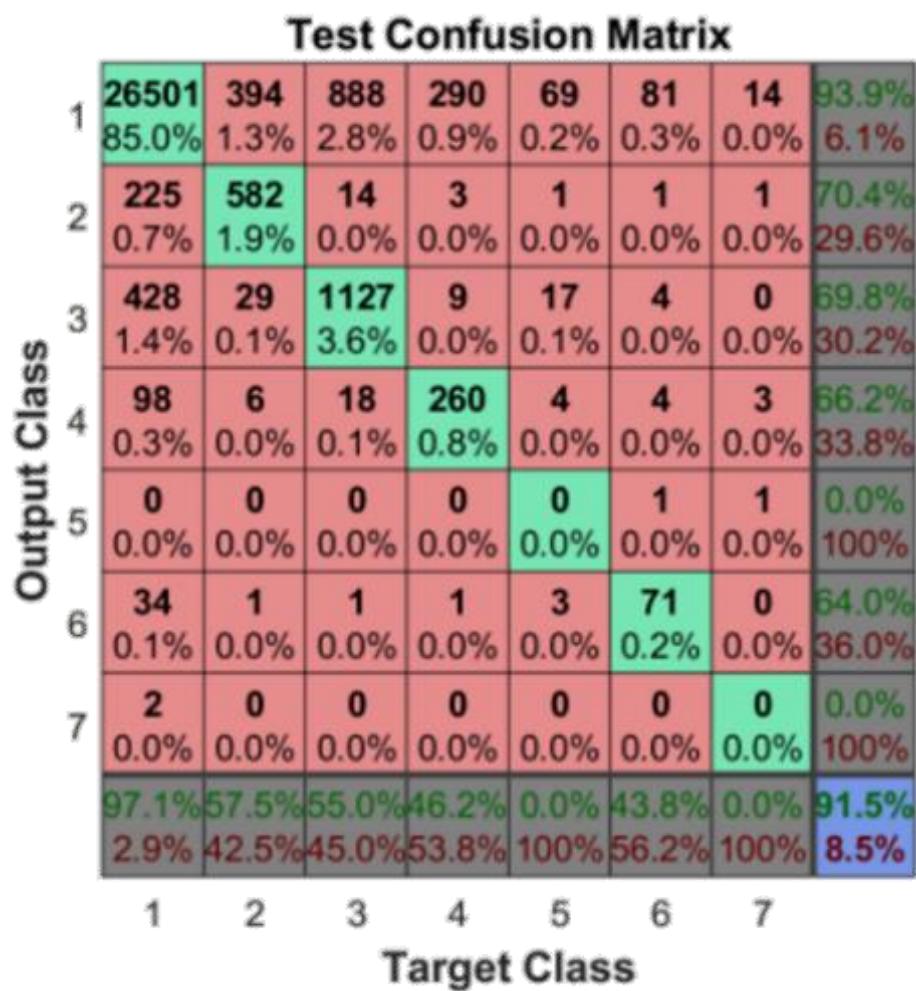
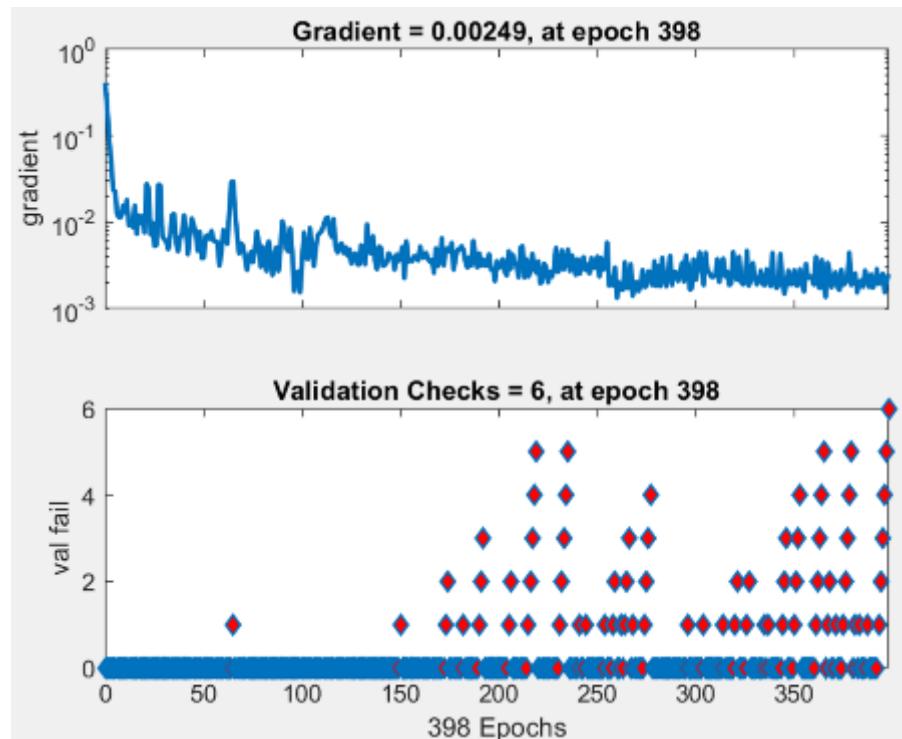




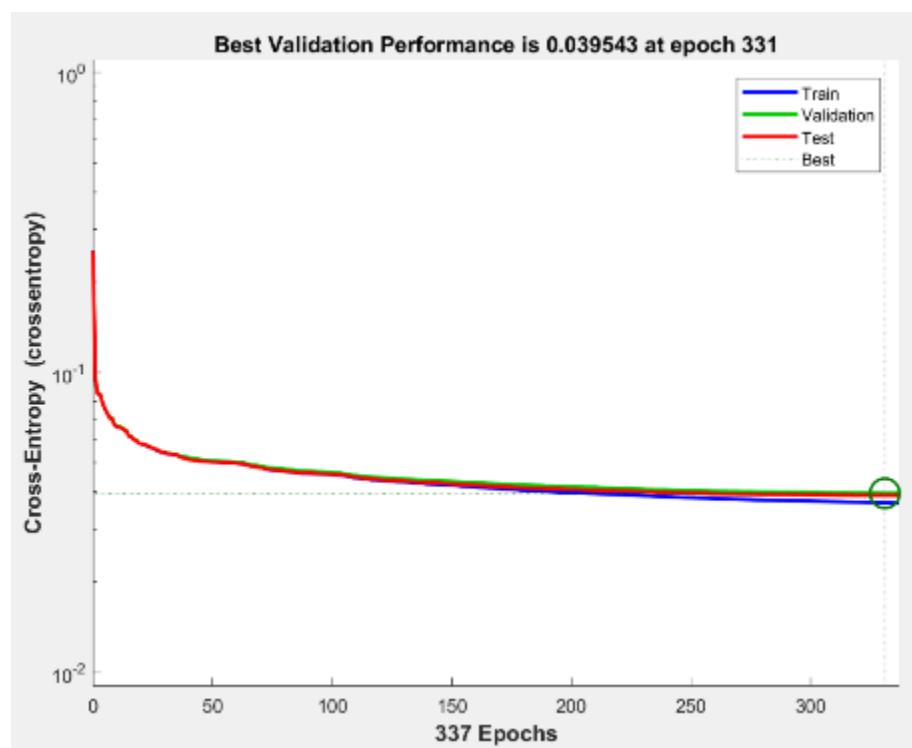
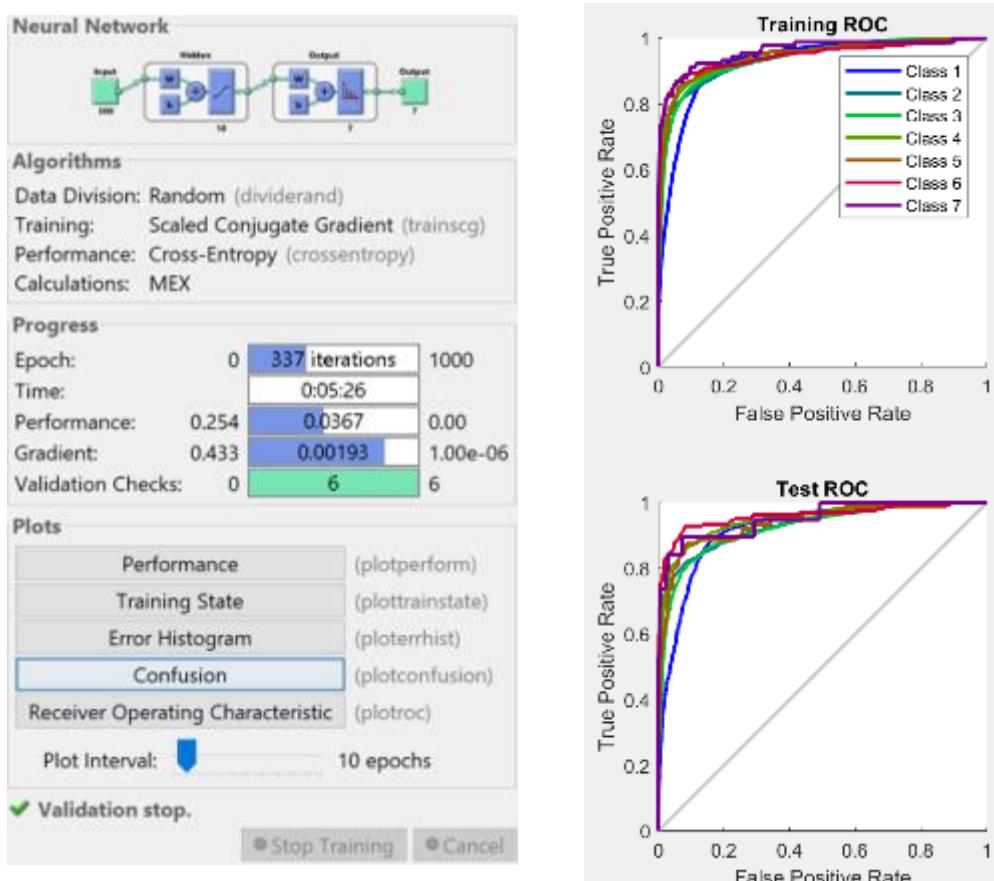
Test Confusion Matrix									
Output Class	1	2	3	4	5	6	7		
	26583 85.2%	513 1.6%	1004 3.2%	287 0.9%	94 0.3%	72 0.2%	16 0.1%	93.0% 7.0%	
	161 0.5%	460 1.5%	6 0.0%	1 0.0%	4 0.0%	0 0.0%	0 0.0%	72.8% 27.2%	
	412 1.3%	17 0.1%	1025 3.3%	19 0.1%	12 0.0%	5 0.0%	2 0.0%	68.7% 31.3%	
	109 0.3%	2 0.0%	11 0.0%	259 0.8%	2 0.0%	12 0.0%	1 0.0%	65.4% 34.6%	
	0 0.0%	0 0.0%	0 0.0%	0 0.0%	0 0.0%	0 0.0%	0 0.0%	NaN% NaN%	
	23 0.1%	0 0.0%	2 0.0%	1 0.0%	1 0.0%	57 0.2%	0 0.0%	67.9% 32.1%	
	4 0.0%	1 0.0%	2 0.0%	0 0.0%	0 0.0%	2 0.0%	2 0.0%	18.2% 81.8%	
		97.4% 2.6%	46.3% 53.7%	50.0% 50.0%	45.7% 54.3%	0.0% 100%	38.5% 61.5%	9.5% 90.5%	91.0% 9.0%

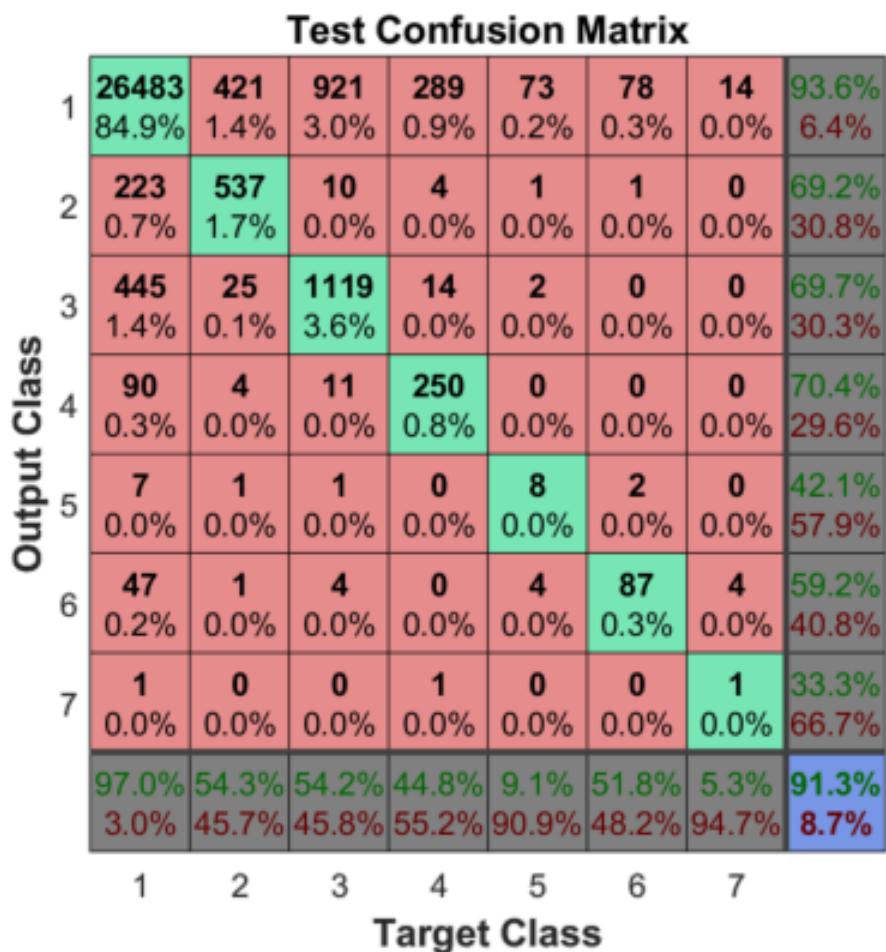
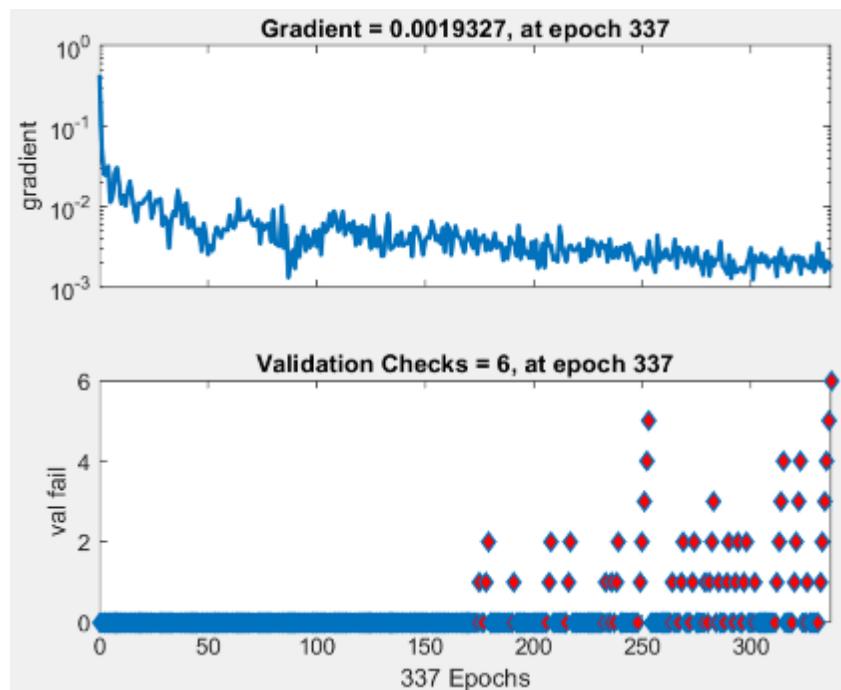
NS2: MLF Training für Negatives Sentiment. Versteckte Layer: 10 Neuronen , 6 Output Klassen, N-Gram von min 2, max 3



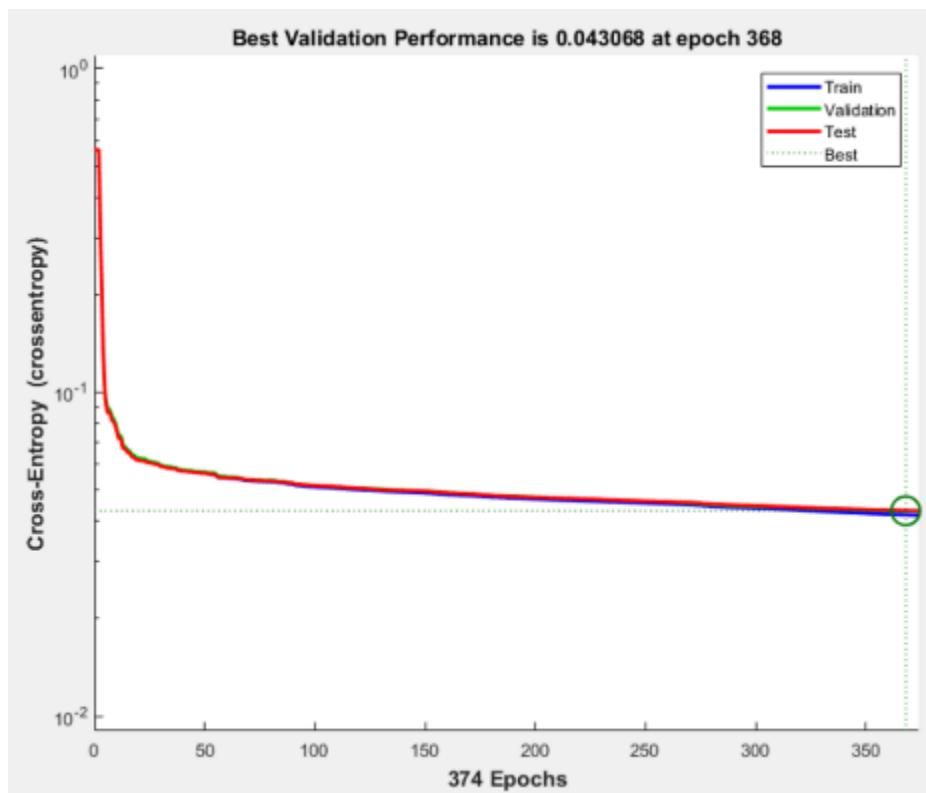
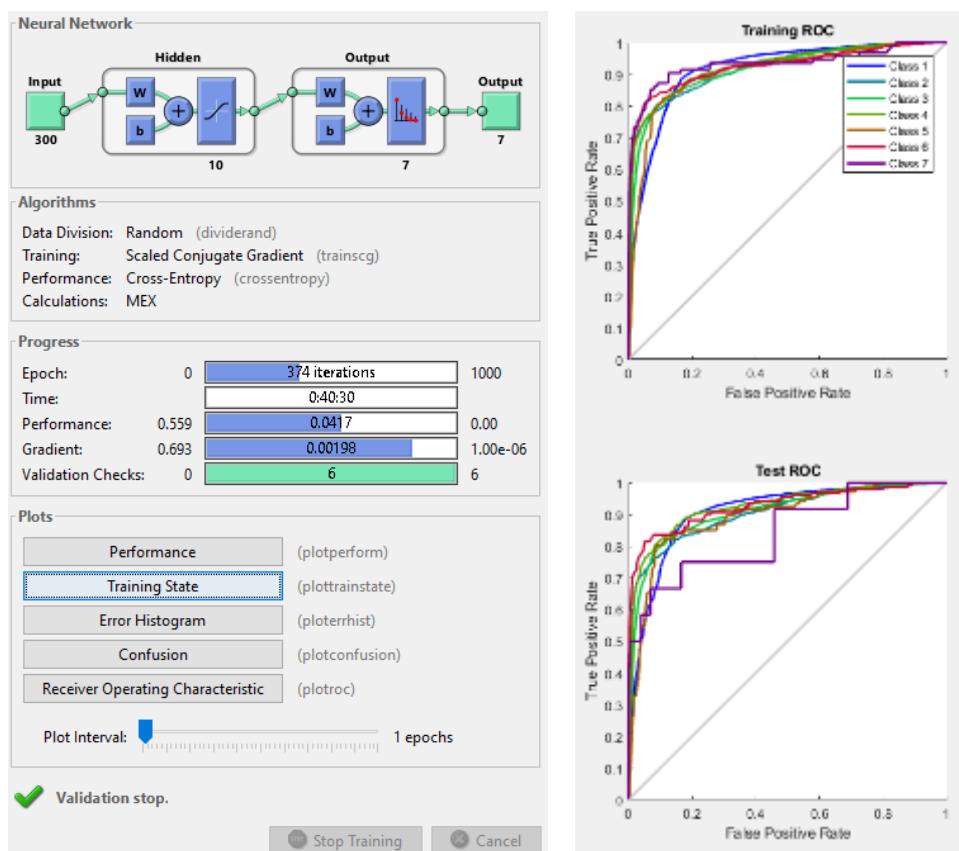


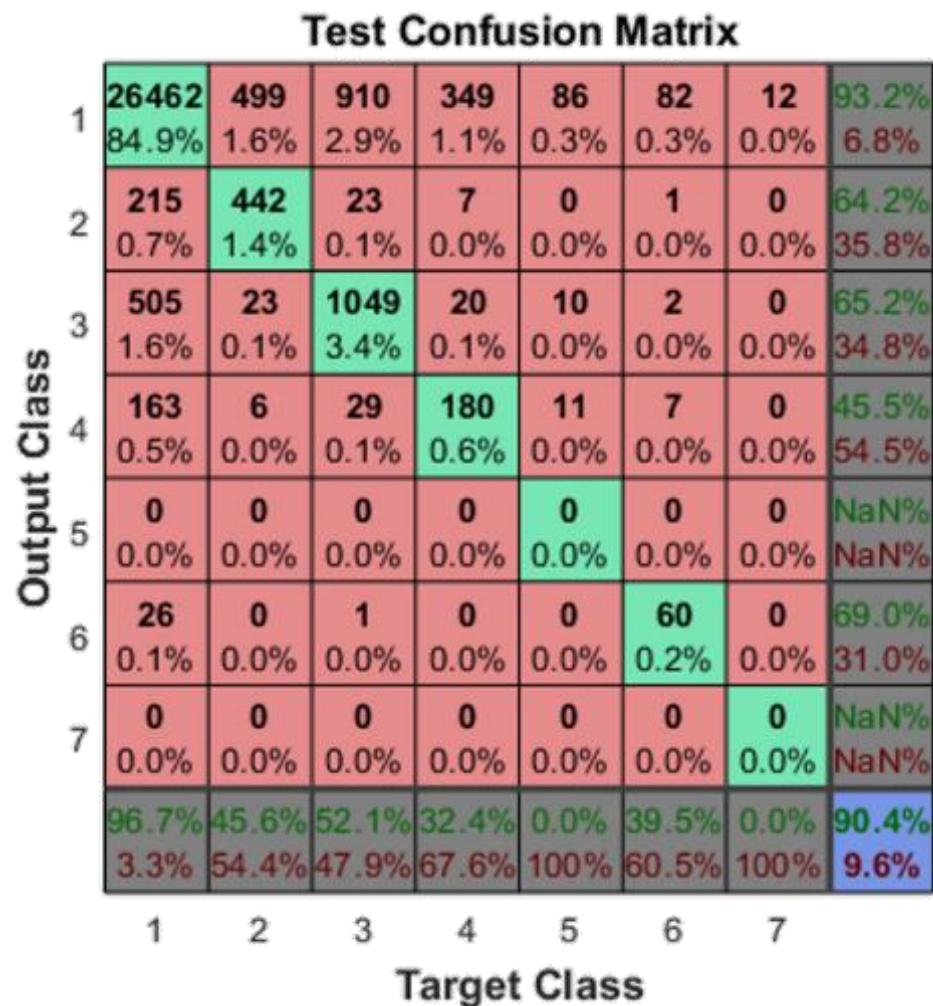
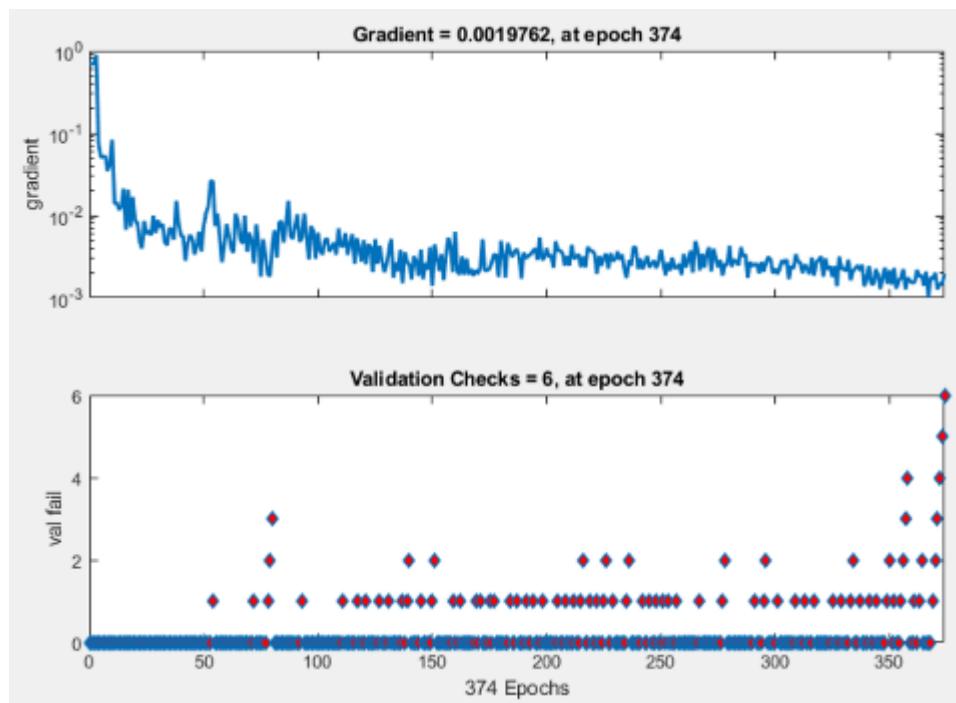
NS3: MLF Training für Negatives Sentiment. Versteckte Layer: 10 Neuronen , 6 Output Klassen, N-Gram von min 2, max 4



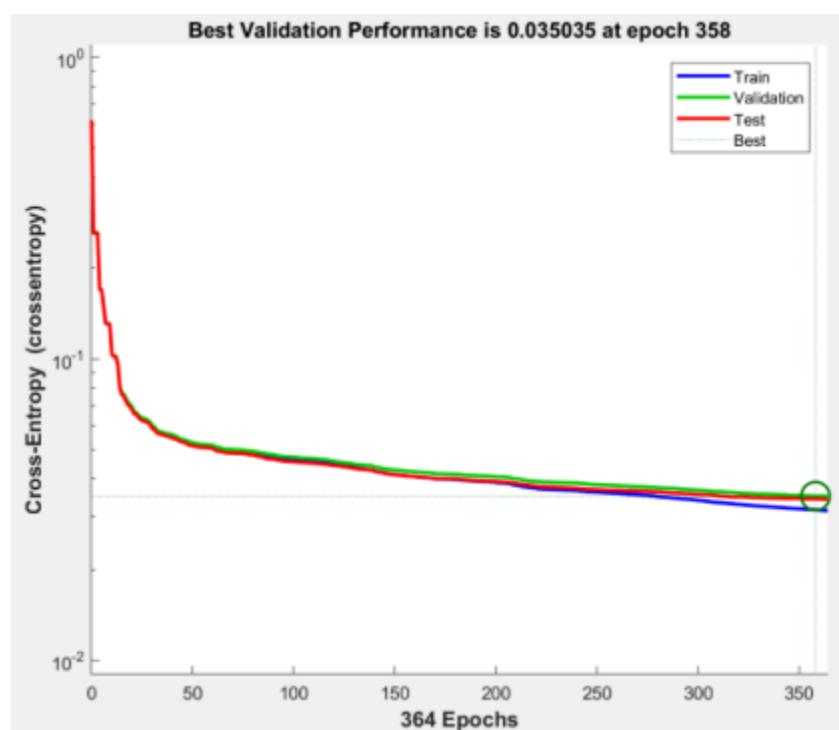
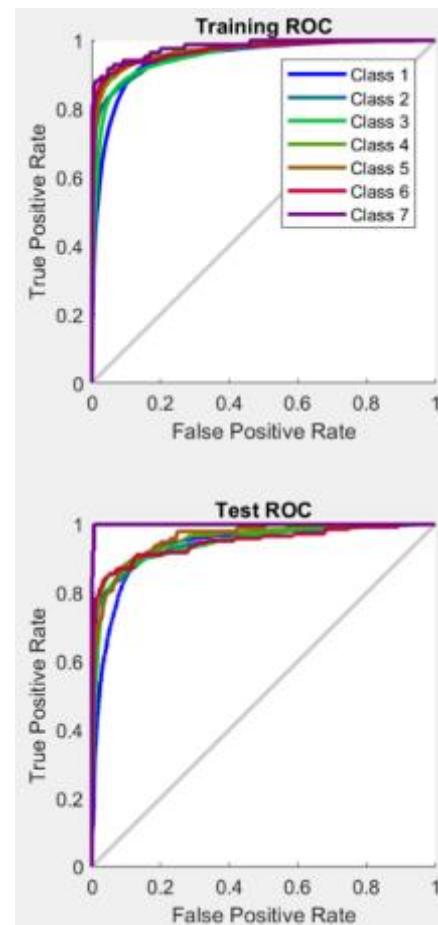
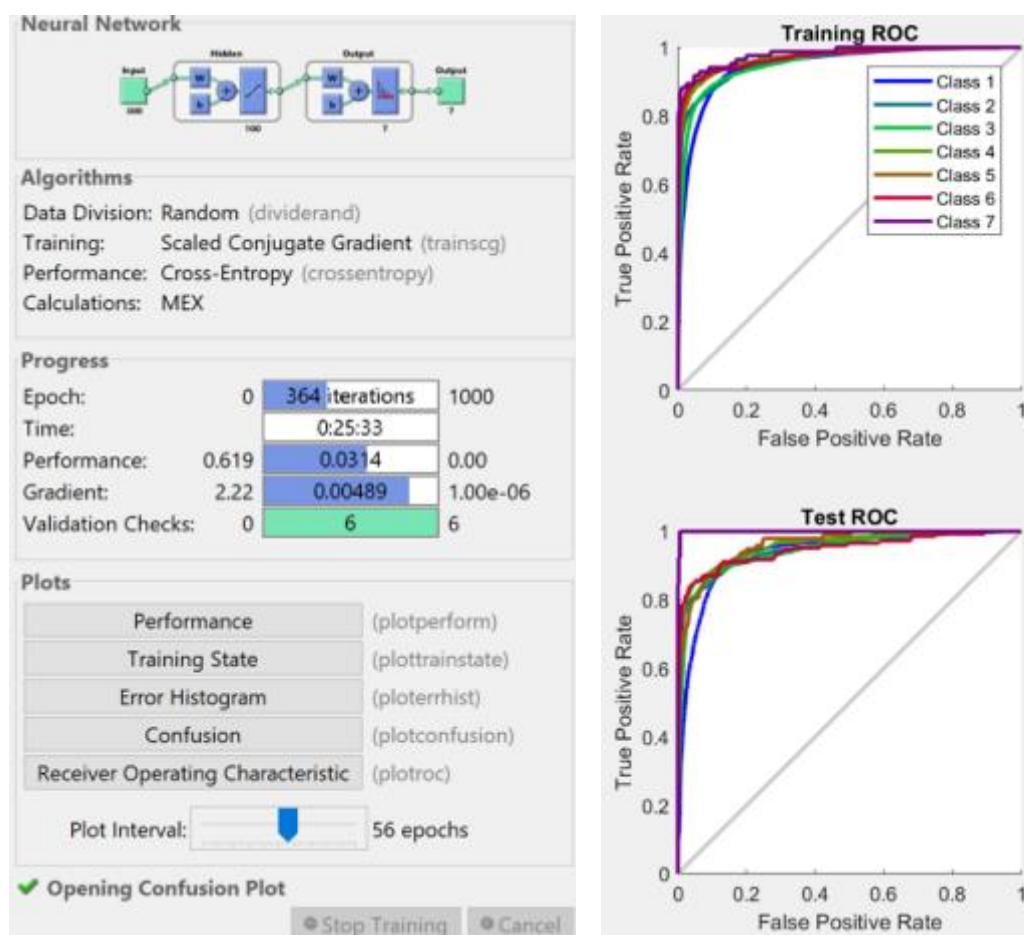


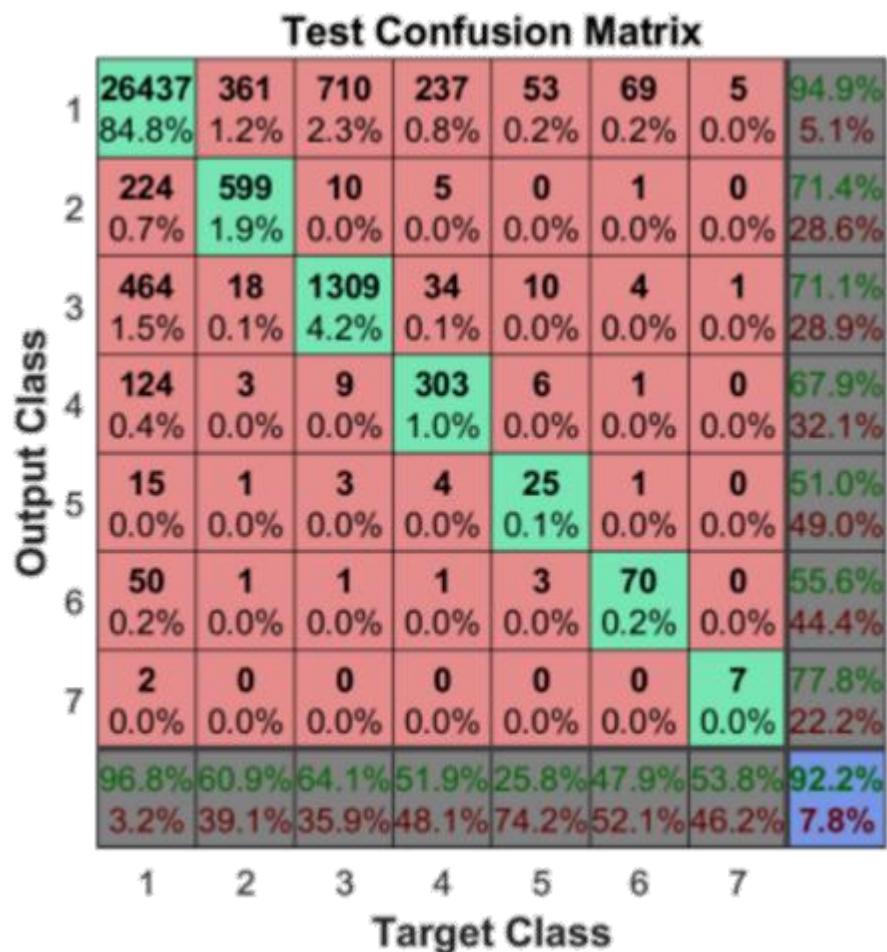
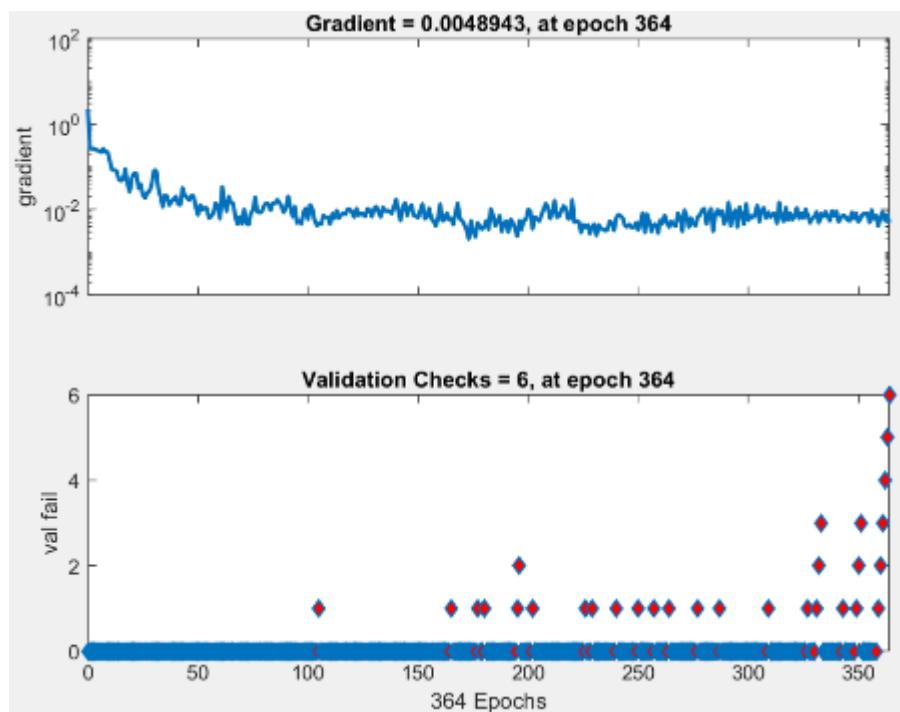
NS4: MLF Training für Negatives Sentiment. Versteckte Layer: 10 Neuronen , 6 Output Klassen, N-Gram von min 3, max 6



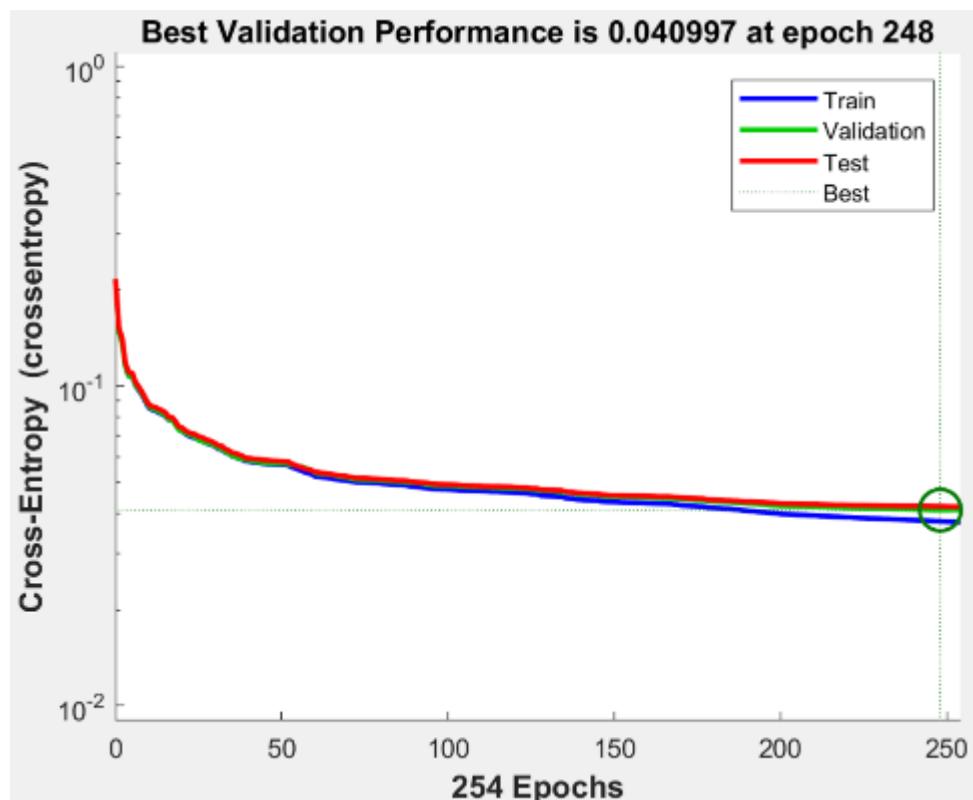
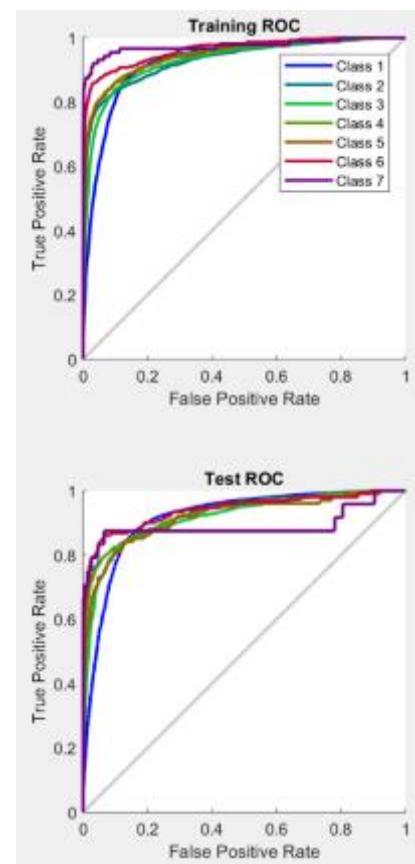
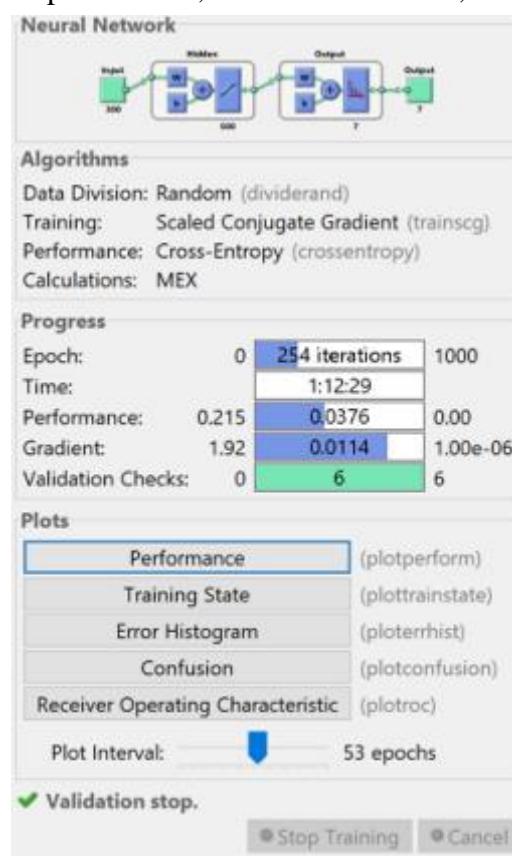


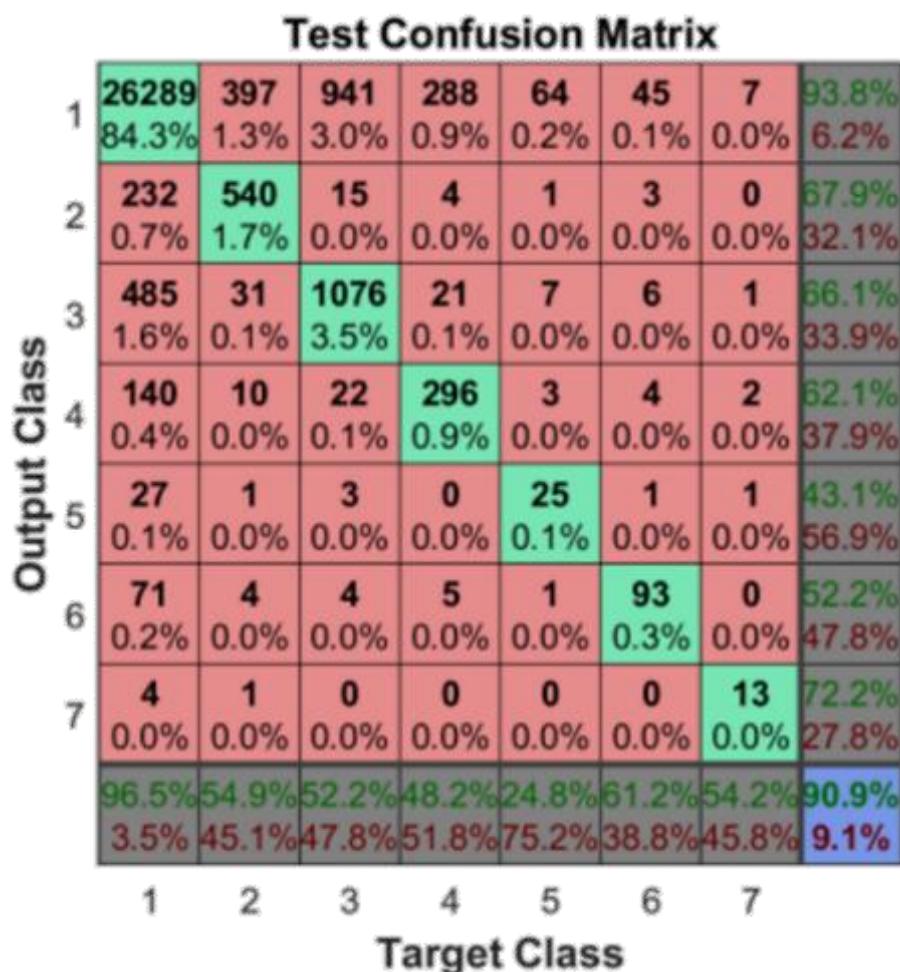
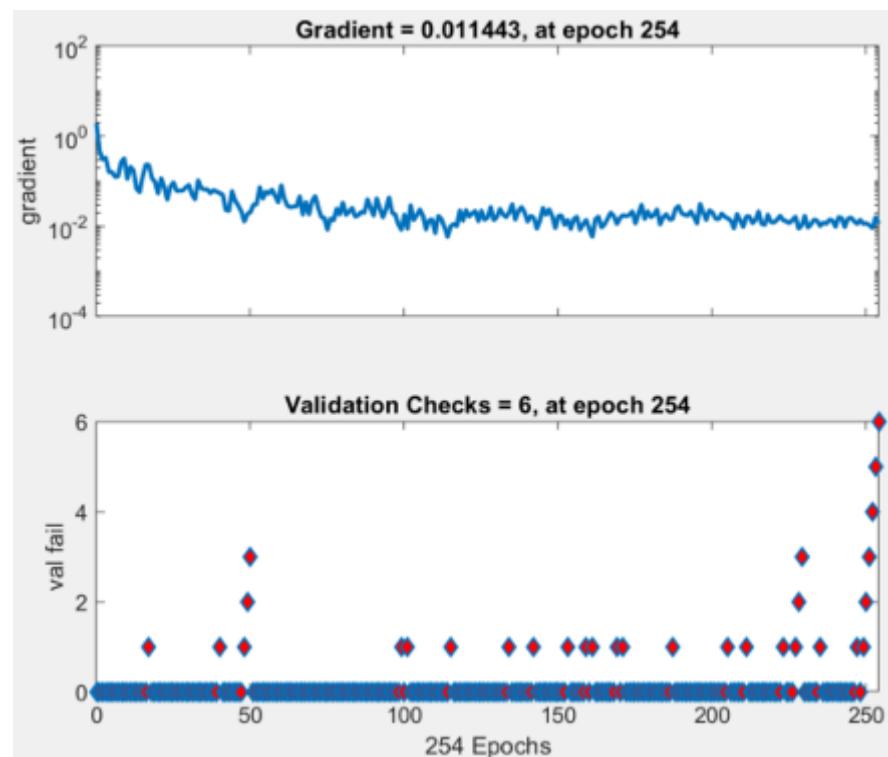
NS5: MLF Training für Negatives Sentiment. Versteckte Layer: 100 Neuronen , 6 Output Klassen, N-Gram von min 3, max 6



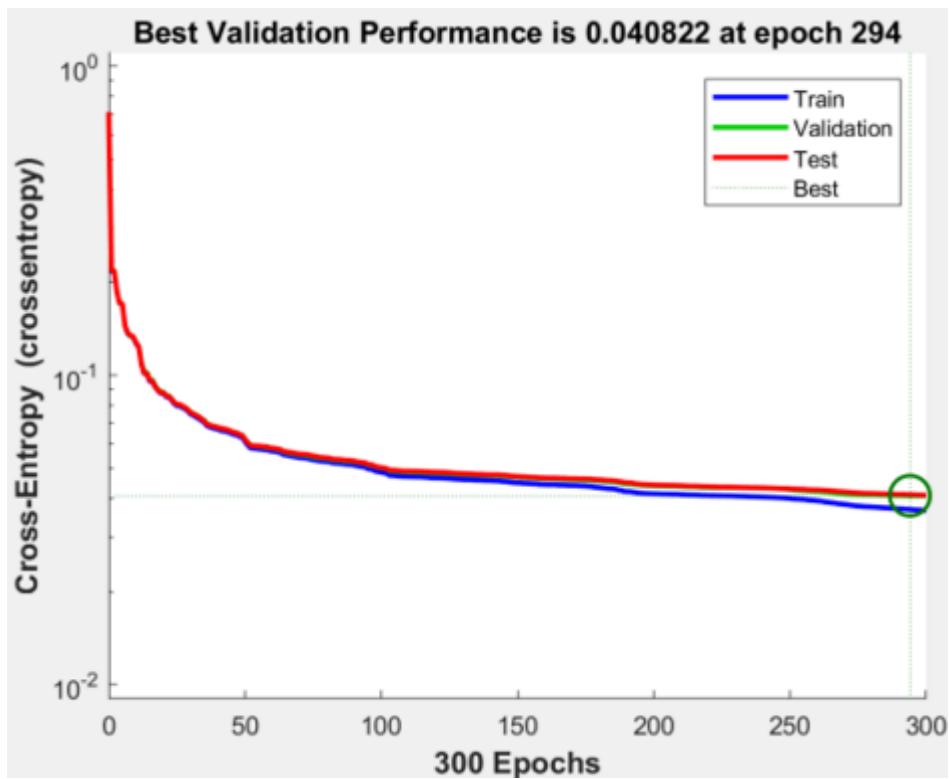
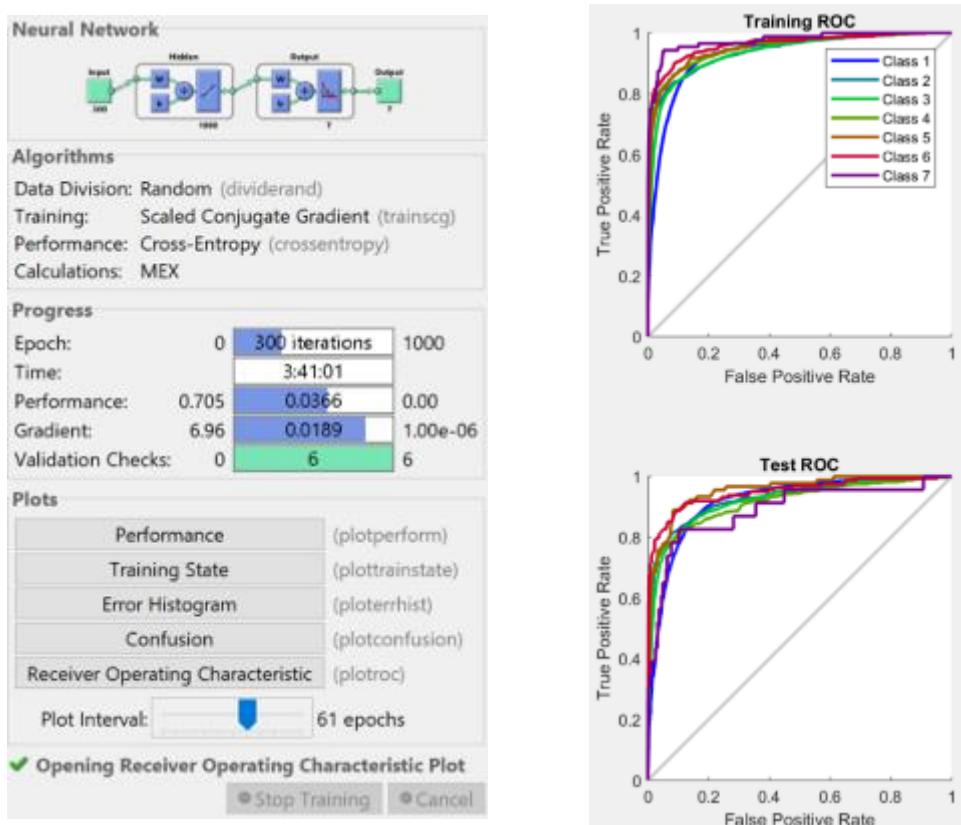


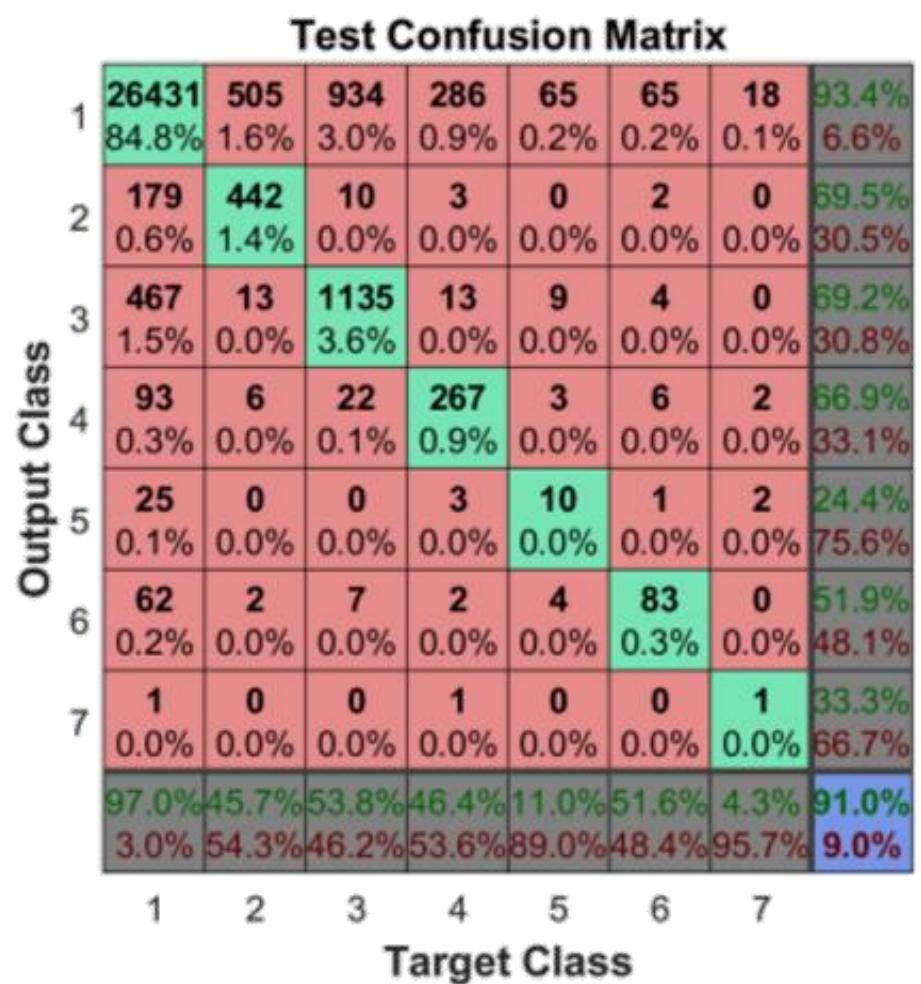
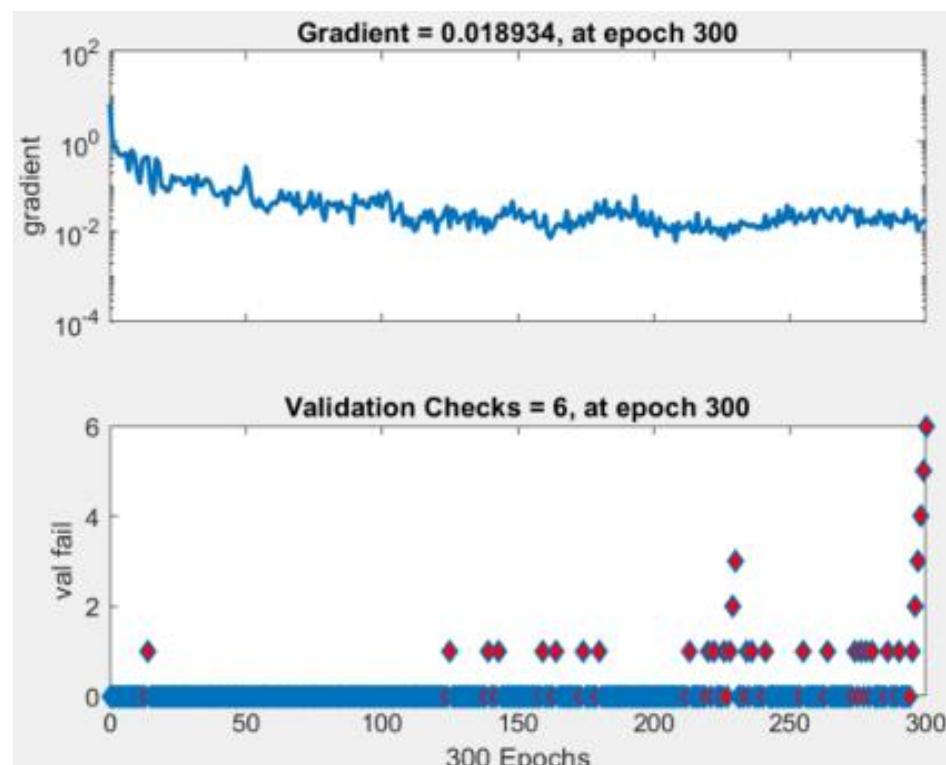
NS6: MLF Training für Negatives Sentiment. Versteckte Layer: 500 Neuronen , 6 Output Klassen, N-Gram von min 3, max 6





NS7: MLF Training für Negatives Sentiment. Versteckte Layer: 1000 Neuronen , 6 Output Klassen, N-Gram von min 3, max 6



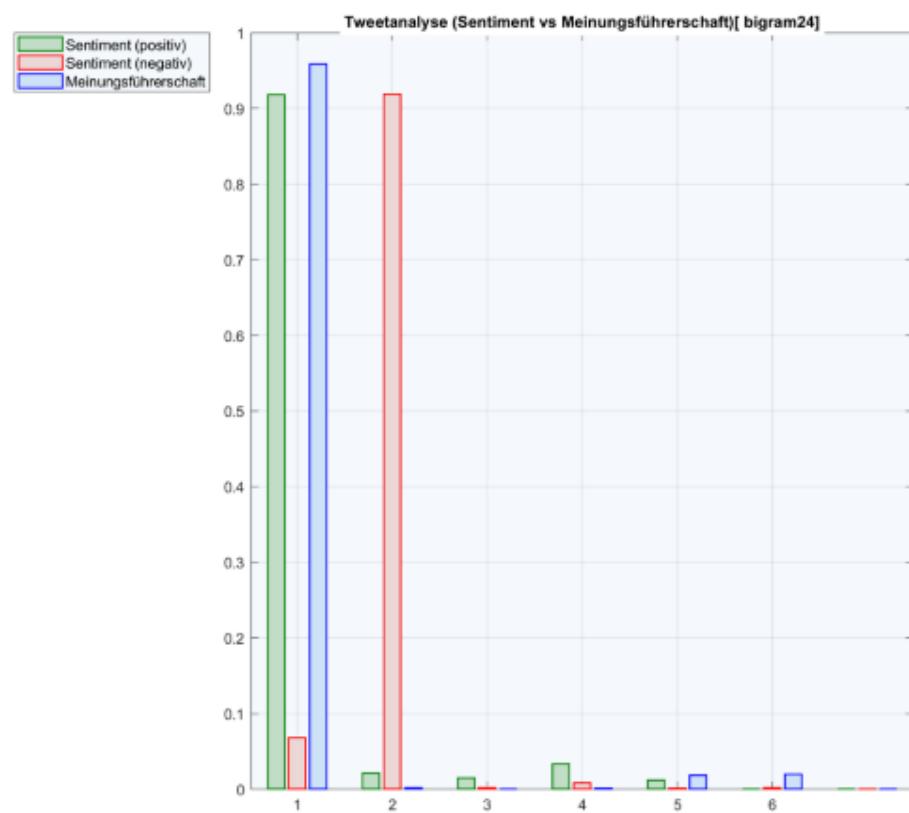
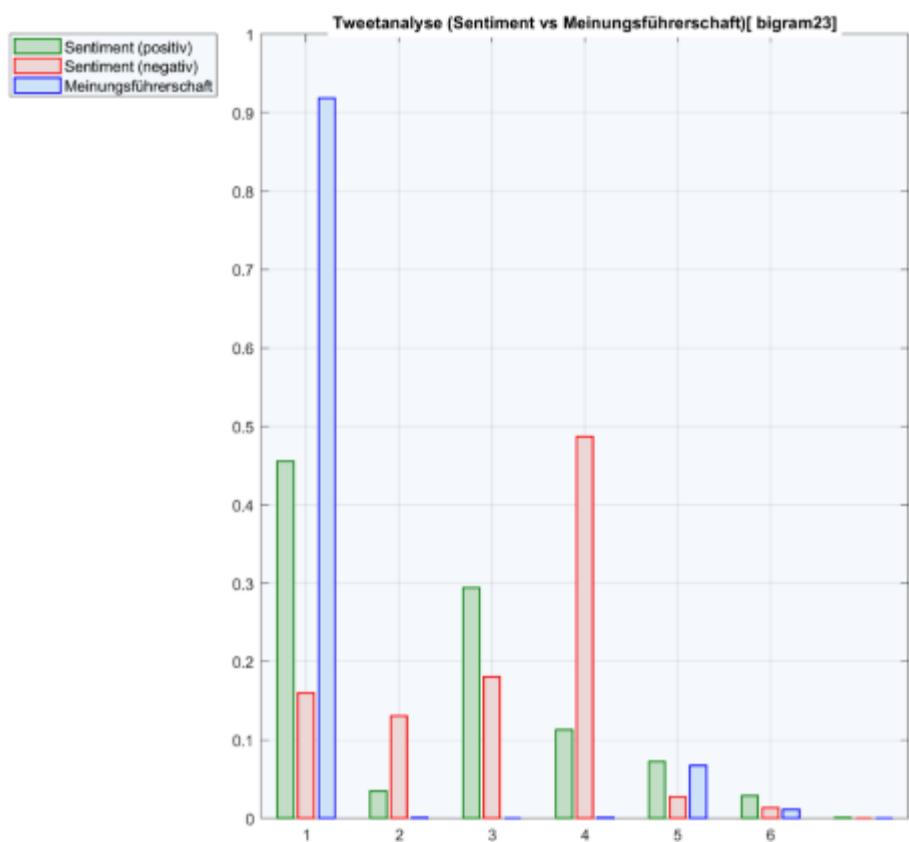


Anhang F

Test Tweet:

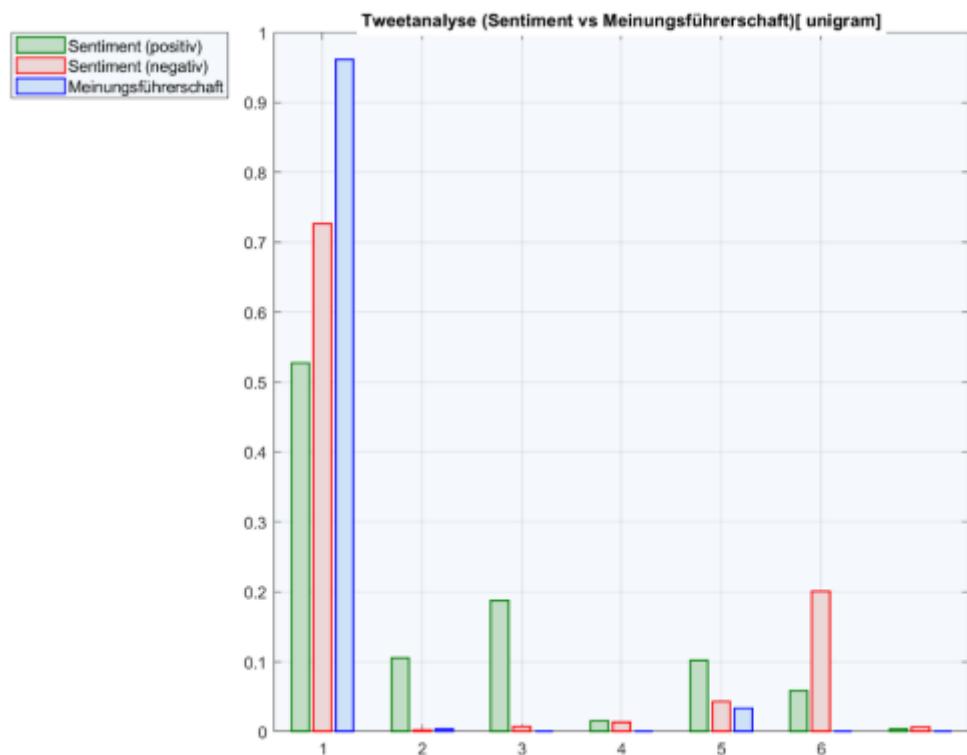
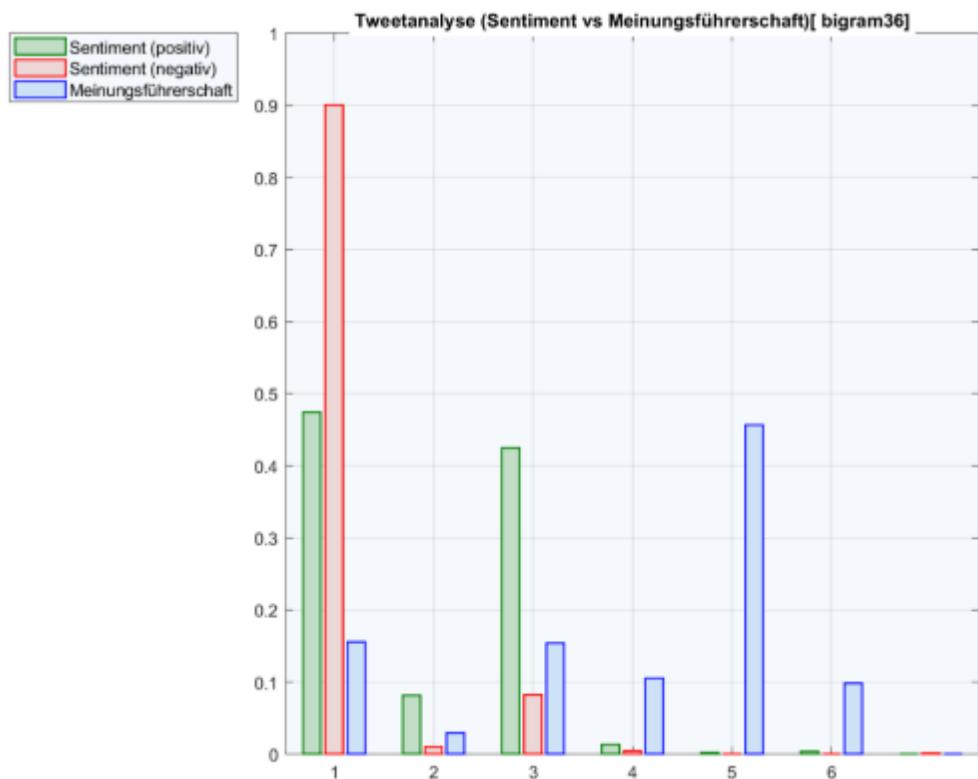
“When people are healthy, countries thrive. Learn how universal health coverage can help #EndPoverty”





Test Tweet:

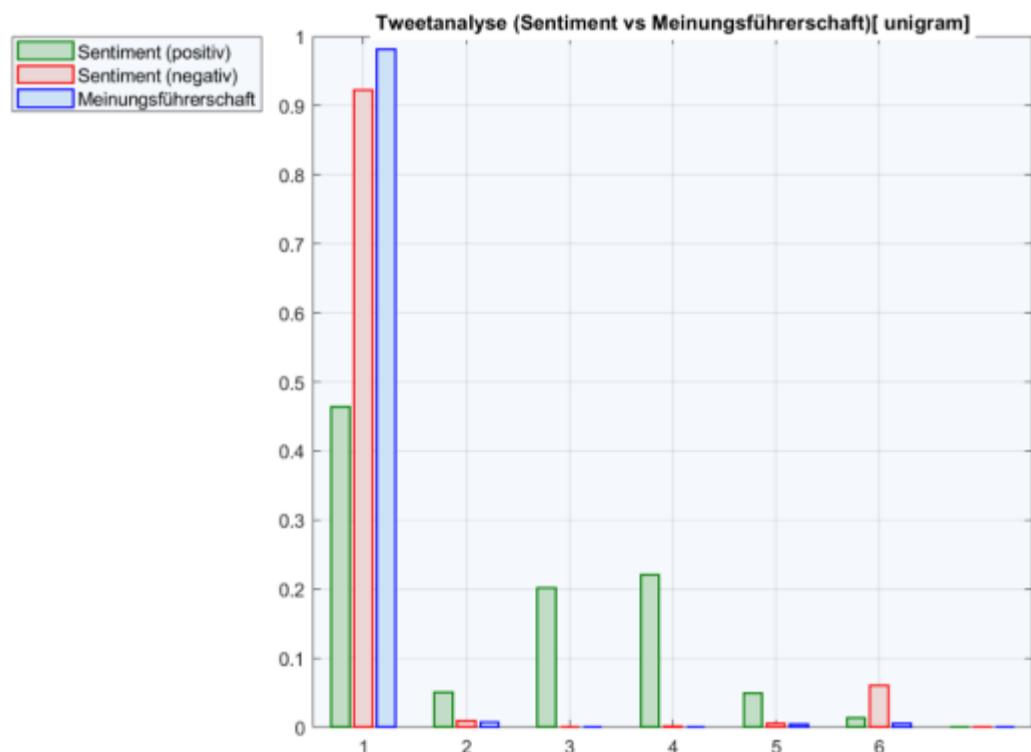
"My #WeAreHere pledge: I am here to disrupt how things used to be done! @mashable @unfoundation @92Y @gatesfoundation"

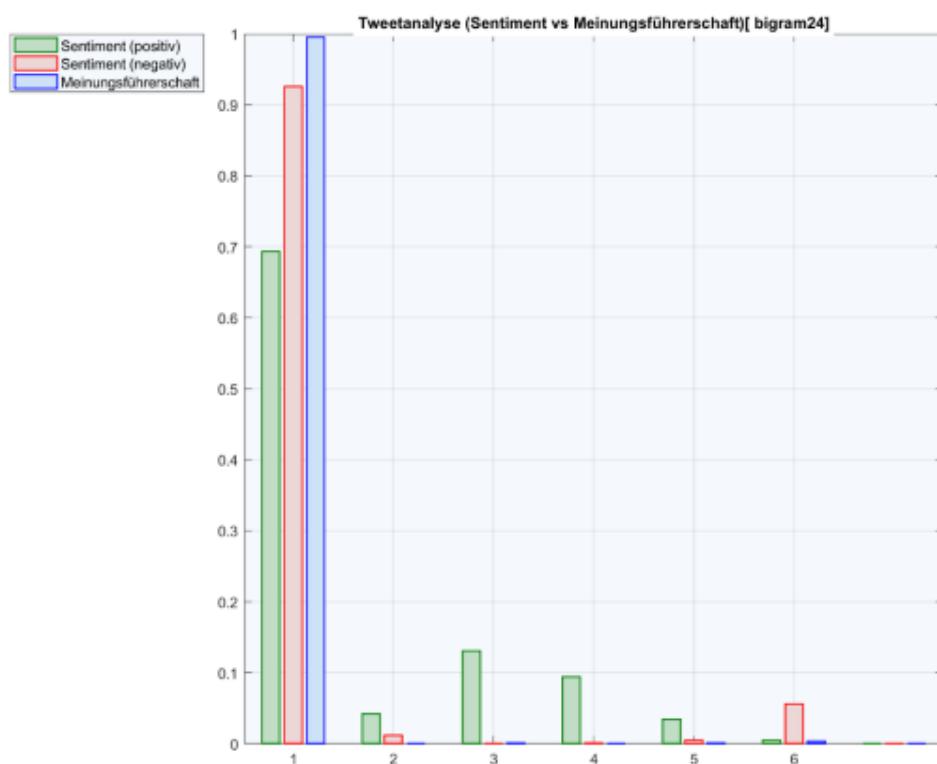
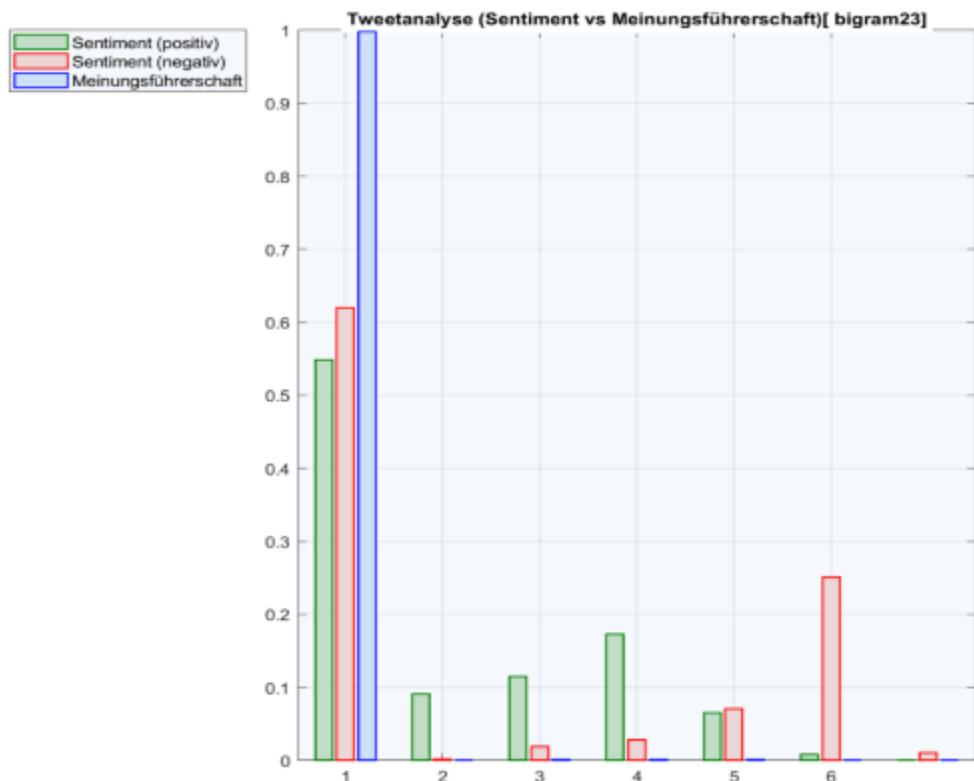




Test Tweet:

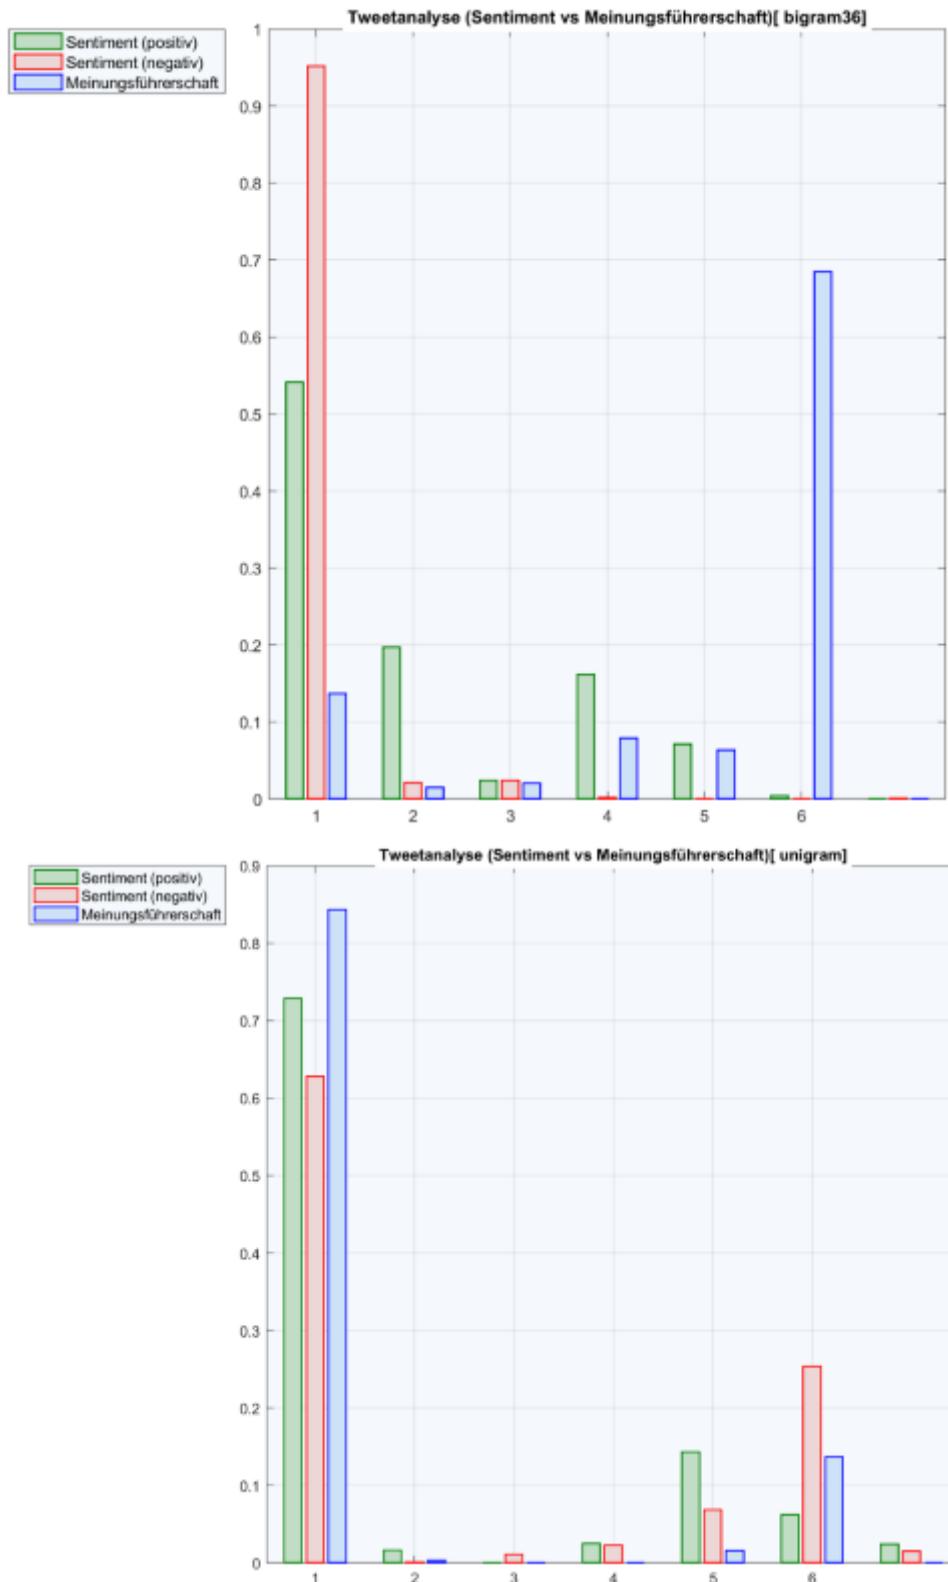
“A record 65,6 Million People are now displaced worldwide, says @Refugees”

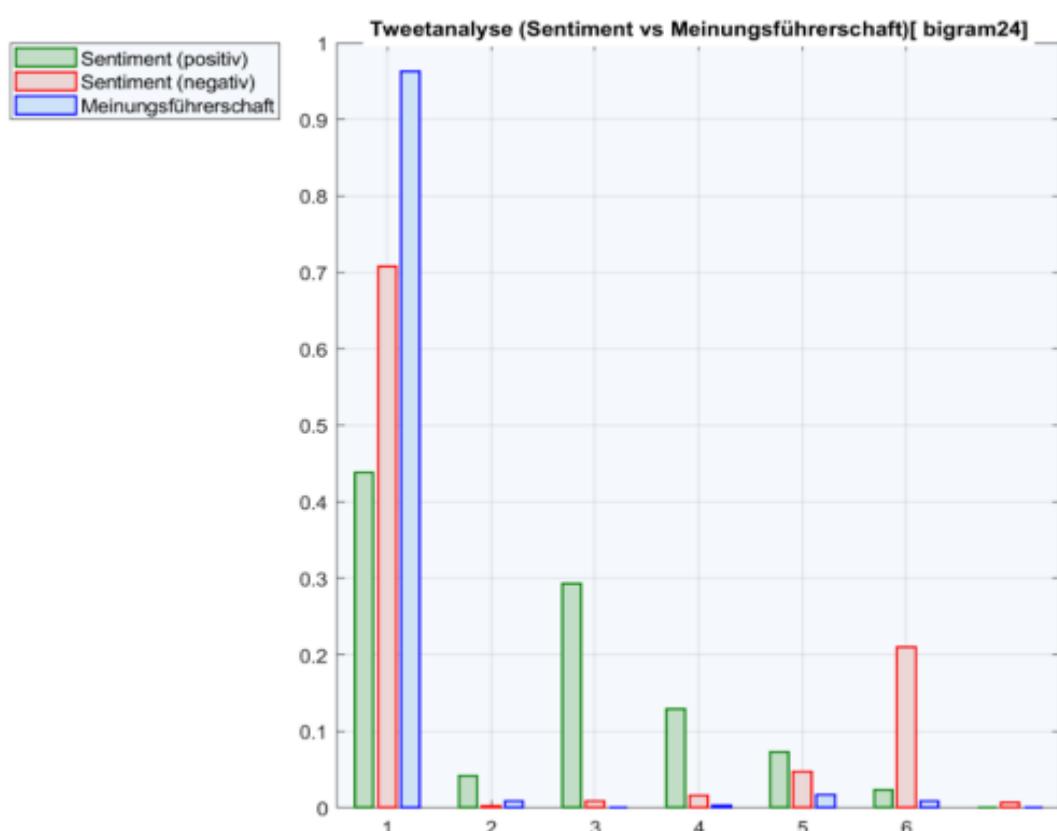
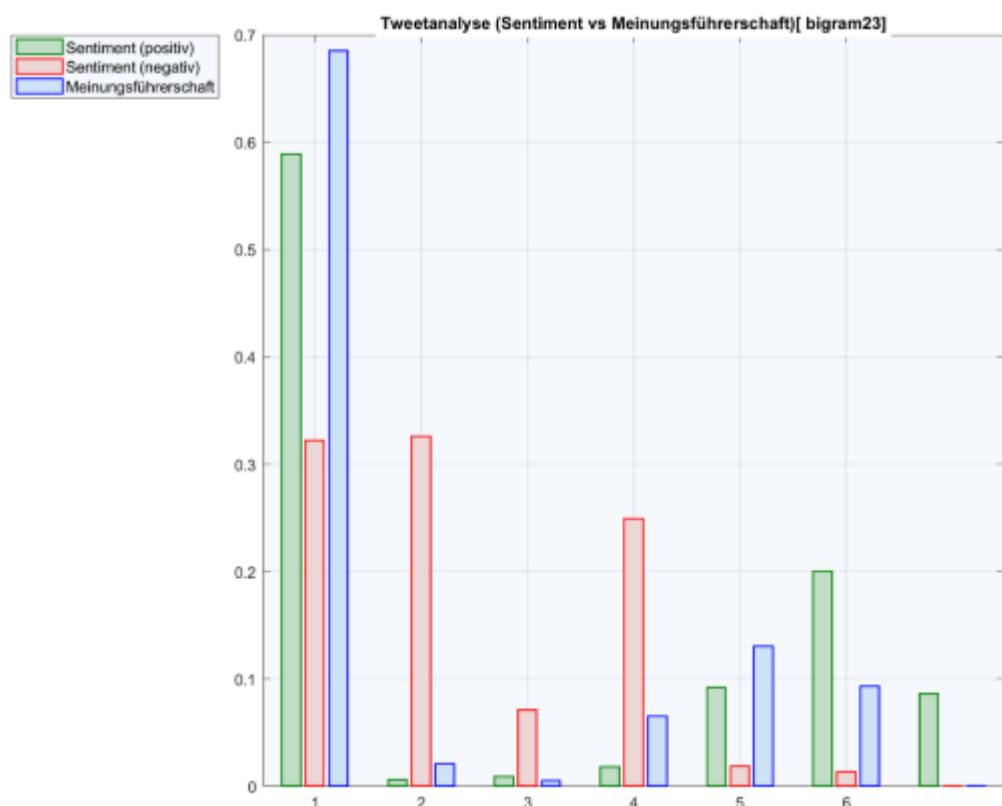




Test Tweet:

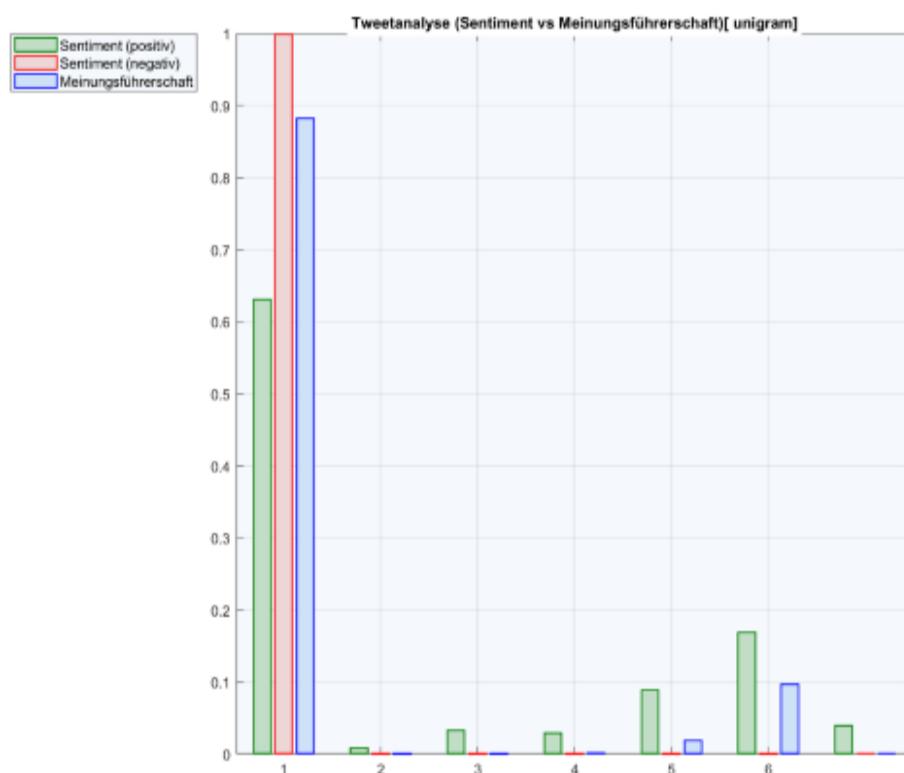
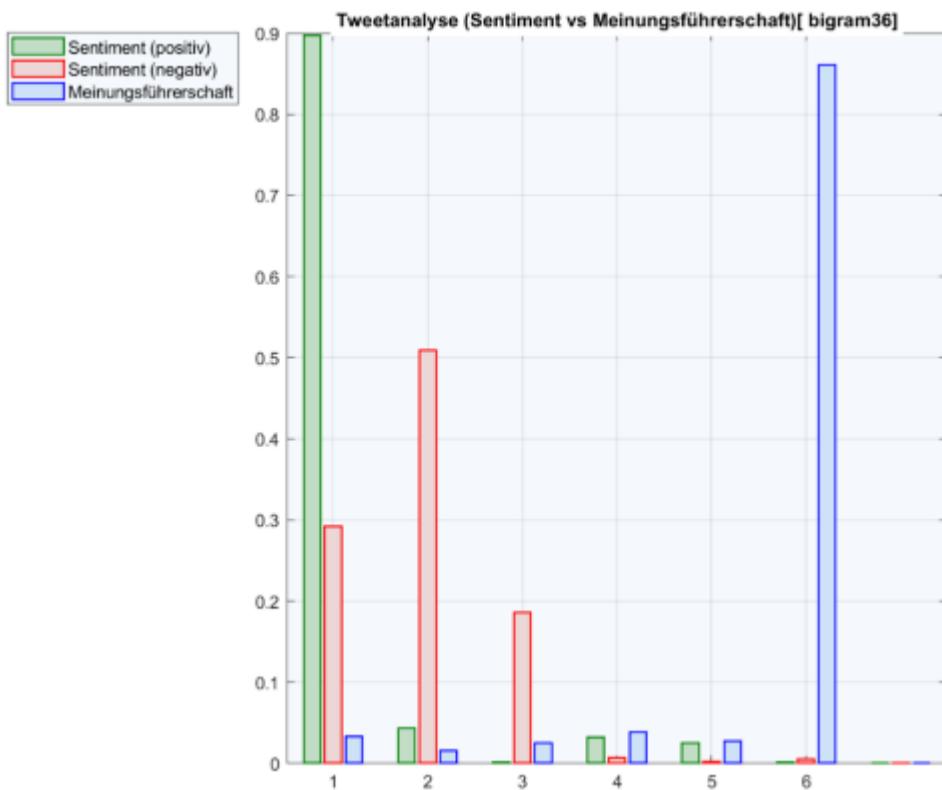
“Every 2 min, a child dies of malaria @nothingbutnets wants to #endmalaria for good”

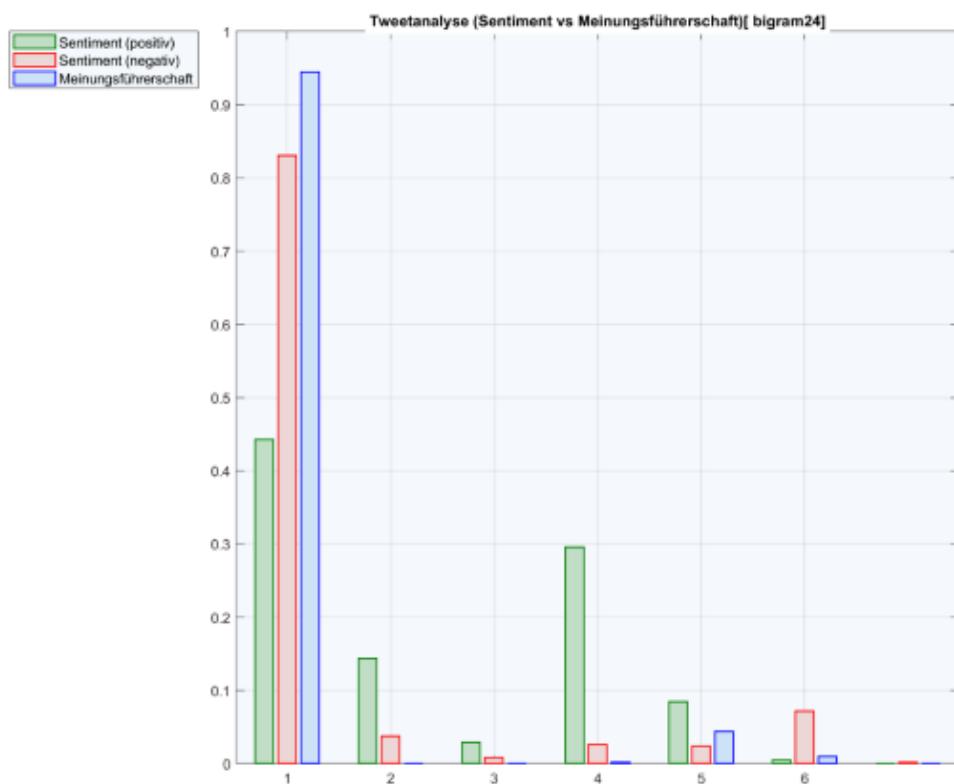
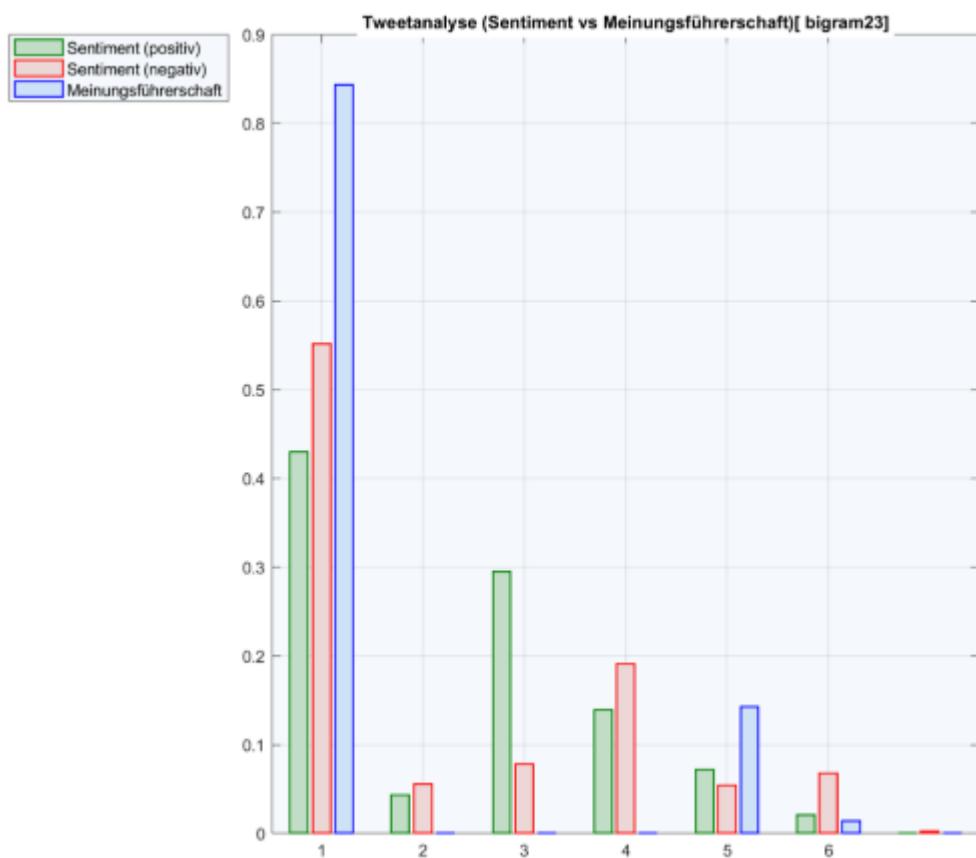




Test Tweet:

"As #HLPF continues, @who stresses the need for universal health coverage to achieve health targets of #GlobalGoals"





ERKLÄRUNG

Ich bestätige mit meiner Unterschrift, dass ich die Arbeit persönlich erstellt und dabei nur die aufgeführten Quellen und Hilfsmittel verwendet sowie wörtliche Zitate und Paraphrasen als solche gekennzeichnet habe.

Es ist mir bekannt, dass andernfalls die Fakultät gemäss der Entscheidung des Fakultätsrats vom 09.11.2004 das Recht hat, den auf Grund dieser Arbeit verliehenen Titel zu entziehen.

Ich erkläre hiermit weiterhin, dass diese Arbeit bzw. Teile daraus noch nicht in dieser Form an anderer Stelle als Prüfungsleistung eingereicht worden sind, gemäss der Entscheidung des Fakultätsrats vom 18.11.2013.

.....Boll....., den14.02.2018.....

.....
Janice Butler